

Luca Stephan Cueto de Almeida

Tornando visível o design de LLMs: um estudo eDSR do Projeto Gaia em português brasileiro

São Paulo

2025

Luca Stephan Cueto de Almeida

Tornando visível o design de LLMs: um estudo eDSR do Projeto Gaia em português brasileiro

Trabalho de Conclusão de Curso apresentado
à Escola de Administração de Empresas de
São Paulo da Fundação Getulio Vargas, como
requisito para obtenção do título de Bacharel
em Administração de Empresas.

Fundação Getulio Vargas

Escola de Administração de Empresas de São Paulo (FGV EAESP)

Graduação em Administração de Empresas

Orientador: Prof. Gabriel Silva Cogo

São Paulo

2025

Agradecimentos

Para quem lê, este é o começo. Mas esta página foi a última a ser produzida, pois não exigiu pesquisas, referências ou malabarismos mentais. Esta parte não foi quantitativa, nem qualitativa; sabe-se lá como posso chamar o impulso que transcreve pessoas, sensações e experiências em palavras.

Durante os últimos 5 anos e meio, dediquei-me integralmente à incerteza, seja por afinidade ou generalismo, mas minha trajetória foi uma colcha de retalhos. Ora me via seguindo os rumos tradicionais que a Fundação prepara, ora me via na contramão, ora estava em lugar nenhum. Mas apoio nunca me faltou.

Hoje, finalizo um arquivo que é uma síntese de tudo que aprendi e de tudo que fui ao longo desse tempo. Coloco reticências nessa trajetória com enorme satisfação, uma vez que sinto que consegui interseccionar minhas áreas favoritas do conhecimento — o que, apesar da complexidade, representa um desafio prazeroso.

Todavia, de absolutamente nada vale essa caminhada sem as pessoas que a compuseram. A vocês, quero que saibam que de nada valeria este momento sem tê-los em meus pensamentos agora. Portanto, dedico minha felicidade a todos.

Um imenso agradecimento aos meus colegas de sala, profissionais, colegas de entidade e chefes. Vocês me ensinaram muito e valorizo cada troca de conhecimento, mas especialmente a troca pessoal.

Jamais conseguiria sequer sonhar grande sem a base de apoio em que cresci. Logo, dedico o meu propósito integralmente à minha família, como uma criança que dedica o sonho de ser astronauta. Mãe, Pai, Nhan, Graça e Margot (essa aqui nunca vai entender, tadinha), obrigado por serem os maiores impulsionadores da minha formação acadêmica, mas principalmente da minha formação como ser humano.

Aos meus melhores amigos: é um prazer crescer com vocês e dividir essas conquistas em mais uma fase da vida. Espero celebrar com vocês até o final. Giovana, Eliza, Enzo, Rômulo, Cauê, Lorenzo, Henrisco, Duardin, Miranda, Teteu, Moçamba, Duds, Pipo, Ap6(rs), Guizão, Braga, Thalin e Vieira: vocês são a melhor parte da vida.

Além desses amores, também tenho o prazer de celebrar mais um. À minha querida companheira, namorada e melhor amiga, Duarda, dedico cada linha desta tese e cada batida que meu coração errou nestes últimos dois anos. A frequência e a intensidade da sua companhia sempre me lembram como tudo vale a pena. Desejo que o futuro nos reserve o que o presente nos proporciona: um ao outro.

Por fim, celebro todo esse amor que me circunda e me orgulha mais que qualquer conquista acadêmica. Obrigado.

Resumo

Modelos de Linguagem de Grande Porte (LLMs) têm demonstrado uma assimetria de desempenho global, resultando em performance inferior e menor aderência cultural quando operam em Português Brasileiro (PT-BR) (CRUZ-CASTAÑEDA; AMADEUS, 2025), sobretudo em tarefas de geração. Paralelamente, a literatura de Inteligência Artificial (IA) concentra-se majoritariamente no artefato final (o modelo e suas métricas), estabelecendo uma lacuna metodológica ao deixar invisível o processo sociotécnico de design, as decisões modulares e a validação incremental (LIPTON; STEINHARDT, 2018).

Este trabalho aborda essa dupla lacuna — técnica (o déficit de arquiteturas *decoder-only* especializadas em PT-BR) e metodológica (a “caixa preta” do design de IA) — tomando como estudo de caso o Projeto Gaia, um LLM de nicho aberto, desenvolvido em um consórcio acadêmico-industrial (CRUZ-CASTAÑEDA; AMADEUS, 2025). O objetivo central é gerar uma teoria de médio alcance sobre o design de LLMs de nicho (TUUNANEN; GHANBARI; KAZAN, 2024; GREGOR; HEVNER, 2013).

Para tanto, a pesquisa emprega o framework *Echeloned Design Science Research* (eDSR) para reconstituir o processo de design do Gaia ao longo de cinco echelons (problema, requisitos, design, prova de conceito e prova de valor), tornando visíveis os artefatos intermediários gerados em cada fase (TUUNANEN; GHANBARI; KAZAN, 2024; LIPTON; STEINHARDT, 2018). A análise é complementada pelo *Framework for Evaluation in Design Science* (FEDS) para distinguir rigorosamente as avaliações de Prova de Conceito (PoC) — que são tipicamente formativas e artificiais (ex.: benchmarks) — da Prova de Valor (PoV), que são somativas e naturalísticas (TUUNANEN; GHANBARI; KAZAN, 2024; JINDAL; AL., 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

A investigação adota uma rigorosa estratégia de triangulação em três fontes (literatura, documentação pública e dados primários de entrevistas) (TUUNANEN; GHANBARI; KAZAN, 2024; GREGOR; HEVNER, 2013). Espera-se como contribuição final um conjunto de Princípios de Design generalizáveis e um template metodológico que sirva como roteiro para outras equipes documentarem e otimizarem o ciclo de desenvolvimento de LLMs especializados em línguas com representação assimétrica, como o PT-BR, reduzindo custos e incerteza (GHANBARI; TUUNANEN; KAZAN, 2025).

Palavras-chave: Modelos de linguagem de grande porte. Português brasileiro (PT-BR). LLMs de nicho. Design Science Research (DSR). eDSR. Artefatos intermediários. Prova de conceito (PoC). Prova de valor (PoV).

Abstract

Large Language Models (LLMs) exhibit a global performance asymmetry, leading to inferior performance and lower cultural adherence when operating in Brazilian Portuguese (PT-BR), particularly in generative tasks. In parallel, the Artificial Intelligence (AI) literature predominantly focuses on the final artifact (the model and its metrics), establishing a methodological gap by rendering the sociotechnical design process, modular decisions, and incremental validation invisible (the “black box” of AI design).

This work addresses this dual gap—technical (the deficit of specialized decoder-only architectures for PT-BR) and methodological (the invisibility of AI design)—by taking Projeto Gaia as a case study, an open niche LLM developed within an academic-industrial consortium. The central objective is to generate a mid-range design theory concerning the design of niche LLMs.

To this end, the research employs the Echeloned Design Science Research (eDSR) framework to reconstruct Gaia’s design process across five echelons (problem, requirements, design, proof of concept, and proof of value), thereby making the intermediate artifacts generated in each phase visible. The analysis is complemented by the Framework for Evaluation in Design Science (FEDS) to rigorously distinguish Proof of Concept (PoC) evaluations—typically formative and artificial (e.g., benchmarks)—from Proof of Value (PoV), which are summative and naturalistic (e.g., stakeholder feedback in real use).

The investigation adopts a rigorous strategy of triangulation across three sources (literature, public documentation, and primary interview data). The expected final contribution is a set of generalizable Design Principles and a methodological template to serve as a roadmap for other teams documenting and optimizing the development cycle of LLMs specialized in languages with asymmetric representation, such as PT-BR, thereby reducing costs and uncertainty.

Keywords: Large Language Models. Brazilian Portuguese (PT-BR). Niche LLMs. Design Science Research (DSR). eDSR. Intermediate Artifacts. Proof of Concept (PoC). Proof of Value (PoV).

Lista de ilustrações

Figura 1 – Efeito do CPT e dos Instruction Residuals: em Setting 1 (CPT no instruído), métricas de instruction-following (ex.: IFEval) caem com o aumento de tokens; em Setting 2 (CPT no base + IR), a capacidade é restaurada ou supera o baseline instruído (dados adaptados de Jindal e al. (2024), Tabs. 2–3; Fig. 3–4).	40
Figura 2 – Distribuição de arquiteturas em PT-BR-LLMs (encoder-only $n = 19$; decoder-only $n = 11$; encoder-decoder $n = 4$).	41
Figura 3 – Desempenho generativo e custo de inferência em PT-BR. Comparação entre modelos brasileiros (Sabiá-3, Tucano, Cabra, etc.) e GPT-4o, com tempos de inferência, energia e CO ₂ eq.	43
Figura 4 – Metamodelo do eDSR: echelons, artefatos intermediários e ciclos de validação	47
Figura 5 – FEDS: propósitos e paradigmas de avaliação	51
Figura 6 – Fluxo de Rastreamento da Complexidade Técnica no eDSR (Caso Gaia: CPT + Instruction Residuals)	56
Figura 7 – Pipeline CPT→IR e mitigação de risco	72
Figura 8 – Linha do tempo FEDS (E3→E4→E5)	77
Figura 9 – Progressão FEDS do Echelon 4	79
Figura 10 – Teoria de médio alcance (C–P–M–E) para LLMs de nicho em PT-BR .	85

Lista de tabelas

Tabela 1 – POS em línguas brasileiras: Comparação entre GPT-4 e XLM-R	39
Tabela 2 – Comparativo de Valor entre LLMs Genéricos e de Nicho	45
Tabela 3 – Definição e Artefatos dos Echelons de DSR	49
Tabela 4 – Ponte eDSR × FEDS (o que validar, como validar e quando avançar) .	50
Tabela 5 – Ponte de validação por echelon (eDSR + FEDS) para o Projeto Gaia .	54
Tabela 6 – Exemplo de Registro de Decisão de Design (DDR)	57
Tabela 7 – Matriz FEDS (Formativa/Somativa × Artificial/Naturalística) com exemplos do Projeto Gaia mapeados por echelon	58
Tabela 8 – Definição do Princípio de Design (DP)	59
Tabela 9 – Princípio de Design DP-CPT-IR-01	59
Tabela 10 – Tabela-Mestra eDSR (E1 — Análise do Problema)	62
Tabela 11 – Tabela-Mestra eDSR (E2 — Objetivos & Requisitos)	62
Tabela 12 – Tabela-Mestra eDSR (E3 — Design & Desenvolvimento)	62
Tabela 13 – Tabela-Mestra eDSR (E4 — Demonstração / PoC)	63
Tabela 14 – Tabela-Mestra eDSR (E5 — Avaliação / PoV)	63
Tabela 15 – Mapeamento do Echelon 1 (Diagnóstico do Problema)	69
Tabela 16 – Mapeamento de Objetivos (DO) e Requisitos (DR) do Echelon 2 . . .	70
Tabela 17 – Matriz de Priorização e Validação dos Requisitos (Efficacy vs. Efficiency)	70
Tabela 18 – Matriz comparativa de candidatos × critérios para seleção do <i>backbone</i>	73
Tabela 19 – Quadro 4.3.2-C — DDR-E3-01: Seleção do backbone do Gaia	73
Tabela 20 – Curadoria de dados e implicações para CPT	76
Tabela 21 – Principais DDRs de E3 (Design e Desenvolvimento)	76
Tabela 22 – Boundary conditions e indicadores de saída	77
Tabela 23 – Episódios de E4, tipagem FEDS e ligação com E3/E5	79
Tabela 24 – Indicadores de Ecossistema e Adoção (Hugging Face)	80
Tabela 25 – Episódios de PoV, tipagem FEDS e status de evidência	81
Tabela 26 – Síntese da Instanciação do eDSR no Projeto Gaia (E1–E5)	81
Tabela 27 – Projeto Gaia — Visão eDSR (E1–E5)	82
Tabela 28 – Cartão DP1 — CPT→IR: especializar preservando instruções	87
Tabela 29 – Cartão DP2 — Curadoria por qualidade: subset > volume bruto . . .	89
Tabela 30 – Cartão DP3 — Avaliação dual (FEDS): Formativa/Artificial → Soma- tiva/Naturalística	91
Tabela 31 – Cartão DP4 — Família de tamanhos para adoção contextualizada . . .	92
Tabela 32 – Cartão DP5 — Rastreabilidade via DDRs acoplada a echelons	94
Tabela 33 – Proposições testáveis (P1–P5) baseadas na teoria de médio alcance C–P–M–E	104
Tabela 34 – Template — Tabela-mestra eDSR (E1–E5)	108

Lista de abreviaturas e siglas

AI	Inteligência Artificial
CPT	<i>Continuous Pre-Training</i> (Pré-treinamento contínuo)
DDR	<i>Design Decision Record</i> (Registro de Decisão de Design)
DPs	Princípios de Design
DRs	Requisitos de Design
DSR	<i>Design Science Research</i>
eDSR	<i>Echeloned Design Science Research</i>
FEDS	<i>Framework for Evaluation in Design Science</i>
IR	<i>Instruction Residuals</i> (Resíduos Instrucionais)
LLMs	<i>Large Language Models</i> (Modelos de Linguagem de Grande Porte)
NLG	<i>Natural Language Generation</i> (Geração de Linguagem Natural)
PoC	<i>Proof of Concept</i> (Prova de Conceito)
PoV	<i>Proof of Value</i> (Prova de Valor)
PT-BR	Português Brasileiro
SOTA	<i>State-of-the-Art</i> (Estado da Arte)

Sumário

1	INTRODUÇÃO	19
1.1	Contextualização: a era dos LLMs e a lacuna de representação (o viés do inglês)	20
1.1.1	A Lacuna de Representação no Contexto Brasileiro	21
1.2	O problema de pesquisa	23
1.2.1	O problema técnico: a escassez de LLMs de nicho para o português brasileiro	23
1.2.2	O problema metodológico: a “caixa preta” do processo de design de IA	24
1.3	Objetivo Geral e Objetivos Específicos	26
1.3.1	Objetivo Geral	26
1.3.2	Objetivos Específicos	26
1.4	Justificativa Acadêmica e Prática	27
1.4.1	Justificativa Acadêmica: Transformação do <i>Know-How</i> em Teoria de Design	28
1.4.2	Justificativa Prática: Otimização de Design e Mitigação de Riscos em PT-BR	29
1.5	Delimitações do Estudo	30
1.5.1	Delimitação do Escopo Empírico (O Projeto Gaia)	30
1.5.2	Delimitação do Escopo Metodológico (eDSR e Teoria)	31
1.6	Estrutura da Tese	32
1.7	Lacunas Específicas Abordadas pela Tese	33
2	FUNDAMENTAÇÃO TEÓRICA E METODOLÓGICA	37
2.1	O Eixo do Domínio: Assimetria Linguística e a Lacuna Generativa em PT-BR	38
2.1.1	Paradoxo do PT-BR	38
2.1.2	A Racionalidade Técnica da Especialização (CPT e Instruction Residuals)	39
2.1.3	O Domínio de Arquiteturas Encoder vs. a Lacuna de Decoders	41
2.1.4	LLMs Genéricos vs. LLMs de Nicho: O Posicionamento do Gaia	42
2.1.4.1	O Paradigma Genérico e suas Limitações em PT-BR	43
2.1.4.2	A Emergência do LLM de Nicho	44
2.1.4.3	Posicionamento do Projeto Gaia	44
2.2	O Eixo Metodológico: Da DSR ao eDSR	45
2.2.1	Do DSR clássico à necessidade de gerenciar a complexidade em IA	47
2.2.2	O framework eDSR (Pilar 1): echelons, artefatos intermediários e validação	48
2.2.3	Justificando o eDSR para análise de projetos de IA	51
2.2.3.0.1	Rastreabilidade em contextos multistakeholder.	51
2.2.3.0.2	Visibilidade de mitigação de risco e eficiência técnica.	52
2.2.3.0.3	Alinhamento com o estado da arte em IA aplicada.	52

3	DESIGN DA PESQUISA (RESEARCH DESIGN)	53
3.0.1	Adoção do framework eDSR como processo de pesquisa	53
3.0.2	Rastreando a Complexidade Técnica (CPT + Instruction Residuals)	55
3.0.3	Acoplamento com o FEDS para Validação Formativa e Somativa	55
3.1	Procedimento de Derivação dos Princípios de Design (DPs)	57
3.2	Tabela Mestra: Mapeamento do Projeto como Plano de Pesquisa	60
3.2.1	Funções da Tabela Mestra	60
3.2.2	Estrutura e Componentes	60
3.2.3	Procedimento de Uso e Governança	62
3.3	Fontes e Métodos: A Estratégia de Triangulação	63
3.3.1	Camada 1 — Literatura acadêmica (“Pilares”)	64
3.3.2	Camada 2 — Documentação pública do caso (Gaia)	64
3.3.3	Camada 3 — Entrevistas semiestruturadas (stakeholders)	65
3.3.4	Encadeamento analítico e rastreabilidade	65
3.3.5	Mitigação de vieses e governança dos dados	66
4	VISÃO GERAL DO MÉTODO DE ANÁLISE	67
4.1	Echelon 1: Diagnóstico do Problema	67
4.1.1	O Problema Técnico: A Lacuna de Geração em PT-BR	68
4.1.2	O Gatilho de Negócio: Um Alinhamento Sociotécnico	68
4.1.3	Artefato Gerado: Declaração do Problema Validada	68
4.2	Echelon 2: Objetivos e Requisitos	68
4.2.1	Prioridades Inflexíveis: O Imperativo da Eficácia	69
4.2.2	Parâmetros Ajustáveis: A Flexibilização da Eficiência	70
4.2.3	Conclusão do Echelon	71
4.3	Echelon 3 — Design e Desenvolvimento	71
4.3.1	Racionalidade do pipeline CPT→IR (o “porquê” e a “ordem”)	71
4.3.2	Arquitetura de base: seleção e racionalidade técnica (E2→E3)	71
4.3.2.1	Processo de seleção do backbone (E2→E3)	73
4.3.2.2	Gemma: características arquiteturais relevantes para CPT→IR	74
4.3.2.3	Alternativas descartadas e <i>trade-offs</i> conscientes	75
4.3.3	Dados e curadoria (do Jabuticaba ao subset ~13B)	76
4.3.4	Principais DDRs de E3 (registro mínimo e critérios)	76
4.3.5	Encadeamento com E4 (FEDS) — episódios formativos	76
4.3.6	Candidatos a Princípios de Design (DPs) a partir de E3	77
4.4	Echelon 4 — Demonstração (Prova de Conceito, PoC)	77
4.4.1	PoC formativo (fase exploratória em Qwen)	78
4.4.2	PoC somativo (benchmark ENEM no Gaia final)	78
4.4.3	Consolidação de E4 e ponte para E5	78
4.5	Echelon 5 — Avaliação (Prova de Valor, PoV)	79

4.5.1	Escopo de PoV para o Gaia	79
4.5.2	PoV confirmado — P&D e Ecossistema	79
4.5.3	PoV parcial — Adoção organizacional e feedback loop	80
4.5.4	Implicações para a tese (ponte a Cap. 5)	81

5 CONCLUSÕES E CONTRIBUIÇÕES 83

5.1 Teoria de médio alcance 83

5.2 Princípios de Design (DPs) 85

5.2.1 DP1 — Especialização linguística com preservação instrucional (CPT→IR) 85

5.2.2 DP2 — Curadoria por qualidade (subset nacional guiado por estabilidade/ruído) 87

5.2.3 DP3 — Avaliação dual FEDS (formativa/artificial → somativa/naturalística) 89

5.2.4 DP4 — Família de tamanhos alinhada ao contexto de adoção 90

5.2.5 DP5 — Rastreabilidade de decisões (DDRs) acoplada a echelons 93

5.3 Implicações 94

5.4 Validade e limitações 95

REFERÊNCIAS 97

APÊNDICES 101

APÊNDICE A – PROPOSIÇÕES TESTÁVEIS E MODELO DE MATURIDADE EDSR 103

APÊNDICE B – ARTEFATOS COMPUTÁVEIS 107

1 Introdução

Modelos de Linguagem de Grande Porte (LLMs) consolidaram-se como o principal artefato técnico da atual fase da inteligência artificial generativa, sustentando uma gama crescente de aplicações de compreensão e geração de texto em larga escala (PAVA; AL., 2025). Entretanto, a literatura recente demonstra que esse avanço é distribuído de maneira profundamente desigual entre as línguas (CRUZ-CASTAÑEDA; AMADEUS, 2025). A maioria dos modelos de maior desempenho é pré-treinada predominantemente em inglês — e, em menor grau, em algumas poucas línguas consideradas globais — o que cria um viés estrutural de cobertura. Mesmo iniciativas multilingues de grande escala, como o BLOOM/ROOTS, revelam uma predominância de línguas de alto recurso (HRLs) e limites práticos significativos de curadoria (SCAO et al., 2023; HUANG; MO; ZHANG, 2024).

Essa assimetria no pré-treinamento, favorável às HRLs, resulta em quedas sistemáticas de desempenho quando essas arquiteturas são aplicadas a línguas menos representadas nos corpora originais (ADELANI; AL., 2024; COSTA-JUSSÀ et al., 2022). O problema se torna ainda mais evidente em tarefas generativas (NLG), que dependem não apenas de estatísticas linguísticas, mas também de adequação cultural, discursiva e de registro (CRUZ-CASTAÑEDA; AMADEUS, 2025). Estudos recentes em línguas de baixa disponibilidade de dados — como o letão — mostram que modelos de referência amplamente adotados (LLaMA, Qwen, Gemma, Mistral) mantêm alta qualidade em inglês, mas produzem saídas menos coerentes e menos aderentes ao contexto cultural local quando aplicados à língua-alvo (DARĞIS; AL., 2024).

É nesse cenário que se insere esta pesquisa, posicionada na intersecção de dois desafios estruturais que comprometem simultaneamente o desempenho e a capacidade de aprendizado coletivo no desenvolvimento de LLMs em Português Brasileiro (PT-BR). Essa intersecção forma uma **dupla lacuna de pesquisa**:

1. **Lacuna Técnica de Domínio:** Mesmo com corpora massivos e limpos disponíveis — como o Jabuticaba, com mais de 139 bilhões de tokens — persiste um atraso estrutural em arquiteturas *decoder-only* especializadas para geração em PT-BR (SCOTTI; CRUZ-CASTAÑEDA; AMADEUS, 2025). A insuficiência de modelos otimizados para NLG resulta em quedas sistemáticas de qualidade linguística, fluência e controle de registro.
2. **Lacuna de Processo Metodológico:** O processo de design de IA permanece amplamente invisível. A maior parte dos trabalhos reporta o artefato final (modelo, métricas, rankings), mas quase nunca documenta o *como* e o *porquê* das decisões de design (TUUNANEN; GHANBARI; KAZAN, 2024; HEVNER et al., 2004; VENABLE; PRIES-HEJE; BASKERVILLE, 2016). Esse “silenciamento” metodológico

dificulta a transferência de conhecimento e impede a formulação de princípios de design reutilizáveis.

Para enfrentar rigorosamente essa dupla lacuna, esta tese utiliza o paradigma da *Design Science Research* (DSR), orientado à geração de conhecimento por meio da construção e avaliação de artefatos inovadores (TUUNANEN; GHANBARI; KAZAN, 2024). O objeto empírico deste estudo é o **Projeto Gaia** — um LLM de nicho especializado em PT-BR — analisado sob a lente do *Echeloned Design Science Research* (eDSR), uma extensão metodológica concebida para lidar com projetos digitais complexos e não lineares.

O eDSR opera como uma estrutura organizadora que decompõe o processo em cinco echelons (E1–E5), permitindo que cada decisão relevante — como a adoção de *Instruction Residuals* para mitigar o esquecimento catastrófico decorrente do *Continuous Pre-Training* (CPT) — seja associada a um artefato intermediário validado (JINDAL; AL., 2024). Assim, o que tradicionalmente aparece como um bloco compacto de engenharia passa a ser reconstituído como uma cadeia rastreável de decisões sociotécnicas.

O objetivo central desta tese é formular uma **teoria de médio alcance** (*mid-range design theory*) que abstraia o *know-how* prático do Projeto Gaia e o transforme em Princípios de Design (DPs) generalizáveis, úteis para orientar a criação de futuros LLMs de nicho em línguas caracterizadas por representação assimétrica.

1.1 Contextualização: a era dos LLMs e a lacuna de representação (o viés do inglês)

Modelos de Linguagem de Grande Porte (LLMs) tornaram-se, ao longo da última década, o eixo central da inteligência artificial generativa, possibilitando avanços substanciais em tarefas de compreensão e geração de linguagem natural em larga escala (BOMMASANI et al., 2021; KADDOUR et al., 2023; ZHANG et al., 2022). Esse salto tecnológico, entretanto, não ocorreu de maneira equitativa entre as línguas. A literatura recente aponta que o progresso obtido pelos LLMs é profundamente assimétrico, beneficiando de forma desproporcional as línguas amplamente representadas nos conjuntos de pré-treinamento (LIN et al., 2022).

Essa concentração deriva de uma característica estrutural: a maioria dos modelos de maior desempenho — inclusive arquiteturas amplamente difundidas como LLaMA, Qwen, Mistral, Gemma e GPT — é pré-treinada predominantemente em inglês e em poucas outras línguas de alta disponibilidade de dados. Mesmo iniciativas multilingues abertas de grande escala, como BLOOM/ROOTS, revelam que, apesar do esforço de inclusão, ainda há clara predominância de HRLs (Línguas de Alto Recurso), com limitações culturais e

linguísticas significativas para as demais (CRUZ-CASTAÑEDA; AMADEUS, 2025; SCAO et al., 2023; HUANG; MO; ZHANG, 2024).

Esse viés de pré-treinamento gera consequências diretas sobre a capacidade de generalização translinguística dos modelos. Como demonstram diversos estudos, arquiteturas treinadas majoritariamente em HRLs sofrem quedas sistemáticas de desempenho quando aplicadas a idiomas menos representados nos corpora originais (HUANG; MO; ZHANG, 2025). A queda é particularmente pronunciada em tarefas generativas (*Natural Language Generation* — NLG), que requerem, além de conhecimento linguístico estatístico, a incorporação de nuances discursivas, pragmáticas e culturais (CRUZ-CASTAÑEDA; AMADEUS, 2025).

Evidências empíricas recentes corroboram essa assimetria: experimentos conduzidos em línguas de menor disponibilidade de dados, como o letão, mostram que LLMs de referência mantêm alto desempenho quando operam em inglês, mas produzem saídas substancialmente menos coerentes, menos fluentes e menos sensíveis ao contexto quando aplicados à língua-alvo (DARĞIS; AL., 2024). Esses resultados sugerem que o problema não é apenas quantitativo (ausência de dados), mas também qualitativo: o processo de pré-treinamento global não consegue, por si só, incorporar adequadamente as especificidades culturais e estruturais de idiomas menos privilegiados.

Dessa forma, a lacuna de representação se manifesta como um fenômeno estrutural: quanto menor a proporção de uma língua no pré-treinamento, maior a probabilidade de degradação na performance generativa, mesmo em modelos considerados “multilíngues” no sentido amplo. Essa constatação é particularmente relevante no contexto brasileiro, onde coexistem uma língua de alto recurso (PT-BR) e um conjunto amplo de línguas indígenas classificadas como LRLs (Línguas de Baixo Recurso).

1.1.1 A Lacuna de Representação no Contexto Brasileiro

No Brasil, a problemática da representação linguística assume contornos particularmente complexos. O país constitui um ambiente genuinamente multilíngue: ao lado do Português Brasileiro (PT-BR) — classificado como Língua de Alto Recurso (HRL) devido à sua ampla disponibilidade de dados — coexistem aproximadamente 160 línguas indígenas, muitas delas severamente ameaçadas, e classificadas como Línguas de Baixo Recurso (LRLs) (ADELANI et al., 2025). Essa heterogeneidade linguística intensifica o desafio de garantir equidade no desempenho dos modelos de linguagem.

A disparidade de performance entre HRLs e LRLs é marcante. Enquanto o PT-BR, quando suficientemente representado em corpora curados, pode alcançar níveis de precisão superiores a 90% em tarefas como *Part-of-Speech* (POS) tagging, línguas indígenas avaliadas apresentam, em alguns casos, desempenho inferior a 34% — não por insuficiência intrínseca

das línguas, mas pela sub-representação nos dados de pré-treinamento (ADELANI et al., 2025). Trata-se, portanto, de uma lacuna de representação multidimensional, envolvendo aspectos sociopolíticos, culturais, técnicos e infraestruturais.

O Português Brasileiro ocupa, nesse ecossistema, uma posição paradoxal. Por um lado, o país dispõe hoje de um dos maiores e mais limpos corpora de pré-treinamento monolíngue de língua não inglesa já construídos: o corpus Jabuticaba, com mais de 139 bilhões de tokens, deduplicado e submetido a curadoria sistemática (SCOTTI; CRUZ-CASTAÑEDA; AMADEUS, 2025). Esse avanço evidencia que o gargalo de dados brutos — historicamente apontado como o principal obstáculo para modelos em PT-BR — foi substancialmente mitigado.

Por outro lado, e apesar dessa abundância de dados, persiste um **atraso generativo** no ecossistema de IA brasileiro. Estudos comparativos mostram que os modelos multilíngues mais difundidos continuam apresentando desempenho inferior em tarefas de NLG no PT-BR, quando comparados ao inglês ou a outras HRLs (ASSIS; FREITAS; PAES, 2025). As causas dessa assimetria são estruturais: o ecossistema nacional avançou mais rapidamente em modelos voltados à compreensão (arquiteturas *encoder-only*) do que em modelos orientados à geração (*decoder-only*) (CRUZ-CASTAÑEDA; AMADEUS, 2025). Modelos encoder, embora úteis para classificação e outras tarefas discriminativas, não foram concebidos para geração livre de texto, apresentando limitações importantes em fluência discursiva, progressão temática, adequação de registro e consistência argumentativa (ASSIS; FREITAS; PAES, 2025).

Esses fatores convergem para um cenário no qual a insuficiência generativa em PT-BR deixa de ser apenas um problema acadêmico e passa a afetar diretamente aplicações práticas: sumarização, redação assistida, simplificação, geração de respostas contextualizadas, produção de conteúdo jurídico e administrativo, entre outras. Avaliações recentes da “fauna” de modelos brasileiros mostram que, embora alguns LLMs nacionais sejam competitivos em tarefas discriminativas, modelos fechados de referência ainda superam largamente as alternativas disponíveis em tarefas generativas. Isso sugere que o gargalo atual não está na quantidade de dados, mas na ausência de arquiteturas de nicho explicitamente desenhadas para mitigar o déficit generativo em PT-BR (ASSIS; FREITAS; PAES, 2025).

Assim, a lacuna de representação no Brasil manifesta-se duplamente: (i) na assimetria histórica entre PT-BR e línguas indígenas; e (ii) na escassez de modelos generativos especializados para PT-BR, mesmo frente a grandes corpora. Essa dupla lacuna motiva diretamente o Projeto Gaia e justifica a necessidade de reconstruir e explicitar seu processo de design, de modo a informar futuras iniciativas de desenvolvimento de LLMs para línguas sub-representadas.

1.2 O problema de pesquisa

O avanço global dos Modelos de Linguagem de Grande Porte (LLMs) confronta, de forma simultânea, dois desafios estruturais intimamente ligados. O primeiro é uma **lacuna técnica**: a assimetria de desempenho entre línguas que se encontram no centro do pré-treinamento global e aquelas que permanecem periferizadas em termos de dados e curadoria. O segundo é uma **lacuna metodológica**: a invisibilidade do processo de design que conduz à construção desses artefatos, frequentemente reduzido a poucas linhas em seções de “implementação” (TUUNANEN; GHANBARI; KAZAN, 2024).

A combinação dessas duas lacunas compromete, de um lado, a *utilidade local* dos LLMs em contextos linguísticos específicos — como o Português Brasileiro (PT-BR) — e, de outro, a *acumulação de conhecimento de design reutilizável*, uma vez que as decisões que levaram aos resultados não são devidamente explicitadas (GREGOR; HEVNER, 2013). Em termos de *Design Science*, isso significa que a comunidade dispõe de muitos artefatos finais, mas de poucos princípios de design formalizados e testáveis. A presente tese toma essa dupla lacuna como ponto de partida para formular seu problema de pesquisa.

1.2.1 O problema técnico: a escassez de LLMs de nicho para o português brasileiro

O primeiro componente do problema é de natureza técnica e se manifesta como uma **lacuna de domínio** em PT-BR. A literatura recente demonstra que a performance de LLMs *State-of-the-Art* (SOTA), pré-treinados majoritariamente em inglês, sofre uma queda persistente e particularmente visível em tarefas generativas (*Natural Language Generation* — NLG) quando aplicada a idiomas menos representados, como o Português Brasileiro (CRUZ-CASTAÑEDA; AMADEUS, 2025). Essa insuficiência generativa configura, em essência, um problema de representação linguística (ADELANI; AL., 2024).

Estudos comparativos em Línguas de Baixo Recurso (LRLs), como o letão, ilustram esse fenômeno de forma clara: modelos abertos de referência (famílias LLaMA, Qwen, Gemma, Mistral) mantêm elevada qualidade quando operam em inglês, mas exibem falhas consistentes nas tarefas de NLG na língua-alvo, produzindo saídas menos coerentes, menos fluentes e muitas vezes inadequadas ao contexto local (DARĞIS; AL., 2024).

Quando se desloca o foco das HRLs para línguas menos privilegiadas, a queda de desempenho torna-se sistemática. Mesmo em pipelines de tradução humano-centrados e em larga escala, como o *No Language Left Behind* (NLLB), observam-se limites práticos de cobertura e qualidade fora do núcleo das HRLs (COSTA-JUSSÀ et al., 2022). No contexto brasileiro, avaliações envolvendo línguas indígenas reforçam esse quadro, revelando degradações significativas e a necessidade de curadoria e adaptação local para recuperar parte do desempenho (ADELANI; AL., 2024).

Esse conjunto de evidências aponta para uma conclusão robusta: o pré-treinamento global, ainda que massivo e tecnicamente sofisticado, não é suficiente para incorporar, de forma robusta, as nuances linguísticas, culturais e pragmáticas necessárias para uma geração fluente e contextualizada em PT-BR (CRUZ-CASTAÑEDA; AMADEUS, 2025). Em outras palavras, o déficit não é apenas quantitativo (quantidade de dados), mas qualitativo (modo de incorporação e especialização). Essa assimetria confirma a demanda empírica que esta tese busca enfrentar: a necessidade de LLMs de nicho, explicitamente desenhados para mitigar o déficit generativo em Português Brasileiro, e de compreender *como* esses modelos podem ser projetados de forma sistemática (GREGOR; HEVNER, 2013).

1.2.2 O problema metodológico: a “caixa preta” do processo de design de IA

O segundo componente do problema de pesquisa é de natureza metodológica e se configura como uma **lacuna de processo** (TUUNANEN; GHANBARI; KAZAN, 2024; SEIN et al., 2011; HEVNER et al., 2004; VENABLE; PRIES-HEJE; BASKERVILLE, 2016). A maior parte das publicações em aprendizado de máquina — e, em especial, em LLMs — descreve o artefato final (arquitetura, tamanho do modelo, métricas em benchmarks padronizados) e o ranking alcançado em *leaderboards*, mas oferece pouca ou nenhuma evidência sobre quais decisões de design explicam os ganhos empíricos obtidos.

Aspectos cruciais, como ablações, sensibilidade a hiperparâmetros, escolhas de dados, estratégias de mitigação de risco e critérios práticos de engenharia, são muitas vezes apenas mencionados, quando não omitidos por completo. Lipton e Steinhart qualificam essa prática como “*failure to identify the sources of empirical gains*”, associada a fenômenos como *leaderboard chasing* e *mathiness* — trabalhos que valorizam métricas e formalismo matemático em detrimento da clareza sobre o processo de construção (LIPTON; STEINHARDT, 2018).

Esse déficit de rastreabilidade justifica o recurso a métodos de *Design Science* — em particular ao eDSR — que enfatizam a documentação de artefatos intermediários e tornam observável a ordem das decisões e suas respectivas avaliações (HEVNER et al., 2004; SEIN et al., 2011; TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016). A ênfase exclusiva no artefato final (modelo, métricas, posição em leaderboard) produz um *silenciamento* do *como* e do *porquê* das decisões de design, comprometendo a reprodutibilidade, a auditabilidade e a acumulação cumulativa de conhecimento.

Foi precisamente para tornar visível esse percurso sociotécnico que a *Design Science Research* (DSR) foi formulada (HEVNER et al., 2004) e posteriormente estendida ao *Echelon Design Science Research* (eDSR) para projetos digitais complexos e não lineares (SEIN et al., 2011; TUUNANEN; GHANBARI; KAZAN, 2024). O eDSR decompõe o

projeto em *echelons* (unidades de trabalho encadeadas), explicita os artefatos intermediários e estabelece, para cada decisão, uma trilha de validação rastreável.

Em projetos de IA complexos e multi-organizacionais, nos quais as decisões são não lineares e envolvem *trade-offs* entre custo computacional, eficiência, segurança e mitigação de risco — como a escolha de *Instruction Residuals* (IR) para contornar o risco de esquecimento catastrófico após o *Continuous Pre-Training* (CPT) (JINDAL; AL., 2024) —, essa invisibilidade do processo torna-se um obstáculo crítico. Ela impede a transferência de conhecimento entre equipes, dificulta a identificação de padrões recorrentes de decisão e, sobretudo, inviabiliza a formulação de Princípios de Design reutilizáveis (LIPTON; STEINHARDT, 2018).

Para superar o silenciamento do processo de design, esta tese recorre à DSR e, em particular, ao eDSR como framework de análise. O eDSR foi desenvolvido justamente para lidar com projetos digitais complexos e não lineares (TUUNANEN; GHANBARI; KAZAN, 2024; SEIN et al., 2011; HEVNER et al., 2004; VENABLE; PRIES-HEJE; BASKERVILLE, 2016). Ele decompõe o projeto em cinco *echelons* (E1–E5) e associa a cada um um artefato intermediário validado (por exemplo, declaração de problema, requisitos de design, *blueprints* técnicos, Prova de Conceito — PoC, Prova de Valor — PoV).

A metodologia eDSR, aplicada ao caso Gaia, cumpre, portanto, duas funções centrais:

1. **Tornar visíveis as decisões modulares:** Permite registrar que o uso de IR, por exemplo, foi uma decisão de mitigação de risco tomada no Echelon 3 (Design & Desenvolvimento), e não apenas um detalhe técnico de implementação (JINDAL; AL., 2024).
2. **Garantir rastreabilidade:** Estabelece pontos de ancoragem (artefatos) para cada decisão, facilitando tanto a análise retrospectiva quanto a posterior derivação de Princípios de Design (DPs) generalizáveis (TUUNANEN; GHANBARI; KAZAN, 2024; SEIN et al., 2011; HEVNER et al., 2004; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Problema de Pesquisa Central

Diante da **lacuna técnica** (insuficiência de LLMs generativos robustos para PT-BR) e da **lacuna metodológica** (ausência de documentação estruturada do processo de design), a questão de pesquisa que orienta esta tese — e que será investigada tomando o Projeto Gaia como estudo de caso — é formulada da seguinte forma:

Como o framework metodológico eDSR pode ser empregado para analisar o processo de design (Echelons 1–5) do Projeto Gaia e, a partir dessa análise, derivar Princípios de Design (DPs) generalizáveis para a criação de futuros LLMs de nicho em Português Brasileiro?

O objetivo desta pesquisa é, assim, duplo: (a) utilizar um caso empírico relevante — o Projeto Gaia — para enfrentar, de maneira concreta, o déficit de LLMs generativos em PT-BR; e (b) empregar o eDSR como lente metodológica para tornar visível o processo de construção desse artefato complexo, transformando o *know-how* do caso em conhecimento teórico de médio alcance (*mid-range design theory*) sob a forma de Princípios de Design (TUUNANEN; GHANBARI; KAZAN, 2024; GREGOR; HEVNER, 2013).

1.3 Objetivo Geral e Objetivos Específicos

A pesquisa em *Design Science Research* (DSR) orienta-se pelo princípio da utilidade: desenvolver artefatos capazes de resolver problemas reais ao mesmo tempo em que gera conhecimento de design rigoroso, explícito e reutilizável pela comunidade científica e profissional (HEVNER et al., 2004; MARCH; SMITH, 1995; GREGOR; HEVNER, 2013). No contexto desta tese, a dupla lacuna identificada — a **lacuna técnica** (escassez de LLMs generativos especializados em PT-BR) e a **lacuna metodológica** (invisibilidade do processo de design em IA) — demanda uma investigação que seja simultaneamente empírica e teórico-metodológica (CRUZ-CASTAÑEDA; AMADEUS, 2025; LIPTON; STEINHARDT, 2018).

Assim, os objetivos deste trabalho estão ancorados em um duplo compromisso: (i) enfrentar um problema concreto no domínio da IA generativa para o português brasileiro; e (ii) transformar o processo de construção do Projeto Gaia em conhecimento formalizável, no formato de Princípios de Design (DPs) e teoria de médio alcance.

1.3.1 Objetivo Geral

O objetivo geral desta tese é **gerar uma teoria de médio alcance (*mid-range design theory*) sobre o design de LLMs de nicho em Português Brasileiro**, utilizando o framework metodológico *Echeloned Design Science Research* (eDSR) (TUUNANEN; GHANBARI; KAZAN, 2024) para reconstituir, analisar e tornar visível o processo sociotécnico que guiou o desenvolvimento do Projeto Gaia.

1.3.2 Objetivos Específicos

Para operacionalizar o objetivo geral, a pesquisa se desdobra em quatro objetivos específicos, alinhados às etapas de abstração, reflexão e formalização próprias da DSR:

1. **Mapear o Processo de Design:** Reconstituir o processo de design do Projeto Gaia ao longo dos cinco *echelons* do eDSR (Diagnóstico do Problema, Objetivos e Requisitos, Design e Desenvolvimento, Demonstração, Avaliação). Esse mapeamento deve explicitar os artefatos intermediários gerados em cada fase — como a declaração do problema, requisitos de design, *blueprints* técnicos e evidências de avaliação — e identificar as lacunas de evidência que exigem coleta adicional (TUUNANEN; GHANBARI; KAZAN, 2024; SEIN et al., 2011; HEVNER et al., 2004; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).
2. **Derivar Princípios de Design (DPs):** Extrair, consolidar e validar um conjunto de Princípios de Design (DPs) prescritivos, ancorados nas decisões críticas efetivamente tomadas durante o desenvolvimento do Gaia. Os DPs expressam mecanismos, condições e justificativas que podem orientar futuros projetos de LLMs de nicho (TUUNANEN; GHANBARI; KAZAN, 2024).
3. **Elaborar a Teoria de Médio Alcance:** Formular uma teoria de design de médio alcance que articule os DPs derivados do caso Gaia e os conecte a uma classe mais ampla de projetos de LLMs especializados em línguas com representação assimétrica. Essa teoria deve seguir a estrutura proposta por Gregor & Hevner (GREGOR; HEVNER, 2013), formalizando metas, mecanismos, justificativas, condições de aplicação e limites de validade.
4. **Propor um Template Metodológico:** Propor um modelo de aplicação (template) do eDSR para projetos de IA generativa complexos e multistakeholder. Esse template evidenciará como o eDSR pode ser acoplado ao *Framework for Evaluation in Design Science* (FEDS), permitindo diferenciar Provas de Conceito (PoC) formativas e Provas de Valor (PoV) somativas, aumentando o rigor e a rastreabilidade em contextos de design não lineares e sociotécnicos (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

1.4 Justificativa Acadêmica e Prática

A relevância desta tese reside na capacidade de conectar um problema empírico concreto, situado no domínio da Inteligência Artificial Generativa (IA GenAI), com o rigor teórico-metodológico da *Design Science Research* (DSR). A DSR, conforme formulada na literatura clássica, busca simultaneamente a utilidade para a prática e a verdade para a teoria: artefatos devem resolver problemas relevantes e, ao mesmo tempo, gerar conhecimento de design explicitável, comunicável e reutilizável (HEVNER et al., 2004; GREGOR; HEVNER, 2013).

Este trabalho se justifica, portanto, ao atacar de forma integrada a dupla lacuna identificada no Capítulo 1: (i) a **lacuna técnica** em LLMs generativos para PT-BR; e (ii) a **lacuna metodológica** no relato do processo de design de projetos de IA complexa (CRUZ-CASTAÑEDA; AMADEUS, 2025; LIPTON; STEINHARDT, 2018). A seguir, detalham-se as justificativas acadêmica e prática.

1.4.1 Justificativa Acadêmica: Transformação do *Know-How* em Teoria de Design

No plano acadêmico, esta pesquisa se justifica pela necessidade de elevar o rigor metodológico na documentação de projetos de IA generativa, respondendo a uma lacuna de processo que compromete a acumulação sistemática de conhecimento.

1. **Enfrentamento à “Caixa Preta” da IA (Lacuna Metodológica):** A maior parte dos trabalhos em LLMs concentra-se em relatar o artefato final — modelo, arquitetura, métricas em benchmarks — dedicando pouquíssimo espaço à documentação do processo de concepção e das decisões de *trade-off*. Essa prática, frequentemente associada ao *leaderboard chasing*, privilegia o “trabalho de resultado” em detrimento da reprodutibilidade e da transparência, gerando uma invisibilidade do design (LIPTON; STEINHARDT, 2018). A adoção do eDSR nesta tese é uma resposta explícita a esse problema: tornar o processo de design um objeto de análise em si, e não apenas um pano de fundo para o artefato final.
2. **Contribuição Metodológica em Domínio de Fronteira:** A tese aplica o framework eDSR — concebido para projetos digitais complexos e não lineares — ao domínio de fronteira da IA generativa (TUUNANEN; GHANBARI; KAZAN, 2024). Ao mapear o Projeto Gaia *echelon* por *echelon*, este trabalho demonstra a adequação do eDSR para artefatos multistakeholder e tecnicamente modulados por riscos (por exemplo, riscos de esquecimento catastrófico, alocação de capacidade computacional, seleção de dados). Trata-se de um campo emergente no qual o eDSR começa a ser adotado em áreas como automação inteligente e gêmeos digitais, mas ainda é pouco explorado na modelagem de LLMs.
3. **Geração de Conhecimento Abstrato (Rigor Teórico):** O objetivo central da pesquisa em DSR é a geração de conhecimento de design generalizável. Ao reconstituir o processo do Gaia e formalizar os achados sob a forma de Princípios de Design (DPs), esta tese transforma o *know-how* prático do caso em teoria de médio alcance (*mid-range design theory*), seguindo os requisitos de Gregor & Hevner (GREGOR; HEVNER, 2013). Os DPs resultantes (Capítulo 5) funcionarão como proposições testáveis (por exemplo, ISDT/DREPT), passíveis de refinamento e reutilização por outras equipes envolvidas em projetos de LLMs de nicho.

4. **Estruturação da Avaliação:** O acoplamento do eDSR com o *Framework for Evaluation in Design Science* (FEDS) permite diferenciar explicitamente a *Prova de Conceito* (PoC) — focada na eficácia técnica em ambiente artificial/formativo (por exemplo, benchmarks internos) — da *Prova de Valor* (PoV) — focada em utilidade, adoção e adequação em ambiente naturalístico/somativo (VENABLE; PRIES-HEJE; BASKERVILLE, 2016). Essa distinção reforça o rigor da avaliação processual, permitindo que cada decisão de design seja interpretada à luz do tipo de evidência disponível e das condições de uso do artefato.

1.4.2 Justificativa Prática: Otimização de Design e Mitigação de Riscos em PT-BR

No plano prático, a pesquisa se justifica pela necessidade de responder à lacuna técnica de domínio e de fornecer recursos reutilizáveis para a comunidade de IA no Brasil, especialmente em projetos que envolvam LLMs especializados em PT-BR.

1. **Enfrentando o Déficit Generativo em PT-BR (Lacuna Técnica):** A pesquisa aborda a persistente assimetria de desempenho dos LLMs globais em tarefas generativas em Português Brasileiro. Embora a lacuna de dados brutos tenha sido amplamente mitigada pela existência de corpora massivos e curados, como o Jaticaba (mais de 139 bilhões de tokens), o atraso reside na escassez de modelos *decoder-only* especializados para geração em PT-BR (SCOTTI; CRUZ-CASTAÑEDA; AMADEUS, 2025). O Projeto Gaia é uma resposta concreta a essa lacuna, e a análise de seu processo de design pode informar futuras iniciativas análogas.
2. **Redução de Risco e Custo (Utility):** Uma contribuição prática central é fornecer um “template” — composto pelos DPs e pelo template metodológico — que permita a outras organizações reduzir incertezas, otimizar recursos e mitigar riscos na construção de LLMs de nicho. Ao tornar explícitas as decisões críticas registradas no eDSR (por exemplo, a adoção de CPT + IR como estratégia de especialização com mitigação de esquecimento catastrófico), a documentação produzida pela tese pode orientar escolhas de arquitetura, dados e avaliação em novos projetos, gerando ganhos de eficiência computacional e de governança de risco.
3. **Avaliação da Utilidade em Contexto:** A aplicação do FEDS garante que a avaliação do Gaia não se limite a métricas técnicas, mas inclua a análise de utilidade em uso (PoV). Ao rastrear o feedback de stakeholders reais (por exemplo, órgãos públicos parceiros), a pesquisa assegura que o conhecimento gerado seja relevante para a comunidade e para os atores diretamente envolvidos no ecossistema do Projeto Gaia, cumprindo o requisito de relevância prática da DSR (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

1.5 Delimitações do Estudo

As delimitações deste estudo abrangem tanto o domínio empírico (o Projeto Gaia) quanto o domínio metodológico (a lente eDSR e a natureza do conhecimento gerado). Elas definem, de forma explícita, as fronteiras da pesquisa, isto é, o que se pretende e o que não se pretende cobrir.

1.5.1 Delimitação do Escopo Empírico (O Projeto Gaia)

O foco empírico da tese é estritamente limitado ao Projeto Gaia e à sua especialização em Português Brasileiro (PT-BR). As principais decisões de escopo empírico são:

1. **Foco Linguístico:** Embora o problema de pesquisa seja ancorado na assimetria linguística global e na disparidade estrutural que afeta tanto Línguas de Alto Recurso (HRLs), como o PT-BR, quanto Línguas de Baixo Recurso (LRLs), o estudo de caso concentra-se exclusivamente no PT-BR. As conclusões e os Princípios de Design (DPs) derivados serão propostos como potencialmente generalizáveis para LLMs de nicho em outras línguas sub-representadas, mas sua validade empírica direta permanece restrita ao contexto brasileiro.
2. **Foco no Design Generativo (*Decoder-Only*):** A tese concentra-se em LLMs voltados para tarefas generativas (*Natural Language Generation* — NLG), como sumarização, simplificação e *Question Answering* (QA) em contexto fechado. Ficam fora do escopo análises detalhadas de modelos puramente *encoder-only* e de tarefas predominantemente discriminativas (por exemplo, classificação de sentimento ou NER), para as quais já existem modelos robustos no ecossistema PT-BR. O foco é mitigar a lacuna de arquiteturas *decoder-only* voltadas à geração em português brasileiro.
3. **Fonte de Dados:** A análise do design do Gaia está delimitada aos dados utilizados no *Continuous Pre-Training* (CPT), que consistem em um subconjunto curado de aproximadamente 13 bilhões de tokens do corpus Jabuticaba. Reconhece-se que o Jabuticaba, embora massivo e deduplicado, apresenta limitações, como a sub-representação de determinadas variedades regionais, registros de fala informal e gêneros textuais específicos.
4. **Avaliação:** A avaliação do artefato (Projeto Gaia) é restrita à reconstituição e análise dos episódios de validação já conduzidos pela equipe do consórcio, interpretados à luz do *Framework for Evaluation in Design Science* (FEDS). A tese não realiza novos treinamentos, *fine-tunings* ou experimentos técnicos (como novas rodadas de benchmarking). O foco recai sobre o processo de avaliação (PoC/PoV) e suas implicações de design, e não sobre a geração de novos dados de desempenho.

1.5.2 Delimitação do Escopo Metodológico (eDSR e Teoria)

A delimitação metodológica define a natureza do conhecimento que esta pesquisa pretende gerar, distinguindo-a de outros paradigmas acadêmicos (por exemplo, estudos puramente experimentais, pesquisas preditivas de uso ou surveys de larga escala).

1. **Foco no Processo de Design:** O objetivo primário não é avaliar o desempenho final do Projeto Gaia em termos de métricas de acurácia, mas tornar visível e auditável o processo sociotécnico que levou à sua concepção. A tese concentra-se na documentação e análise dos artefatos intermediários gerados em cada *echelon* (E1 a E5), conforme organizado pelo eDSR.
2. **Natureza da Contribuição Teórica:** A pesquisa visa à geração de uma teoria de médio alcance (*mid-range design theory*) sobre o design de LLMs de nicho, expressa por meio de Princípios de Design (DPs). Trata-se de uma teoria prescritiva (Tipo V, orientada a design e ação), e não de uma teoria explanatória ou preditiva voltada a comportamentos de usuários ou adoção organizacional.
3. **Dependência de Dados Primários:** A capacidade de derivar DPs robustos e generalizáveis está intrinsecamente ligada ao sucesso na coleta de dados primários (especialmente entrevistas semiestruturadas com stakeholders). Esses dados são cruciais para revelar o “porquê” e a “ordem” das decisões de design. Caso essa coleta seja inviável ou incompleta, a tese ficará limitada à reconstituição documental do Projeto Gaia, e a derivação de DPs será mais dependente de inferências do pesquisador, com enfraquecimento correspondente da densidade empírica e da força causal das proposições.
4. **Âncora Metodológica:** O framework eDSR é utilizado como lente de análise e guia de condução da própria pesquisa. Não se busca aplicar, de forma sistemática, metodologias de desenvolvimento ágil ou modelos sequenciais puros; o foco está em mapear a complexidade não linear das decisões do Projeto Gaia a partir da lógica de *echelons*, respeitando a natureza retrospectivo-analítica do estudo.

Em síntese, a tese é delimitada como um exercício de *Design Science Research* retrospectivo-analítico, que utiliza o Projeto Gaia como lente para extrair conhecimento sobre o processo de design e para formular contribuições teóricas e metodológicas. Não se trata de uma pesquisa de desenvolvimento de software preditiva ou comportamental, mas de um esforço de reconstrução, explicitação e formalização de decisões de design em um projeto de IA generativa de alta complexidade.

1.6 Estrutura da Tese

Esta tese está organizada em seis capítulos encadeados, de modo a acompanhar a sequência lógica prescrita pela *Design Science Research* (DSR). A estrutura progride do estabelecimento do problema e da lente metodológica (Capítulos 1 e 2), passa pela explicitação do plano de pesquisa (Capítulo 3), entra no núcleo empírico de análise do artefato (Capítulo 4) e culmina na formulação das contribuições e na síntese final (Capítulos 5 e 6).

Capítulo 1 – Introdução

O primeiro capítulo estabelece o contexto da pesquisa. Define o cenário atual da inteligência artificial generativa e explicita a lacuna de representação e desempenho em LLMs para o Português Brasileiro (PT-BR) (Huang; Mo; Zhang, 2024; Assis et al., 2025). Formula o problema de pesquisa como uma dupla lacuna — técnica (escassez de arquiteturas *decoder-only* robustas em PT-BR) e metodológica (a “caixa preta” do design de IA) (Lipton & Steinhardt, 2018). Apresenta o Projeto Gaia como objeto de estudo empírico e o *Echeloned Design Science Research* (eDSR) como lente metodológica, justificando a relevância acadêmica e prática da investigação e definindo as delimitações do estudo (Tuunanen et al., 2024).

Capítulo 2 – Fundamentação Teórica e Metodológica

O segundo capítulo constrói o alicerce conceitual em dois eixos complementares:

- *Eixo do Domínio*: Analisa o panorama de LLMs em PT-BR, destacando a predominância de arquiteturas *encoder-only* e a persistência da lacuna generativa (escassez de *decoders*) (Cruz-Castañeda & Amadeus, 2025; Assis et al., 2025). Justifica a racionalidade técnica do Projeto Gaia (estratégia CPT + *Instruction Residuals*) como caminho eficiente e de mitigação de risco para especialização linguística (Jindal et al., 2024; Amadeus et al., 2025).
- *Eixo Metodológico*: Discute a DSR clássica e suas limitações para projetos de IA complexos e não lineares (Hevner et al., 2004; Gregor & Hevner, 2013). Apresenta o eDSR como solução para gerenciar essa complexidade, decompondo o projeto em cinco *echelons* (unidades de trabalho encadeadas) e acoplando-o ao *Framework for Evaluation in Design Science* (FEDS) para diferenciar avaliações de Prova de Conceito (PoC) e Prova de Valor (PoV) (Tuunanen et al., 2024; Venable; Pries-Heje; Baskerville, 2016).

Capítulo 3 – Design da Pesquisa

O terceiro capítulo descreve o método de pesquisa adotado. Detalha a adoção do eDSR como processo de pesquisa que espelha a lógica não linear do Projeto Gaia (Tuunanen

et al., 2024). Apresenta a Tabela Mestra de Echelons (v1.7) como artefato de controle que mapeia o que já se sabe (documentação pública e literatura) e as lacunas (o “porquê” das decisões) (Ghanbari; Tuunanen; Kazan, 2025). Define a estratégia de triangulação em três fontes (literatura, documentos públicos e entrevistas semiestruturadas) para preencher essas lacunas e garantir a rastreabilidade entre decisão e evidência (Kitchenham, 2007). Explica como a análise será conduzida de forma temática e dirigida por echelons (E1 a E5), com o FEDS orientando a classificação das avaliações (formativas/somativas; artificiais/naturalísticas) (Tuunanen et al., 2024; Venable; Pries-Heje; Baskerville, 2016).

Capítulo 4 – Análise e Mapeamento eDSR do Caso Gaia

O quarto capítulo constitui o núcleo empírico da tese. O Projeto Gaia é reconstruído *echelon* por *echelon*, utilizando dados triangulados (primários e secundários) (Tuunanen et al., 2024). O mapeamento reconstitui: (i) o Echelon 1 (Diagnóstico do Problema), (ii) o Echelon 2 (Objetivos e Requisitos de Design), (iii) o Echelon 3 (Design e Desenvolvimento, com foco em decisões cruciais como o uso do corpus Jabuticaba e a técnica de *Instruction Residuals* – IR) (Amadeus et al., 2025; Jindal et al., 2024), (iv) o Echelon 4 (Demonstração / PoC) e (v) o Echelon 5 (Avaliação / PoV). O foco é registrar a ordem das decisões, sua racionalidade e as evidências associadas, tornando visível um processo que a literatura de IA costuma condensar em poucos parágrafos (Lipton & Steinhardt, 2018).

Capítulo 5 – Conclusões e Contribuições

O quinto capítulo realiza a síntese e a discussão dos achados. A partir do mapeamento apresentado no Capítulo 4, são derivados os Princípios de Design (DPs) e formalizada a teoria de médio alcance sobre o design de LLMs de nicho em PT-BR, conforme os requisitos de Gregor & Hevner (2013). O foco recai sobre a generalização: discute-se em que condições os DPs são aplicáveis a outros contextos de línguas sub-representadas e quais mecanismos (por exemplo, CPT → esquecimento; IR → restauração instrucional) sustentam as proposições formuladas.

Capítulo 6 – Limitações, Agenda Futura e Considerações Finais

O sexto capítulo sintetiza as contribuições acadêmicas e práticas da tese, explicita suas limitações e propõe uma agenda de pesquisa futura. São discutidas as restrições do estudo (por exemplo, dependência de dados primários, escopo restrito ao PT-BR e ao Projeto Gaia) e indicadas possíveis extensões, tanto em termos de novos casos empíricos quanto de aprofundamento metodológico em eDSR e avaliação em IA generativa.

1.7 Lacunas Específicas Abordadas pela Tese

Para explicitar a contribuição desta pesquisa e orientar a leitura, esta tese endereça três lacunas complementares na literatura — técnica, metodológica e teórica — cuja

interdependência molda os desafios atuais do design de LLMs de nicho para o Português Brasileiro.

(1) Lacuna técnica — déficit de *decoders* otimizados para PT-BR.

A predominância de pré-treino em inglês e o foco histórico em arquiteturas *encoder-only* produzem queda sistemática de desempenho em tarefas generativas (NLG) quando modelos globais são aplicados a línguas menos representadas. No caso do PT-BR, essa assimetria é documentada em benchmarks recentes e em estudos comparativos envolvendo HRLs e LRLs (Costa-Jussà et al., 2022; Adelani et al., 2024/2025; Assis et al., 2025; Pava et al., 2025; Cruz-Castañeda & Amadeus, 2025). Esta tese mapeia esse ecossistema, posiciona o Gaia como um *decoder* especializado para PT-BR e examina a decisão *Continuous Pre-Training* (CPT) + *Instruction Residuals* (IR) como estratégia de eficiência e mitigação de risco para especialização linguística.

(2) Lacuna metodológica — invisibilidade do processo de design em IA.

A literatura de LLMs tende a relatar o “resultado” — modelo, arquitetura, métricas — enquanto silencia o *como* e o *porquê* das decisões de design (Lipton & Steinhardt, 2019). Essa opacidade dificulta rastreabilidade, replicação e a geração acumulativa de conhecimento. Ancorada na Design Science Research (Hevner et al., 2004; Sein et al., 2011), esta tese adota o *Echeloned Design Science Research* (eDSR) para tornar o processo visível por meio de echelons e acopla o *Framework for Evaluation in Design Science* (FEDS) para planejar avaliações formativas/somativas e artificiais/naturalísticas (Venable; Pries-Heje; Baskerville, 2016; Tuunanen; Ghanbari; Kazan, 2024).

(3) Lacuna teórica — ausência de teoria de médio alcance para LLMs de nicho.

Falta na literatura um conjunto explícito de *Princípios de Design* (DPs) e respectivas condições de aplicação para LLMs especializados em PT-BR. Esta tese responde a essa lacuna derivando DPs diretamente das decisões empíricas do Projeto Gaia e articulando-os como *mid-range design theory* (Gregor & Hevner, 2013), conectando mecanismos (por exemplo, CPT → esquecimento; IR → restauração instrucional), objetivos de design e contexto de uso.

Como a tese responde a essas lacunas.

- O Capítulo 2 fundamenta o domínio técnico e a abordagem metodológica.
- O Capítulo 3 apresenta o plano empírico, incluindo a Tabela Mestra e o procedimento para derivação dos DPs.
- O Capítulo 4 reconstrói o caso Gaia *echelon* por *echelon*, tornando o processo de design observável.

- O Capítulo 5 formaliza a teoria de médio alcance e os Princípios de Design derivados.
- O Capítulo 6 sintetiza contribuições, limitações e agenda futura.

2 Fundamentação Teórica e Metodológica

Este capítulo tem por finalidade construir o alicerce conceitual que permitirá analisar o Projeto Gaia como um artefato resultante de um processo de design sociotécnico, situado em um ecossistema linguístico específico e descrito por uma metodologia adequada a projetos digitais complexos (SEIN et al., 2011; GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016). O objetivo central é reorganizar a literatura de modo a justificar a dupla lacuna (técnica e metodológica) que a tese se propõe a enfrentar (HUANG; MO; ZHANG, 2025; SCAO et al., 2023; COSTA-JUSSÀ et al., 2022; ADELANI; AL., 2024; ASSIS; FREITAS; PAES, 2025; LIPTON; STEINHARDT, 2019; HEVNER et al., 2004; TUUNANEN; GHANBARI; KAZAN, 2024).

A argumentação desenvolvida neste capítulo estrutura-se em dois eixos complementares, que dialogam diretamente com o problema de pesquisa:

Eixo do Domínio (o problema empírico). Este eixo endereça a lacuna técnica ao apresentar o panorama dos Modelos de Linguagem de Grande Porte (LLMs) em Português Brasileiro (PT-BR). Mostra-se que, embora o gargalo de dados brutos tenha sido substancialmente mitigado por iniciativas nacionais de grande escala, como o corpus Jabuticaba (mais de 139 bilhões de tokens), persiste uma assimetria de desempenho entre línguas. Essa insuficiência é mais aguda em tarefas de geração (*Natural Language Generation* — NLG) e em registros culturalmente marcados, padrão também observado em outras línguas sub-representadas, do letão ao nheengatu (DARĞIS; AL., 2024; ADELANI et al., 2025). Tal evidência torna tecnicamente sensata a busca por modelos de nicho e por *pipelines* de especialização modular, como a combinação de *Continuous Pre-Training* (CPT) seguida de restauração instrucional por meio de *Instruction Residuals* (IR) (JINDAL; AL., 2024).

Eixo Metodológico (a lente analítica). Este eixo endereça a lacuna de processo. A *Design Science Research* (DSR) clássica é revisitada, e suas limitações para projetos de IA que envolvem múltiplos *stakeholders*, dados não estáticos e iteração constante entre problema e solução são destacadas. O foco desloca-se então para o *Echeloned Design Science Research* (eDSR), um framework concebido para gerenciar essa complexidade ao decompor o projeto em *echelons* (unidades de trabalho encadeadas) e associar a cada um um artefato intermediário validado (TUUNANEN; GHANBARI; KAZAN, 2024). Argumenta-se que o eDSR não apenas descreve de forma mais fidedigna o processo de design em ambientes digitais complexos (GREGOR; HEVNER, 2013), como também cria pontos de ancoragem explícitos para o registro de decisões críticas. Além disso, demonstra-se como o eDSR se acopla ao *Framework for Evaluation in Design Science* (FEDS), permitindo distinguir entre Prova de Conceito (PoC) — avaliações formativas

em contextos artificiais — e Prova de Valor (PoV) — avaliações somativas em contextos naturalísticos (GREGOR; HEVNER, 2013; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Ao articular esses dois eixos — um que explicita por que são necessários LLMs especializados em PT-BR e outro que explicita como documentar, de forma rastreável, o caminho até esses artefatos —, o capítulo estabelece o enquadramento teórico-metodológico sobre o qual se apoia a análise empírica do Capítulo 4, orientada à derivação de Princípios de Design generalizáveis (TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

2.1 O Eixo do Domínio: Assimetria Linguística e a Lacuna Generativa em PT-BR

O panorama de LLMs é marcado por assimetria de recursos: a maioria dos modelos de alto desempenho é pré-treinada majoritariamente em inglês e em poucas línguas de alta disponibilidade (CRUZ-CASTAÑEDA; AMADEUS, 2025). Essa assimetria de treinamento implica queda de desempenho quando arquiteturas globais são aplicadas a idiomas menos representados nos corpora originais, sobretudo em tarefas generativas que exigem adequação cultural e de registro, e não apenas reconhecimento de padrões (COSTA-JUSSÀ; AL., 2022; ADELANI; AL., 2024).

Evidências empíricas:

1. Em línguas de menor disponibilidade, como o letão, modelos abertos de famílias fortes (LLaMA, Qwen, Gemma, Mistral) mantêm qualidade em inglês, mas falham em NLG na língua-alvo, produzindo saídas menos coerentes e pouco adequadas ao contexto local (DARĞIS; AL., 2024).
2. No Brasil, o PT-BR (HRL) convive com ≈ 160 LRLs indígenas; enquanto HRLs superam 90% em POS tagging, LRLs podem ficar abaixo de 34%, mostrando que a lacuna é multidimensional (COSTA-JUSSÀ; AL., 2022; ADELANI; AL., 2024).

2.1.1 Paradoxo do PT-BR

O gargalo de dados está mitigado: há corpora massivos, limpos e deduplicados; p.ex., Jabuticaba reúne >139B tokens e 669 GB exclusivamente em português (SCOTTI; CRUZ-CASTAÑEDA; AMADEUS, 2025). Ainda assim, persiste lacuna generativa em PT-BR, explicada pelo avanço histórico mais rápido em modelos *encoder-only* (típicos de tarefas discriminativas) do que em *decoder-only* voltados à geração livre (CRUZ-CASTAÑEDA; AMADEUS, 2025). Avaliações da “fauna” de LLMs brasileiros sugerem que, embora

Tabela 1 – POS em línguas brasileiras: Comparação entre GPT-4 e XLM-R

Language	XLM-R	XLM-R (zero-shot cross-lingual transfer)						GPT-4
	Test set A	Test set A			Test set B			Test set B
	Full-sup.	en→xx	pt→xx	LAFT + pt→xx	en→xx	pt→xx	LAFT + pt→xx	0-shot
high-resource languages								
en_cwt	98.0	98.0	83.6			91.9		
pt_gsd	97.8	90.0	97.8			92.4		
Brazilian languages								
apu.ufpa	-	37.5	40.6	44.9	36.8	40.2	44.7	42.6
aqz.tudet	-	31.9	37.8		31.3	36.8		49.5
arr.tudet	-	3.9	14.9		6.3	19.8		27.7
bor.bdt	-	19.0	23.5	27.3	18.4	23.0	26.4	41.3
gub.tudet	-	26.5	30.2	36.0	27.8	32.1	37.1	36.2
jaa.jarawara	-	28.2	28.4	34.5	27.2	27.9	33.6	33.0
mpu.tudet	-	4.9	9.0		0.0	0.8		0.0
myu.tudet	-	21.2	27.1	30.3	10.8	14.8	16.5	18.2
tpn.tudet	-	39.1	41.9		38.9	41.8		47.2
urb.tudet	-	7.8	11.8	21.2	9.2	9.5	21.6	32.3
xav.xdt	-	26.5	29.0	28.2	27.3	29.9	29.3	36.5
yrl-complin	-	28.9	31.5		29.0	31.7		41.2
African languages								
wo_wtb	87.6	29.3	35.6					64.8
yo_ytb	-	22.5	31.5					75.4
Average (Brazilian languages)								
	-	23.0	27.1		21.9	25.7		33.8

Fonte: Adaptado de Adelani et al. (2025).

competitivos em tarefas discriminativas, modelos fechados de referência (e.g., GPT-4o) seguem no topo em geração; o gargalo está na falta de decoders de nicho desenhados para mitigar o déficit generativo em PT-BR (ASSIS; FREITAS; PAES, 2025).

2.1.2 A Racionalidade Técnica da Especialização (CPT e Instruction Residuals)

A insuficiência generativa e o histórico de modelos *encoder-only* justificam a necessidade de especialização linguística pesada (Modo Especializado/de Nicho). O Projeto Gaia adota essa rota, tomando uma base decoder (Gemma) e submetendo-a a *Continuous Pre-training* (CPT) intensivo em PT-BR (cerca de 13 bilhões de tokens curados), conforme consta em sua documentação pública.

A ordem dessas etapas é crucial e está ancorada em evidência experimental. Jindal et al. (2024) mostram que aplicar pré-treino contínuo (CPT) diretamente sobre um modelo já instruído degrada a capacidade de seguir instruções (esquecimento catastrófico), ao passo que realizar o CPT no modelo base e só depois restaurar a instrução preserva o conhecimento novo e a competência instrucional (JINDAL; AL., 2024). Para essa restauração, os autores propõem os *Instruction Residuals* (IR), definidos no espaço paramétrico como o resíduo instrucional entre pesos do modelo instruído e do modelo base:

$$\Theta_{res} = \Theta_{instr} - \Theta_{base} \quad (2.1)$$

(cf. Jindal e al. (2024), Eq. 1).

Em múltiplas famílias (LLaMA 3/3.1; Qwen 2/2.5), os autores evidenciam:

- (i) queda consistente nas métricas de *instruction-following* quando se faz CPT no modelo instruído (Setting 1);
- (ii) estabilidade ou ganhos quando se faz CPT no base + IR (Setting 2);
- (iii) portabilidade do Θ_{res} entre variantes da mesma família (JINDAL; AL., 2024).

Do ponto de vista de custo, o *instruction fine-tuning* completo tende a ser substancialmente mais caro do que um CPT moderado seguido de IR (JINDAL; AL., 2024), o que reforça a eficiência da estratégia por resíduos.

No caso do Gaia, essa evidência motiva a decisão de design: combinar CPT focalizado no PT-BR com IR para restaurar instrução, obtendo especialização linguística com melhor relação custo-benefício. No eDSR, por exemplo, essa decisão é documentada no Echelon 3 (racionalidade de design) e verificada no Echelon 4 (PoC), enquanto a restrição de eficiência/custo é rastreada ao Echelon 2 (requisitos).

Figura 1 – Efeito do CPT e dos Instruction Residuals: em Setting 1 (CPT no instruído), métricas de instruction-following (ex.: IFEval) caem com o aumento de tokens; em Setting 2 (CPT no base + IR), a capacidade é restaurada ou supera o baseline instruído (dados adaptados de Jindal e al. (2024), Tabs. 2–3; Fig. 3–4).

Benchmark	Metric	L3b				L3i				L3b + 3Lr		
		# of new tokens →	org.	+100M	+500M	+1B	org.	+100M	+500M	+1B	100M	500M
IFEval	ILL_acc	19.06	17.75	19.30	20.14	53.36	45.68	45.32	41.01	57.67	56.47	57.79
	ILS_acc	17.87	16.31	17.87	17.87	47.84	40.41	38.61	35.25	51.68	51.44	51.68
	PLL_acc	09.98	09.61	10.54	11.09	41.77	34.20	33.64	28.10	44.18	42.88	44.36
	PLS_acc	09.06	08.69	09.61	09.80	35.30	29.21	26.80	22.55	37.52	36.78	37.52
MMLU	acc	62.14	63.76	63.77	63.62	63.83	66.04	65.38	65.52	67.69	67.16	67.51
MMLU-Pro	EM	34.51	34.92	34.70	35.49	39.70	36.39	35.76	35.52	40.72	40.84	40.27
GSM8K	EM	49.58	48.14	47.54	47.08	75.06	69.22	68.08	68.01	74.83	73.92	73.16
	strict-EM	49.20	34.04	36.62	39.04	74.98	65.35	59.74	55.42	46.93	55.27	49.51
Sub-Average		31.43	29.15	29.99	30.52	53.98	48.31	46.67	43.92	52.65	<u>53.10</u>	52.73
Winogrande	acc	73.16	72.14	71.59	71.27	71.74	72.22	71.74	71.74	71.43	72.06	71.19
Hellaswag	acc	60.12	60.17	60.27	60.23	57.70	58.69	58.73	59.00	59.30	59.16	59.39
	acc_n	79.22	78.62	78.20	78.36	75.76	77.84	77.68	77.80	79.01	79.14	79.00
ARC_easy	acc	80.39	81.14	80.60	80.60	81.52	79.71	79.63	79.46	82.20	82.32	82.03
	acc_n	77.78	80.30	79.67	79.38	79.63	77.53	77.65	77.44	79.00	79.25	79.08
Piqa	acc	79.54	80.09	80.30	80.20	78.56	79.87	79.49	79.49	80.25	80.20	80.41
	acc_n	80.74	81.56	81.34	80.96	78.62	80.41	79.98	79.98	80.63	80.74	80.90
Sub-Average		75.85	76.29	76.00	75.86	74.79	75.18	74.99	74.99	75.97	<u>76.12</u>	76.00
T_mc2	acc	43.94	47.64	47.29	47.41	51.67	51.80	51.55	51.68	<u>56.13</u>	55.73	56.17
Average		51.64	50.93	51.20	51.41	62.94	60.28	59.36	58.00	63.07	63.34	63.12


2.1.3 O Domínio de Arquiteturas Encoder vs. a Lacuna de Decoders

No ecossistema de PLN, arquiteturas *encoder-only* (p.ex., BERT/RoBERTa) são tradicionalmente superiores em tarefas discriminativas (classificação, NER, recuperação), enquanto arquiteturas *decoder-only* (p.ex., GPT-like) são a base de geração aberta (NLG); arranjos *encoder-decoder* costumam dominar tradução e sequências condicionadas (DELOBELLE; WINTERS; BERENDT, 2020; COSTA-JUSSÀ; AL., 2022; SCAO et al., 2023). Essa distinção não é apenas tipológica: ela configura o tipo de capacidade que cada comunidade nacional consegue desenvolver com mais rapidez (compreensão vs. geração).

No Brasil, a distribuição recente de modelos treinados/adaptados para PT-BR mostra predomínio de *encoder-only* (voltados à compreensão/discriminação) frente a *decoder-only* especializados em geração aberta, com *encoder-decoder* representando um contingente menor. Em um levantamento de PT-BR-LLMs, observa-se o seguinte quadro agregado de arquiteturas (CRUZ-CASTAÑEDA; AMADEUS, 2025):

- encoder-only = 19;
- decoder-only = 11;
- encoder-decoder = 4.

Figura 2 – Distribuição de arquiteturas em PT-BR-LLMs (encoder-only $n = 19$; decoder-only $n = 11$; encoder-decoder $n = 4$).



Fonte: Cruz-Castañeda e Amadeus (2025).

Esse desequilíbrio ajuda a explicar a lacuna generativa em PT-BR: o ecossistema local avançou mais em tarefas de classificação/extração do que em geração aberta de alta qualidade.

A consequência prática desse viés arquitetural aparece quando avaliamos tarefas generativas: estudos de “fauna” de LLMs brasileiros indicam que, embora modelos nacionais sejam competitivos em tarefas discriminativas, modelos fechados de referência ainda tendem a liderar geração aberta (sumarização, simplificação, QA), sinalizando déficit de decoders de nicho realmente otimizados para PT-BR (ASSIS; FREITAS; PAES, 2025).

Em paralelo, análises em outras línguas menos centrais (p.ex., letão) mostram padrão semelhante: famílias fortes (LLaMA, Qwen, Gemma, Mistral) preservam alta qualidade em inglês, mas degradam coerência/adequação local em NLG na língua-alvo (DARĞIS; AL., 2024). Esse contraste reforça que geração aberta exige decoders especializados e dados/ajustes alinhados ao registro cultural.

Além da tipologia, pipelines em estágios têm sido adotados em projetos recentes para especializar capacidades antes de ajustes finos no domínio (p.ex., Code Llama, derivado de Llama 2), ilustrando como estratégias de especialização progressiva podem transferir habilidades de base e, depois, focar em tarefas de geração específicas (ROZIÈRE et al., 2023). No contexto brasileiro, essa lógica sustenta a priorização de decoders quando o objetivo é melhorar NLG em PT-BR.

Em síntese, o quadro arquitetural nacional — muito encoder, pouco decoder — é consistente com a lacuna generativa observada em PT-BR. Para revertê-la, torna-se necessário um design orientado a decoders e a pipelines de especialização (dados curados + estratégias de treino/ajuste compatíveis com geração aberta), condição que fundamenta as escolhas técnicas analisadas nos tópicos seguintes (CRUZ-CASTAÑEDA; AMADEUS, 2025; ASSIS; FREITAS; PAES, 2025; ROZIÈRE et al., 2023).

2.1.4 LLMs Genéricos vs. LLMs de Nicho: O Posicionamento do Gaia

A literatura atual e a documentação técnica estabelecem uma distinção clara entre dois paradigmas de desenvolvimento de LLMs: o Modo Genérico/Global e o Modo Especializado/de Nicho (CRUZ-CASTAÑEDA; AMADEUS, 2025). Embora os LLMs modernos demonstrem notável capacidade multilíngue, sendo treinados em dados massivos que cobrem diversas línguas, essa abordagem é frequentemente dominada pelo inglês, o que pode limitar a generalização e aprofundar a assimetria em contextos linguísticos com menos recursos ou representação assimétrica (LIN et al., 2022).

2.1.4.1 O Paradigma Genérico e suas Limitações em PT-BR

Modelos genéricos *State-of-the-Art* (SOTA), como os da família GPT e Claude, buscam a máxima generalização e cobertura (SCHUCK; AL., 2025). No entanto, esta generalidade se traduz em uma propensão a falhas contextuais em línguas com baixa presença no pré-treinamento global. Mesmo que esses modelos multilíngues consigam obter alta performance em tarefas discriminativas em PT-BR, como análise de sentimento, eles frequentemente demonstram insuficiência em tarefas generativas (NLG), falhando na adequação cultural e na escolha de registro (PAVA; AL., 2025).

Evidência externa de desempenho generativo em PT-BR. Avaliações recentes em três tarefas de Geração de Linguagem Natural (sumarização, simplificação e QA generativo) mostram que a série GPT-4o lidera em português, com a família Sabiá-3 em segundo lugar, enquanto modelos de pesos abertos como Tucano se destacam pela eficiência computacional (tempo/energia/CO₂) apesar de ficarem atrás em métricas generativas. A análise combina métricas léxicas (BLEU/ROUGE/METEOR), semânticas (BERTScore), julgamentos “LLM-as-a-judge” (G-Eval) e um conjunto linguístico específico para PT-BR (NILC-Metrix), oferecendo uma leitura mais completa que os benchmarks exclusivamente discriminativos. Esses achados corroboram a necessidade de especialização e avaliação contextualizadas à língua e, para o nosso caso, justificam a estratégia de CPT focalizado + IR como caminho de mitigação de risco/eficiência para alcançar utilidade prática com custos controlados.

Figura 3 – Desempenho generativo e custo de inferência em PT-BR. Comparação entre modelos brasileiros (Sabiá-3, Tucano, Cabra, etc.) e GPT-4o, com tempos de inferência, energia e CO₂eq.

Model	Inference Consumption (↓)				Generative Metrics (↑)										
	Rank (Gen.)	Time (h)	Energy (kWh)	CO ₂ eq (kg)	BLANC	METEOR	BLEU	ROUGE				BERTScore			G-Eval
								R1	R2	RL	RLs	prec.	recall	f1	
Tucano (G-440 passara)	4	0.699	0.142	0.016	0.059	0.109	0.000	12.750	1.530	8.300	8.560	0.648	0.681	0.664	0.399
Periquito (G-350 passara)	8	0.575	0.134	0.015	0.018	0.043	0.000	6.870	0.500	5.160	5.160	0.616	0.636	0.625	0.322
Bode (G-030 passara)	6	1.325	0.349	0.040	0.037	0.068	0.000	9.590	0.790	6.870	7.370	0.620	0.656	0.637	0.228
Cabra (G-030 passara)	7	1.334	0.352	0.040	0.025	0.057	0.000	8.590	0.670	6.190	6.870	0.609	0.648	0.628	0.225
Boto (G-240 passara)	5	1.997	0.515	0.058	0.043	0.074	0.000	10.710	1.160	7.430	7.460	0.649	0.675	0.661	0.306
Sabiazinho-3 (G-parana andanover)	1	—	—	—	0.243	0.294	0.055	37.010	14.910	24.650	24.660	0.721	0.742	0.731	0.495
GPT4o-mini (G-parana andanover)	2	—	—	—	0.268	0.314	0.051	36.540	14.740	24.080	24.080	0.713	0.750	0.731	0.503
Sabiá-3 (G-parana andanover)	3	—	—	—	0.242	0.291	0.052	36.950	14.690	24.490	24.500	0.718	0.741	0.729	0.500
GPT4o (G-parana andanover)	2	—	—	—	0.271	0.313	0.053	36.420	14.750	24.020	24.020	0.713	0.749	0.731	0.518

Fonte: Adaptado de Assis, Freitas e Paes (2025).

Observa-se que:

- (i) modelos proprietários mantêm a dianteira em qualidade gerativa;
- (ii) há alternativas abertas competitivas por critério de eficiência (Tucano);

- (iii) “forças divergentes” entre abertos (melhor em um critério, pior em outro) reforçam a importância de avaliar por caso de uso e não por um único leaderboard.

Esses resultados dialogam com a nossa decisão de especialização em estágios e com o acoplamento eDSR + FEDS para separar evidências formativas (benchmarks/ablação) de somativas (utilidade percebida por stakeholders).

Apesar da liderança em tarefas generativas em PT-BR (sumarização, simplificação, QA) (ASSIS; FREITAS; PAES, 2025), o custo, as licenças fechadas e a falta de transparência sobre pesos e dados (Captura de Valor) desses modelos genéricos levam à necessidade de alternativas abertas e especializadas (WU et al., 2023b).

2.1.4.2 A Emergência do LLM de Nicho

LLMs de nicho são artefatos especializados por domínio (p.ex., finanças) ou por língua/cultura, que usam estratégias focadas — *fine-tuning*, *continual pre-training* ou treino *from scratch* — para maximizar utilidade local (ASSIS; FREITAS; PAES, 2025; WU et al., 2023a; ROZIÈRE et al., 2023). Na prática recente, pipelines em estágios têm sido adotados para ampliar capacidades de base antes das especializações (p.ex., Code Llama derivado do Llama 2), ilustrando como especialização progressiva melhora tarefas-alvo sem perder competências já adquiridas (ROZIÈRE et al., 2023).

No Brasil, há um ecossistema ativo (Sabiá, Tucano, Cabra), com forças divergentes por tarefa: eficiência e bons resultados em sumarização/simplificação no Tucano, desempenho competitivo em QA no Cabra, enquanto modelos proprietários seguem líderes em qualidade gerativa (ASSIS; FREITAS; PAES, 2025). Essa heterogeneidade reforça a necessidade de especialização orientada ao caso de uso e à língua-alvo.

2.1.4.3 Posicionamento do Projeto Gaia

O Gaia se posiciona explicitamente como LLM de nicho aberto para PT-BR, partindo de base decoder (Gemma) e adotando CPT focalizado seguido de *Instruction Residuals* (IR) como decisão de mitigação de risco/eficiência — evitando *catastrophic forgetting* e restaurando a capacidade instrucional com melhor relação custo-benefício (JINDAL; AL., 2024).

À luz do eDSR, esse racional será documentado no Echelon 3 (decisão de design) e avaliado em PoC (E4, formativo/artificial) e PoV (E5, somativo/naturalístico) com o FEDS, assegurando rastreabilidade entre requisito, experimento e valor entregue (TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Em resumo, a tese argumenta que a especialização não é um luxo, mas uma necessidade (lacuna técnica), e o Projeto Gaia representa o estudo de caso exemplar dessa necessidade, sendo seu processo de design a fonte de conhecimento metodológico (lacuna

Tabela 2 – Comparativo de Valor entre LLMs Genéricos e de Nicho

Dimensão de Valor	LLMs Genéricos (SOTA Global)	LLMs de Nicho (Especializados)
Arquitetura de Valor	Treinados sobre corpora massivos e heterogêneos, visando ampla cobertura multilíngue; o idioma-alvo é apenas um entre muitos. (SCOTTI; CRUZ-CASTAÑEDA; AMADEUS, 2025; CRUZ-CASTAÑEDA; AMADEUS, 2025)	Otimizados para um espaço linguístico-cultural específico (PT-BR), utilizando <i>continuous pre-training</i> focalizado e curadoria de dados locais. (CRUZ-CASTAÑEDA; AMADEUS, 2025)
Proposição de Valor	Excelente desempenho médio, mas com maior propensão a falhas contextuais em línguas pouco presentes no pré-treino e em domínios culturalmente marcados. (HUANG; MO; ZHANG, 2025; ASSIS; FREITAS; PAES, 2025)	Maior aderência cultural e contextual, melhor escolha de registro e maior utilidade em tarefas locais em PT-BR. (CRUZ-CASTAÑEDA; AMADEUS, 2025)
Captura de Valor	Predominância de APIs ou licenças fechadas, com pesos e dados pouco transparentes. (CRUZ-CASTAÑEDA; AMADEUS, 2025)	Tendência a distribuição aberta ou semiaberta, permitindo auditoria, personalização e redução de custos locais. (CRUZ-CASTAÑEDA; AMADEUS, 2025)

Fonte: Elaboração própria.

de processo) (GREGOR; HEVNER, 2013; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

2.2 O Eixo Metodológico: Da DSR ao eDSR

Este eixo estabelece o rigor metodológico para tornar auditável o processo de design do Projeto Gaia, respondendo à “caixa-preta” frequentemente criticada na literatura quando trabalhos privilegiam apenas o resultado final e não tornam claros os passos que geraram os ganhos empíricos (HEVNER et al., 2004).

Na disciplina de Sistemas de Informação, convivem dois paradigmas: *behavioral science* (explicar/predizer fenômenos) e *design science* (estender capacidades humanas/organizacionais pela criação de artefatos). Na formulação clássica, a DSR obtém conhecimento ao construir e aplicar artefatos e orienta sua execução por diretrizes de construção e avaliação rigorosas. Artefatos são amplamente definidos como construtos, modelos, métodos e instâncias (HEVNER et al., 2004).

Para operacionalizar a DSR, a *Design Science Research Methodology* (DSRM) consolidou um processo em seis fases: identificação do problema, definição de objetivos, design & desenvolvimento, demonstração, avaliação e comunicação (TUUNANEN; GHAN-

BARI; KAZAN, 2024). Contudo, em projetos digitais complexos e sociotécnicos (como LLMs/GenAI), a avaliação só após o design não capta a coreografia real do projeto, no qual problemas e soluções evoluem de modo não linear; nesses casos, é preferível “falhar cedo, falhar com frequência” e entrelaçar validação às atividades de análise, objetivos e design (TUUNANEN; GHANBARI; KAZAN, 2024).

É nesse ponto que o *Echeloned Design Science Research* (eDSR), de Tuunanen, Winter e vom Brocke (2024), propõe uma lógica organizadora complementar baseada em *echelons* — unidades autocontidas e logicamente coerentes — que decompõem o projeto e amarram cada parte a um artefato intermediário validado. O eDSR define cinco echelons:

1. Análise do Problema (*problem statement*);
2. Objetivos & Requisitos (*design requirements*);
3. Design & Desenvolvimento (*solution design* projetável);
4. Demonstração (instância ilustrativa em contexto artificial ou natural);
5. Avaliação (artefato em uso).


Duas consequências práticas são centrais para esta tese:

- (i) **Validação intercalada:** a avaliação deixa de ser “um momento no fim” e passa a ocorrer ao longo das decisões, reduzindo risco e aumentando traçabilidade (princípio compatível com abordagens ágeis) (TUUNANEN; GHANBARI; KAZAN, 2024).
- (ii) **Acúmulo incremental de conhecimento de design:** cada echelon entrega um artefato comunicável e validado, facilitando iteração e coerência entre as partes (TUUNANEN; GHANBARI; KAZAN, 2024).

Para qualificar a avaliação em cada echelon, acoplamos o eDSR ao *Framework for Evaluation in Design Science* (FEDS). O FEDS caracteriza episódios de avaliação em duas dimensões ortogonais: (a) propósito funcional — formativa (para melhorar) vs. somativa (para julgar) — e (b) paradigma — artificial (ambientes controlados/benchmarks) vs. naturalístico (contexto real). Assim, a estratégia de avaliação pode ser alinhada ao tipo de evidência exigida em cada etapa do design (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Aplicação ao Gaia. No Echelon 3, decisões técnicas como *Instruction Residuals* são registradas com sua racionalidade; no Echelon 4, obtêm-se evidências formativas via benchmarks/ablação; no Echelon 5, conduzem-se avaliações somativas/naturalísticas com stakeholders e tarefas reais — tudo com rastreabilidade entre decisão e valor entregue.

Figura 4 – Metamodelo do eDSR: echelons, artefatos intermediários e ciclos de validação



Fonte: Adaptado de Tuunanen, Ghanbari e Kazan (2024).

2.2.1 Do DSR clássico à necessidade de gerenciar a complexidade em IA

O ponto de partida metodológico desta tese é o arcabouço do *Design Science Research* (DSR), cujo propósito é gerar conhecimento ao construir e avaliar artefatos que solucionem problemas relevantes (HEVNER et al., 2004). A operacionalização mais difundida é a DSRM, estruturada em seis fases: (1) identificação do problema e motivação; (2) definição de objetivos; (3) design & desenvolvimento; (4) demonstração; (5) avaliação; (6) comunicação (PEFFERS et al., 2007). Essa sequência funciona bem quando as fronteiras do sistema são relativamente estáveis e a iteração pode ocorrer depois de um ciclo inicial.

Por que isso é insuficiente em LLMs/GenAI

Em projetos sociotécnicos complexos — como LLMs — problema e solução são emergentes, e o fluxo real raramente é linear. Três frentes expõem as limitações da DSRM “pós-design”:

1. **Não linearidade e coevolução problema–solução.** A solução se refina à medida que o entendimento do problema muda; por isso, avaliação e (re)especificação precisam ocorrer ao longo do percurso, não apenas ao final (SEIN et al., 2011; HEVNER et al., 2004).
2. **Avaliação distribuída e situada.** Em IA, há necessidade de episódios de avaliação com diferentes propósitos (formativo vs. somativo) e em diferentes contextos (artificial vs. naturalístico); planejar essas combinações desde o início é essencial

para reduzir risco e aumentar validade (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

3. **Decisões modulares de mitigação de risco.** Em LLMs, certas escolhas técnicas no meio do design mudam o curso do projeto e precisam de validação intercalada. No Projeto Gaia, por exemplo, o *continuous pre-training* (CPT) intensivo em PT-BR é necessário para especialização, mas induz *catastrophic forgetting* quando aplicado sobre modelos já instruídos; a resposta de design foi adotar *Instruction Residuals* (IR) para restaurar a capacidade instrucional com eficiência computacional (JINDAL; AL., 2024). Sem uma moldura metodológica própria, essa decisão apareceria apenas como “detalhe técnico” em documentação pública (p.ex., *model card*), sem rastreabilidade processual que permita convertê-la em princípio de design (CEIA-UFG, 2025; JINDAL; AL., 2024).

Do DSR ao eDSR

Para gerenciar essa complexidade, adotamos o *Echeloned Design Science Research* (eDSR) como lógica organizadora complementar (TUUNANEN; GHANBARI; KAZAN, 2024). O eDSR decompõe o projeto em *echelons* — unidades autocontidas e encadeadas — e vincula cada uma a um artefato intermediário validado, tornando o processo observável por partes. Assim, decisões como IR são registradas com sua racionalidade no Echelon 3 (*Design & Desenvolvimento*) e validadas por episódios formativos (PoC, Echelon 4) e somativos/naturalísticos (PoV, Echelon 5), conforme o FEDS (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

O eDSR não revoga a DSRM; ele a desdobra, alinhando a cadência metodológica à cadência real de projetos de IA complexos, com rastreabilidade entre decisão e evidência (TUUNANEN; GHANBARI; KAZAN, 2024).

2.2.2 O framework eDSR (Pilar 1): echelons, artefatos intermediários e validação

Diante das limitações do DSR clássico para projetos digitais não lineares e sociotécnicos, adotamos o *Echeloned Design Science Research* (eDSR) como lógica organizadora complementar. Enquanto o DSR/DSRM oferece os fundamentos do ciclo de construção–avaliação (HEVNER et al., 2004; PEFFERS et al., 2007), o eDSR decompõe o projeto em unidades de trabalho encadeadas — os *echelons* — e vincula cada uma a um artefato intermediário validado, tornando o processo observável “em partes” (TUUNANEN; GHANBARI; KAZAN, 2024).

Arquitetura do eDSR: echelons e artefatos. O eDSR propõe cinco echelons, cada qual com entregáveis verificáveis e critérios de coerência com os demais (ver Figura 4).

Tabela 3 – Definição e Artefatos dos Echelons de DSR

Echelon 1 – Análise do Problema	
Artefato	Problem statement validado.
Perguntas-chave	Qual é o problema relevante e para quem? Que evidências o sustentam?
Fonte típica	Literatura e documentos públicos triangulados (TUUNANEN; GHANBARI; KAZAN, 2024).
Echelon 2 – Objetivos e Requisitos de Design	
Artefato	DO/DRs explicitados (“que desempenho, em quais tarefas, sob quais restrições?”).
Perguntas-chave	O que o artefato deve fazer e sob que recursos/limitações?
Rastreabilidade	Requisitos ancorados no E1 e auditáveis (TUUNANEN; GHANBARI; KAZAN, 2024).
Echelon 3 – Design & Desenvolvimento	
Artefato	Blueprint técnico e registro de decisões.
Perguntas-chave	Por que esta alternativa e não outra? Quais riscos e mitigações foram consideradas?
Exemplo Gaia	Decisão CPT + IR como mitigação do <i>catastrophic forgetting</i> e restauração instrucional eficiente (JINDAL; AL., 2024).
Echelon 4 – Demonstração (PoC)	
Artefato	Evidências de eficácia técnica em ambiente controlado (benchmarks, ablações).
Perguntas-chave	Funciona como pretendido sob condições artificiais?
Echelon 5 – Avaliação (PoV)	
Artefato	Evidências de utilidade em uso real (feedback, adoção, valor percebido).
Perguntas-chave	Entrega valor no contexto-alvo? Há retorno para refinar E2/E3?

Fonte: Adaptado de Tuunanen, Ghanbari e Kazan (2024).

Essa decomposição reduz risco de revisões tardias e aumenta a transparência, pois cada decisão é registrada com propósito, evidência e efeito nos demais echelons.

Exemplo de rastreabilidade no Projeto Gaia (E3). No Gaia, a adoção de IR após CPT é tratada como decisão de design:

- **Racionalidade:** CPT direto em modelo instruído degrada *instruction-following*; IR restaura a capacidade instrucional de forma modular e eficiente (JINDAL; AL., 2024).

- **Registro:** a decisão é documentada no artefato E3 (blueprint técnico + *decision log*).
- **Generalização:** registrada dessa forma, a decisão pode ser derivada como Princípio de Design (TUUNANEN; GHANBARI; KAZAN, 2024).

Tabela 4 – Ponte eDSR $\times$ FEDS (o que validar, como validar e quando avançar)

Echelon	Artefato intermediário	Avaliação (FEDS)	Evidências típicas	Exemplo Gaia	Critério de saída
E1	Problem statement	Formativa $\times$ Naturalística; Formativa $\times$ Artificial	Falhas em NLG; benchmarks; literatura	Dossiê da lacuna generativa	Consenso sobre problema e métricas iniciais
E2	DOs/DRs + Tabela Mestra	Formativa $\times$ Naturalística; Formativa $\times$ Artificial	Matriz DO/DR; restrições; critérios de sucesso	DR: CPT focalizado + restauração instrucional	Requisitos aprovados e rastreáveis
E3	Blueprint + decisões	Formativa $\times$ Artificial	Dados (13B tokens), arquitetura (Gemma), IR	Adoção de IR como mitigação de risco	Demonstração de viabilidade técnica e orçamentária
E4	Instâncias/PoC	Formativa $\times$ Artificial	ENEM-like, NILC-Metrix, ROUGE, BERTScore	Gaia-4B com metas técnicas atingidas	Metas de PoC cumpridas
E5	Avaliação em uso real	Somativa $\times$ Naturalística	Feedback de órgãos/empresas; valor percebido	Utilidade reportada por stakeholders	Evidência de valor e retorno a requisitos

Fonte: Adaptado de Tuunanen, Ghanbari e Kazan (2024), Venable, Pries-Heje e Baskerville (2016).

Validação rigorosa: acoplamento eDSR $\leftrightarrow$ FEDS. O eDSR indica *quando* validar; o FEDS indica *como* validar. O FEDS organiza episódios de avaliação em duas dimensões: propósito (formativa vs. somativa) e paradigma (artificial vs. naturalístico) (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).


Pelo FEDS, avaliações formativas melhoram o artefato ao longo do projeto (benchmarks, ablações), enquanto avaliações somativas julgam o valor entregue. Episódios artificiais incluem testes de laboratório e leaderboards; episódios naturalísticos incluem uso real com stakeholders.

No Gaia:

- E4/PoC: formativa $\times$ artificial (ENEM 2024, NILC-Metrix, SARI).
- E5/PoV: somativa $\times$ naturalística (feedback de órgãos e empresas).

Assim, cada decisão registrada no E3 (ex.: IR) é avaliada em E4 sob eficácia técnica/riscos e em E5 sob utilidade percebida, garantindo rastreabilidade entre decisão, evidência e valor (VENABLE; PRIES-HEJE; BASKERVILLE, 2016; TUUNANEN; GHANBARI; KAZAN, 2024).

Figura 5 – FEDS: propósitos e paradigmas de avaliação



Fonte: Adaptado de Venable, Pries-Heje e Baskerville (2016).

2.2.3 Justificando o eDSR para análise de projetos de IA

Adotamos o *Echeloned Design Science Research* (eDSR) porque ele estende o DSR ao organizar o projeto em *echelons*, cada qual com artefatos intermediários validados, tornando visível o processo de design e permitindo relatos parciais com critérios explícitos em cada etapa (TUUNANEN; GHANBARI; KAZAN, 2024). Diferentemente do DSR clássico — cuja lógica sequencial tende a concentrar a avaliação no fim do ciclo (HEVNER et al., 2004; PEFERS et al., 2007) — o eDSR acomoda iteração e não linearidade, comuns em IA generativa e projetos multistakeholder.

Adequação ao caso Gaia — três justificativas centrais

2.2.3.0.1 Rastreabilidade em contextos multistakeholder.

Projetos de IA generativa combinam interesses organizacionais heterogêneos (empresas, laboratórios, comunidade) e dados em evolução. O eDSR atua como lógica organizadora: decompõe o trabalho em echelons e exige um artefato validado por fase (p.ex., *problem statement* em E1; DO/DRs em E2; blueprint técnico e *decision log* em E3), criando linha de rastreamento entre requisito, decisão e evidência (TUUNANEN; GHANBARI; KAZAN, 2024). Assim, requisitos de negócio e restrições de custo/licença tornam-se escolhas de arquitetura auditáveis.

2.2.3.0.2 Visibilidade de mitigação de risco e eficiência técnica.

Em LLMs de nicho, decisões modulares surgem no meio do projeto para mitigar riscos e otimizar custo. No Gaia, o CPT intensivo em PT-BR é necessário para especialização, mas abre o risco de *catastrophic forgetting*; a opção por *Instruction Residuals* (IR) fornece restauração instrucional eficiente (JINDAL; AL., 2024). O eDSR eleva essa escolha a artefato de design em E3 (com racionalidade e evidência), em vez de deixá-la como “detalhe de model card”, permitindo sua abstração em Princípio de Design (TUUNANEN; GHANBARI; KAZAN, 2024).

2.2.3.0.3 Alinhamento com o estado da arte em IA aplicada.

A literatura recente tem adotado abordagens de DSR estruturadas por etapas para domínios adjacentes à GenAI, reforçando a relevância do eDSR. Em gêmeos digitais com GenAI, por exemplo, Mata et al. (2025) propõem um framework que integra métodos multicritério e conhecimento humano para seleção de arquiteturas, destacando a falta de metodologia padronizada e a necessidade de um processo documentado e adaptável — cenário em que a decomposição por echelon e a validação faseada são úteis.

eDSR acoplado ao FEDS

O eDSR indica *quando* validar; *como* validar é estruturado pelo FEDS, que classifica episódios de avaliação por propósito (formativo vs. somativo) e paradigma (artificial vs. naturalístico) (VENABLE; PRIES-HEJE; BASKERVILLE, 2016). No caso do Gaia, isso diferencia:

- **E4/PoC** → avaliações formativas–artificiais (benchmarks, ablações, eficácia técnica);
- **E5/PoV** → avaliações somativas–naturalísticas (utilidade percebida por stakeholders; feedback e realimentação para E2/E3).

O eDSR fornece a estrutura para transformar o estudo do Gaia de um relato descritivo em um DSR retrospectivo-analítico, com rastreabilidade completa e capacidade de generalização em forma de Princípios de Design (HEVNER et al., 2004; TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

3 Design da Pesquisa (Research Design)

Este capítulo explicita como a investigação foi operacionalizada para tornar observável o processo de design do Projeto Gaia. Enquanto o Capítulo 2 estabeleceu o enquadramento teórico — a lacuna de domínio (LLMs em PT-BR aquém em geração) e a lacuna metodológica (opacidade do processo) — aqui definimos fontes, ordem, instrumentos e regras de análise que encaixam as evidências nos cinco echelons do eDSR (GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024).

3.0.1 Adoção do framework eDSR como processo de pesquisa

Este capítulo explicita como a investigação foi operacionalizada para tornar observável o processo de design do Projeto Gaia. Enquanto o Capítulo 2 estabeleceu o enquadramento teórico — a lacuna de domínio (LLMs em PT-BR aquém em geração) e a lacuna metodológica (opacidade do processo) — aqui definimos fontes, ordem, instrumentos e regras de análise que encaixam as evidências nos cinco echelons do eDSR (GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024).

Adota-se um estudo de caso qualitativo, analítico, estruturado pelo *Echeloned Design Science Research* (eDSR), guiado por três premissas:

1. **Coerência metodológica.** Como o objeto (Gaia) é um projeto não linear e multis-takeholder, a própria pesquisa espelha essa lógica: o eDSR funciona simultaneamente como lente de análise e roteiro de condução. Cada evidência coletada é posicionada no echelon correspondente, preservando alinhamento entre prática empírica e processo de design (TUUNANEN; GHANBARI; KAZAN, 2024).
2. **Rastreabilidade.** O objetivo é produzir Princípios de Design (DPs) e uma teoria de médio alcance. Para legitimar esses produtos, cada decisão discutida no Cap. 5 deve poder ser traçada até: (i) um excerto de entrevista; (ii) um documento público do Gaia; ou (iii) um artefato intermediário da Tabela Mestra de Echelons (GREGOR; HEVNER, 2013).
3. **Triangulação.** Para abrir a “caixa-preta” do design, combinam-se três fontes: (i) literatura/pilares; (ii) documentação pública do projeto; e (iii) entrevistas semi-estruturadas com participantes-chave. A triangulação está acoplada ao FEDS: resultados de PoC (formativos/artificiais) e PoV (somativos/naturalísticos) são distinguidos e utilizados para preencher lacunas por echelon (GREGOR; HEVNER, 2013; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Em síntese, esta seção não apenas lista técnicas de coleta: ela delinea um plano compatível com a complexidade e a não linearidade do caso. A análise é dirigida pelos echelons (E1–E5) e utiliza a Tabela Mestre como artefato de controle para mapear o que já se sabe (público/literatura) e o que falta (racionalidades e ordem das decisões).

A Tabela-ponte abaixo organiza o plano de validação por echelon do eDSR, indicando, para cada unidade de trabalho, qual artefato deve ser produzido, de onde virá a evidência e como será avaliado segundo o FEDS (formativa/somativa $\times$ artificial/naturalística). Com isso, garante-se rastreabilidade entre decisão de design e evidência empírica, preparando o terreno para os Capítulos 4 e 5 (TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Tabela 5 – Ponte de validação por echelon (eDSR + FEDS) para o Projeto Gaia

Echelon	Artefato esperado	Fonte de evidência	Estratégia FEDS	Critério de sucesso
E1 (Problema)	Declaração validada do problema e domínio	Literatura, documentos públicos, entrevistas	Formativa $\times$ Naturalística	Convergência entre fontes e clareza do problema
E2 (Requisitos)	DO/DRs priorizados + rastreabilidade	Documentação pública, entrevistas, Tabela Mestre	Formativa $\times$ Naturalística	Compleitude, coerência e ancoragem em E1
E3 (Design)	Blueprint técnico + registro de decisões (DDR)	Documentação técnica, entrevistas, logs de decisão	Formativa $\times$ Artificial	Justificativa explícita para cada decisão crítica
E4 (PoC)	Resultados de benchmarks e testes controlados	Model cards, relatórios técnicos, ablações	Formativa $\times$ Artificial	Evidência de eficácia técnica frente aos DRs
E5 (PoV)	Evidências de valor em uso real	Entrevistas, relatos de stakeholders, métricas	Somativa $\times$ Naturalística	Demonstração de utilidade e retorno a requisitos

Fonte: Adaptado de Tuunanen, Ghanbari e Kazan (2024) e Venable, Pries-Heje e Baskerville (2016).

A partir desta Tabela-ponte, cada evidência coletada será mapeada para seu respectivo echelon e, em seguida, transcrita na Tabela Mestre de Echelons (v1.7) com status (*confirmado/parcial/refutado/novo*). No Cap. 4, esse mapeamento sustenta a reconstituição do caso Gaia; no Cap. 5, permite trilhar cada Princípio de Design (DP) até suas fontes (entrevista, documento público ou Pilar), mantendo o alinhamento eDSR e a distinção FEDS entre PoC (eficácia técnica) e PoV (utilidade em uso) (TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

3.0.2 Rastreando a Complexidade Técnica (CPT + Instruction Residuals)

A adoção do eDSR se justifica pela necessidade de tornar visíveis decisões de mitigação de risco e de eficiência que ocorrem no meio do design, algo típico em projetos de IA generativa com múltiplas partes móveis (dados, arquitetura, custos, stakeholders) (TUUNANEN; GHANBARI; KAZAN, 2024). No Projeto Gaia, essa dinâmica aparece de modo exemplar no pipeline de especialização linguística:

- **Risco e necessidade (E2 → requisitos de design).** O projeto demanda *Continuous Pre-Training* (CPT) intensivo em PT-BR para ampliar repertório lexical e estilístico. Contudo, aplicar CPT diretamente sobre um modelo já instruído degrada as capacidades de seguir instruções (*catastrophic forgetting*), configurando um risco técnico explícito que precisa ser tratado como requisito (“preservar instrução” sob restrição de custo) (JINDAL; AL., 2024).
- **Decisão modular (E3 → design e desenvolvimento).** A resposta de engenharia adotada foi *Instruction Residuals* (IR), solução paramétrica e eficiente que calcula o resíduo instrucional como diferença de pesos entre o modelo instruído e o modelo base ($\nabla\Theta = \Theta_{\text{instr}} - \Theta_{\text{base}}$) e o soma ao modelo após o CPT, restaurando a capacidade instrucional sem um *instruction fine-tuning* completo (JINDAL; AL., 2024).
- **Rastreabilidade e validação (E4/E5 → FEDS).** No Echelon 4 (PoC), a decisão é avaliada de forma formativa e em paradigma artificial (ablação Setting 1 vs Setting 2; métricas como **IFEval**), mostrando queda de desempenho quando se faz CPT no instruído e estabilidade/ganhos quando se faz CPT no base + IR (JINDAL; AL., 2024). No Echelon 5 (PoV), a utilidade é avaliada de forma somativa/naturalística junto a stakeholders, conforme o FEDS (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).


Para tornar explícitas as escolhas sob incerteza no Echelon 3, registramos as Assunções de Design como *Design Decision Records* (DDRs). A seguir, o DDR do caso CPT no modelo-base + IR.

Assunções confirmadas em E4/E5 tornam-se candidatas a Princípios de Design (DPs); se refutadas, retornam ao E2 para revisão de requisitos.

3.0.3 Acoplamento com o FEDS para Validação Formativa e Somativa

Como o eDSR indica *quando* cada artefato intermediário deve ser validado, mas não *como*, esta pesquisa o acopla ao *Framework for Evaluation in Design Science* (FEDS), que organiza os episódios de avaliação em duas dimensões ortogonais (VENABLE; PRIES-HEJE; BASKERVILLE, 2016):

Figura 6 – Fluxo de Rastreamento da Complexidade Técnica no eDSR (Caso Gaia: CPT + Instruction Residuals)



Fonte: Elaboração própria. E3 responde a risco (E2) e é validado tecnicamente (E4) e socialmente (E5).

- (i) **Propósito funcional** — formativa (para melhorar) vs. somativa (para julgar);
- (ii) **Paradigma de avaliação** — artificial (ambientes controlados, como laboratórios e *benchmarks*) vs. naturalística (contextos reais de uso).

Essa distinção é crucial para LLMs em PT-BR, pois as avaliações do Projeto Gaia se distribuem de forma planejada pelos echelons:

- **Echelon 4 (Prova de Conceito — PoC):** avaliações formativas/artificiais que demonstram eficácia técnica em ambiente controlado — por exemplo, ablação CPT no *base* + IR vs. CPT no instruído, métricas padronizadas e *benchmarks* (como o ENEM 2024) para evidenciar ganhos ou perdas sob hipóteses de design específicas (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).
- **Echelon 5 (Prova de Valor — PoV):** avaliações somativas/naturalísticas que aferem utilidade no mundo real — por exemplo, feedback de *stakeholders* (órgãos públicos e parceiros), estudos de adoção, análise de *logs* e julgamentos humanos situados no contexto de uso (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Tabela 6 – Exemplo de Registro de Decisão de Design (DDR)

Campo	Conteúdo
DDR-ID	DDR-E3-CPT+IR-v1
Echelon	E3 – Design & Desenvolvimento
Enunciado	Executar CPT em PT-BR no modelo base e restaurar a instrução utilizando Instruction Residuals (IR).
Racionalidade	Mitigar <i>catastrophic forgetting</i> , garantir eficiência paramétrica e assegurar portabilidade do resíduo (JINDAL; AL., 2024).
Evidência	Setting 1 (queda) vs. Setting 2 (restauração); custo computacional muito inferior ao de um FT instrucional completo.
Plano FEDS	E4-PoC: formativa/artificial (IFEval). E5-PoV: somativa/naturalística (feedback de stakeholders).
Critérios de Sucesso	(a) Não-inferioridade vs. baseline; (b) ganhos em PT-BR; (c) custo < limite definido.

Fonte: Elaboração própria com base em Jindal et al. (2024) e no framework eDSR.

Ao amarrar cada tipo de avaliação ao seu echelon, o estudo evita a armadilha de “avaliar tudo no final” e registra ciclos explícitos de realimentação: resultados de PoC (E4) podem retroalimentar E2/E3 para refinar requisitos e decisões; evidências de PoV (E5) consolidam ou tensionam Princípios de Design antes da generalização. Esse encadeamento claro entre dado, artefato intermediário e princípio sustenta a rastreabilidade requerida em DSR e eleva o trabalho ao padrão de tese de alto rigor (VENABLE; PRIES-HEJE; BASKERVILLE, 2016; TUUNANEN; GHANBARI; KAZAN, 2024).

Para evitar concentrar toda a avaliação ao final do ciclo, acoplamos o eDSR ao FEDS, distribuindo episódios formativos e somativos entre contextos artificiais e naturalísticos, como sintetizado na matriz a seguir, que ilustra exemplos do Projeto Gaia mapeados por echelon.

3.1 Procedimento de Derivação dos Princípios de Design (DPs)

Esta subseção explicita como os Princípios de Design serão obtidos a partir das evidências coletadas, preservando a rastreabilidade e o acoplamento eDSR↔FEDS. O procedimento ocorre em três passos encadeados.

Passo 1 — Extração (por echelon E1–E5)

Para cada evidência confirmada (entrevista ou documento), registram-se *frases de design* que descrevem uma decisão, condição ou mecanismo observável. Cada frase é acompanhada de metadados mínimos:

- Echelon (E#);

Tabela 7 – Matriz FEDS (Formativa/Somativa × Artificial/Naturalística) com exemplos do Projeto Gaia mapeados por echelon

	Artificial	Naturalística
Formativa (para melhorar)	E4 PoC — Formativa/Artificial • <i>Benchmarks</i> controlados (ex.: ENEM 2024) • Ablações CPT no <i>base</i> + IR vs. CPT no instruído • Métricas: IFEval, NILC-Metrix, ROUGE/BERTScore em <i>runs</i> de desenvolvimento	E4→E5 — Formativa/Naturalística • Pilotos com <i>stakeholders</i> (walkthroughs guiados) • <i>Prompt audits</i> e tarefas-sentinela em contexto de uso • Feedback inicial para ajustar requisitos (retorno a E2/E3)
Somativa (para julgar)	E4 (tardio) — Somativa/Artificial • Bateria comparativa com a “fauna” PT-BR (sumarização, simplificação, QA) • Protocolo fixo de eficiência (tempo/energia/CO₂) • Relato consolidado de desempenho em laboratório	E5 PoV — Somativa/Naturalística • Evidência de utilidade em uso real (órgãos públicos, empresas parceiras) • Medidas de valor: acurácia de tarefa, tempo, satisfação, aderência cultural • Geração de novas demandas e re-alimentação formal para E2/E3

Fonte: Elaboração própria, com base em Venable, Pries-Heje e Baskerville (2016) e Tuunanen, Ghanbari e Kazan (2024). O eDSR torna explícito “quando” validar (E1–E5), enquanto o FEDS estrutura “como” avaliar ao longo do ciclo, distinguindo evidência técnica (PoC) de evidência de valor (PoV).

- Fonte (entrevista X; doc Y);
- Ponteiro (link, ID ou commit);
- Tipologia FEDS do episódio (Formativa/Somativa × Artificial/Naturalística);
- Referência ao DDR correspondente (quando aplicável, em E3).

Passo 2 — Abstração (mecanismos/heurísticas)

As frases de design são organizadas em grupos por mecanismo subjacente ou heurística de projeto (ex.: “CPT no *base* induz esquecimento; IR restaura instrução com custo marginal”). Duplicatas são consolidadas; inconsistências são marcadas. Cada grupo é verificado:

- contra os DRs de E2 (coerência e cobertura);
- contra a Tabela-Ponte DO/DR↔Echelon (integridade analítica).

Passo 3 — Formulação do DP (formato Gregor & Hevner)

Cada grupo abstrato é convertido em DP no formato canônico:

Tabela 8 – Definição do Princípio de Design (DP)

Campo	Descrição
Enunciado	Para C (contextos), quando P (problema), designers devem A (ação) para produzir E (efeito).
Mecanismo	Explica por que $A \rightarrow E$ (ligação causal técnica/organizacional).
Boundary	Limites e pré-requisitos (dados, hardware, licenças).
Trade-offs	Riscos e custos associados.
Evidências	(E#, fonte, FEDS, DDR/commit).
Status	Confirmado / Parcial / Em validação.

Fonte: Elaboração própria.

Tabela 9 – Princípio de Design DP-CPT-IR-01

Campo	Conteúdo
Enunciado	Para LLMs de nicho em PT-BR (C), quando CPT no modelo-base for necessário e houver risco de esquecimento instrucional (P), designers devem aplicar Instruction Residuals derivados do modelo instruído original (A) para recuperar <i>instruction-following</i> com custo marginal reduzido (E).
Mecanismo	Soma do resíduo paramétrico $\Theta_{\text{res}} = \Theta_{\text{instr}} - \Theta_{\text{base}}$ sobre o modelo após o CPT.
Boundary	Requer acesso ao modelo instruído original e compatibilidade arquitetural para derivar o resíduo.
Trade-offs	Pequena sobreposição paramétrica e necessidade de verificação de estabilidade pós-CPT.
Evidências	DDR-CPT-IR-01 (E3); IFEval/ENEM 2024 (E4); entrevistas e PoV (E5).
Status	Validado.

Fonte: Elaboração própria.

Critério de promoção a DP

Uma proposição só é promovida a DP se satisfizer simultaneamente:

- (i) convergência mínima entre entrevista + documento (ou múltiplas fontes independentes);
- (ii) consistência com os DRs validados em E2;
- (iii) mecanismo causal explicitado;
- (iv) reprodutibilidade razoável (ponteiros claros para evidência e DDR).

Proposições sem convergência suficiente permanecem como *achados tentativos*.

Rastreabilidade e Produto Final

Cada DP publicado no Capítulo 5 trará, ao final, uma linha “**Evidências**” com ponteiros para E#, tipologia FEDS, DDRs e documentos. Assim, preserva-se o encadeamento completo:

Dado → Frase de Design → Mecanismo → DP

3.2 Tabela Mestra: Mapeamento do Projeto como Plano de Pesquisa

Diante do caráter incompleto e majoritariamente descritivo das fontes públicas sobre o Projeto Gaia, esta pesquisa emprega um artefato de organização e controle que torna observável o percurso do design: a **Tabela Mestra de Echelons**. Ela materializa a lógica do eDSR, posicionando evidências e perguntas nos respectivos echelons (E1–E5) e preservando a rastreabilidade entre decisão técnica, racionalidade e avaliação (TUUNANEN; GHANBARI; KAZAN, 2024).

3.2.1 Funções da Tabela Mestra

- **Plano de pesquisa.** Para cada echelon do eDSR (E1–E5), a tabela indica o que já pode ser preenchido com evidências documentais (literatura revisada e documentação pública) e o que depende de dado primário, a ser obtido por entrevistas semiestruturadas com participantes-chave (HEVNER et al., 2004; GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024).
- **Mecanismo de rastreabilidade de design.** A Tabela Mestra permite seguir uma decisão específica até o echelon em que sua racionalidade foi definida e até o tipo de avaliação empregado (formativa/somativa; artificial/naturalística). Isso assegura que os Princípios de Design (Cap. 5) sejam traçáveis até suas evidências e artefatos intermediários (GREGOR; HEVNER, 2013; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

3.2.2 Estrutura e Componentes

A tabela está organizada em três colunas que, em conjunto, estruturam o roteiro da investigação:

1. **Echelon eDSR (tipo).** Cinco unidades de trabalho que decompõem o processo sociotécnico:

- E1 – Problema: diagnóstico da lacuna de domínio (LLMs PT-BR aquém em geração).
- E2 – Requisitos: objetivos e requisitos de design (DOs/DRs).
- E3 – Design & Desenvolvimento: decisões técnicas (arquitetura, dados, eficiência; ex.: CPT + IR).
- E4 – PoC: avaliações formativas/artificiais (benchmarks).
- E5 – PoV: avaliações somativas/naturalísticas (valor percebido em uso real).

(TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

2. **O que JÁ SABEMOS (fatos públicos / pilares).** Consolida o Conhecimento Justificatório (literatura + documentos públicos):

- **Domínio:** lacuna generativa em PT-BR; gargalo de dados mitigado (Jabuticaba >139B tokens).
- **Técnico:** base Gemma 3; CPT ~13B tokens; adoção de Instruction Residuals (IR).
- **Avaliação:** registros de PoC (benchmarks) e PoV (parceiros/órgãos).

(SCOTTI; CRUZ-CASTAÑEDA; AMADEUS, 2025; JINDAL; AL., 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

3. **O que FALTA (foco da entrevista).** Roteiro para capturar racionalidades omitidas:

- **Motivação (“porquê”):** por que IR? quais restrições de custo? qual trigger de E1?
- **Sequência (“ordem”):** o ENEM foi usado como PoC formativa ou apenas somativa? PoV gerou feedback de retorno para E2/E3?

(TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Nota metodológica: A coluna “O que FALTA” não é um achado, mas um programa de coleta derivado do gap metodológico. Será preenchida/validada por entrevistas e pelo Formulário Híbrido (v3.0).

Tabela 10 – Tabela-Mestra eDSR (E1 — Análise do Problema)

Componente	Descrição
Artefato	Problem Statement validado.
Já sabemos	Literatura e docs públicos convergem para a existência de lacuna generativa em PT-BR.
Falta	Trigger inicial do projeto; metas preliminares; constraints de negócio.
Evidência-alvo	Entrevistas, minutas e apresentações internas.
FEDS	Formativa × Naturalística.
Status	Parcial.

Fonte: Elaboração própria.

Tabela 11 – Tabela-Mestra eDSR (E2 — Objetivos & Requisitos)

Componente	Descrição
Artefato	DO/DRs priorizados e validados.
Já sabemos	DRs hipotéticos (Tabela 2 v0.3); justificativa técnica preliminar.
Falta	Prioridades reais; métricas-alvo; restrições de custo/infraestrutura.
Evidência-alvo	Workshops, validações cruzadas de requisitos.
FEDS	Formativa × Naturalística.
Status	Em aberto.

Fonte: Elaboração própria.

Tabela 12 – Tabela-Mestra eDSR (E3 — Design & Desenvolvimento)

Componente	Descrição
Artefato	Blueprint técnico + DDRs (CPT + IR).
Já sabemos	Base: Gemma 3; CPT (~13B); decisão por IR; Jabuticaba (>139B).
Falta	Sequência da decisão; porquês; critérios; fallback técnico.
Evidência-alvo	DDRs, commit logs, ablações.
FEDS	Formativa × Artificial.
Status	Parcial.

Fonte: Elaboração própria.

3.2.3 Procedimento de Uso e Governança

A cada entrevista ou triangulação documental, os itens de “O que FALTA” recebem um status: *confirmado*, *parcialmente confirmado (ordem distinta)*, *não confirmado* ou *novo*. A tabela é versionada (v1.8, v1.9...) e as alterações são refletidas:

- nas tabelas de E2 (requisitos);
- nas tabelas de E3 (decisões de design);

Tabela 13 – Tabela-Mestra eDSR (E4 — Demonstração / PoC)

Componente	Descrição
Artefato	PoC validada.
Já sabemos	ENEM 2024 (0,7000 vs. 0,6556).
Falta	Foi formativo ou somativo? Existiram PoCs internos?
Evidência-alvo	Scripts, planilhas, relatos cronológicos.
FEDS	Formativa $\times$ Artificial <i>ou</i> Somativa $\times$ Artificial.
Status	Parcial.

Fonte: Elaboração própria.

Tabela 14 – Tabela-Mestra eDSR (E5 — Avaliação / PoV)

Componente	Descrição
Artefato	PoV validada.
Já sabemos	Adoção por stakeholders (TCM-GO, TCE-GO, Unimed).
Falta	Valor percebido por tarefa; evidências por contexto.
Evidência-alvo	Entrevistas, logs de uso e feedbacks.
FEDS	Somativa $\times$ Naturalística.
Status	Em aberto.

Fonte: Elaboração própria.

- nos episódios de E4/E5 conforme a tipologia FEDS.

Assim, a Tabela Mestra (v1.7) deixa de ser um quadro descritivo e torna-se um artefato de **controle metodológico**: ela guia a coleta, ancora a análise do Capítulo 4 no eDSR e viabiliza a derivação transparente de Princípios de Design no Capítulo 5 (GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

3.3 Fontes e Métodos: A Estratégia de Triangulação

Para reconstituir o processo de design do Projeto Gaia *echelon por echelon* no Capítulo 4, adotamos uma estratégia de triangulação em três camadas, desenhada para: (i) mitigar a “caixa-preta” típica de projetos de IA (escassez de documentação de processo) e (ii) assegurar que cada Princípio de Design (DP) seja rastreável até evidências concretas (LIPTON; STEINHARDT, 2019; GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024).

A coleta e a extração seguem boas práticas de revisão sistemática em Engenharia de Software (strings, critérios de inclusão/exclusão, *snowballing*, formulários) (KITCHE-

NHAM; CHARTERS, 2007), acopladas à lógica eDSR/FEDS para posicionamento por echelon e qualificação das avaliações (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Regra operacional de confirmação. Afirmações sobre motivações internas ou ordem temporal de decisões (itens da coluna “O que FALTA” da Tabela Mestra) só são consideradas confirmadas quando há convergência entre: (a) uma fonte primária (entrevista), e (b) uma fonte documental (literatura revisada ou documentação pública). Na ausência de convergência, o item permanece tentativo e não fundamenta DPs.

Registro operacional de avaliação e rastreio. Cada episódio de avaliação é registrado em uma Matriz FEDS contendo: propósito (Formativa/Somativa), paradigma (Artificial/Naturalística), tarefa/benchmark, métrica, decisão, e E#. Em paralelo, decisões confirmadas alimentam a Tabela-Ponte DO/DR↔Echelon, garantindo rastreabilidade completa até os DPs do Capítulo 5.

3.3.1 Camada 1 — Literatura acadêmica (“Pilares”)

O objetivo é consolidar o Conhecimento Justificatório sobre: (a) LLMs multilíngues/pt-BR (desempenho, assimetrias, especialização), e (b) DSR/eDSR/FEDS (fundamentos, avaliação, geração de teoria).

Procedimento:

- **Busca dirigida:** bases indexadas; strings combinando “LLM”, “Portuguese”, “multilingual”, “DSR”, “eDSR”, “design evaluation” (KITCHENHAM; CHARTERS, 2007).
- **Inclusão/Exclusão:** (i) peer-reviewed ou preprints amplamente citados; (ii) recorte temporal recente para LLMs; (iii) clássicos de DSR.
- **Extração:** formulário com tema central, achado, figuras/dados, relação com echelons/FEDS e lacunas cobertas pela tese.

Uso no eDSR. Evidências são posicionadas em E1–E3 (problema, requisitos, design) e, quando aplicável, em E4–E5 (tipologia de avaliações), com o FEDS qualificando formativa/somativa e artificial/naturalística (HEVNER et al., 2004; GREGOR; HEVNER, 2013; VENABLE; PRIES-HEJE; BASKERVILLE, 2016; TUUNANEN; GHANBARI; KAZAN, 2024).

3.3.2 Camada 2 — Documentação pública do caso (Gaia)

O objetivo é capturar o estado descritivo do projeto (arquitetura, dados, pipelines, benchmarks, parcerias) para preencher o “O que JÁ SABEMOS” da Tabela Mestra.

Fontes típicas: *model cards*, repositórios (código/pesos), descrições de corpus (ex.: Jabuticaba), blogs técnicos, comunicados institucionais.

Critérios de qualidade:

- **Coerência cruzada:** mesma informação deve aparecer em ≥ 2 documentos independentes.
- **Versionamento e changelogs:** usados para reconstruir ordem temporal.
- **Cautela com *grey literature*:** toda inferência de racionalidade permanece hipótese até validação.

Uso no eDSR. Povoia E3–E4 (design e demonstrações) e gera ganchos de entrevista para E1–E2 (motivações, restrições) e E5 (adoção real).

3.3.3 Camada 3 — Entrevistas semiestruturadas (stakeholders)

O objetivo é tornar explícitas as racionalidades de design — motivação e ordem das decisões — ausentes na documentação pública. A amostragem focaliza papéis-chave do consórcio (coordenação científica, curadoria de dados, training/infra, MLOps, produto/parcerias).

Instrumento: Roteiro semiestruturado ancorado no eDSR (E1→E5), com questões que exploram:

- motivações, trade-offs e alternativas descartadas;
- marcação temporal de decisões;
- classificação FEDS de episódios avaliativos.

Rigor procedural:

- consentimento informado e gravação;
- transcrição e análise temática dirigida por echelons;
- trilha de auditoria e *member check* quando aplicável.

3.3.4 Encadeamento analítico e rastreabilidade

Após a coleta, cada evidência — documental ou entrevista — é anotada com seu E# e, quando aplicável, sua tipologia FEDS. Um item de “O que FALTA” só é promovido a *confirmado* quando há convergência mínima entre fonte primária e documental.

Divergências são classificadas como: *parcial* (ordem distinta), ou *não confirmado*.

Apenas itens confirmados integram a base justificatória para os DPs do Capítulo 5, mantendo a cadeia de evidência (HEVNER et al., 2004; GREGOR; HEVNER, 2013).

3.3.5 Mitigação de vieses e governança dos dados

Para mitigar vieses de recordação/atribuição, relatos são confrontados com documentação versionada. Incertezas persistentes são marcadas explicitamente no corpus.

A Tabela Mestra é *time-stamped* e versionada (v1.7→v1.8...), com registro de *diffs* que preservam a historicidade.

A governança de dados segue princípios de ética e confidencialidade:

- anonimização de trechos sensíveis;
- armazenamento com controle de acesso;
- permissões de uso documentadas.

4 Visão Geral do Método de Análise

Este capítulo reconstitui o processo de design do Projeto Gaia ao longo dos cinco echelons do eDSR e tipa cada episódio de avaliação segundo o FEDS (TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016). O corpus integra três frentes: (i) literatura e pilares de referência, (ii) documentação pública do projeto, e (iii) entrevistas do Formulário v3.0.

O propósito não é recontar fatos, mas explicitar *como* decisões de design foram tomadas, validadas e encadeadas ao longo do projeto.

Toda evidência é registrada na Tabela-Ponte DO/DR↔Echelon com três marcações mínimas: (a) o echelon correspondente (E1–E5), (b) a natureza do item (decisão de design, episódio de avaliação ou artefato intermediário), e (c) quando aplicável, a tipagem FEDS (formativa/somativa; artificial/naturalística).

Para decisões sob incerteza empregamos *Design Decision Records* (DDRs) — enunciado curto, racionalidade, momento aproximado, ponteiros de fonte e critério de sucesso/*fallback* — de modo que escolhas como *CPT* → *IR* sejam tratadas como decisões de design, e não como meros detalhes de implementação (KUECHLER; VAISHNAVI, 2012).

A regra de evidência é conservadora: um item só migra de *hipótese* a *confirmado* mediante convergência entre entrevista e documento (ou entre múltiplos documentos independentes). Itens sem lastro suficiente permanecem *parciais* e são remetidos ao echelon responsável (p.ex., revisão de requisitos em E2).

Quando um conjunto de decisões apresenta estabilidade empírica e condições de aplicação claras, formulamos Princípios de Design no formato de Gregor e Hevner (2013) — “para contextos do tipo C, quando ocorrer P, designers devem executar A para obter E” — preservando ponteiros de evidência e *boundary conditions*.

As seções 4.1–4.5 seguem a mesma cadência: para cada echelon, indicamos o que foi confirmado, o que permanece em aberto, como foi avaliado no sentido FEDS e como alimenta candidatos a DPs. Assim, fechamos o ciclo entre narrativa empírica e construção teórica, assegurando rastreabilidade completa do dado à proposição de design.

4.1 Echelon 1: Diagnóstico do Problema

A primeira etapa do ciclo eDSR, o Echelon de Análise do Problema, tem como objetivo produzir uma *Declaração do Problema Validada* (*Validated Problem Statement*) que guie o restante do projeto. Para o Projeto Gaia, a validação deste echelon ocorreu em dois níveis: uma validação técnica baseada na literatura (Fase 1) e uma validação motivacional baseada na triangulação com dados primários (Fase 2).

4.1.1 O Problema Técnico: A Lacuna de Geração em PT-BR

A literatura especializada caracteriza uma assimetria estruturante: embora o PT-BR disponha de grandes corpora (p.ex., Jabuticaba, ~139B tokens), persiste um déficit em tarefas generativas (NLG) e escassez relativa de arquiteturas *decoder-only* otimizadas para o idioma. As entrevistas corroboram integralmente esse diagnóstico: ao avaliar o objetivo de “resolver a lacuna de performance de LLMs SOTA em PT-BR”, o participante atribuiu concordância máxima (5/5), destacando falhas recorrentes de registro e sensibilidade cultural mesmo em modelos multilíngues robustos. Com isso, o **DO1** fica validado como razão de ser técnica do projeto.

4.1.2 O Gatilho de Negócio: Um Alinhamento Sociotécnico

A documentação pública não explicitava um “dono” único do problema. A apuração com stakeholders indica que o gatilho foi uma composição de interesses (acadêmicos, industriais e comunitários), e não uma demanda comercial isolada. Esse arranjo explica a opção por um artefato aberto e justifica a complexidade de governança — características típicas de projetos multistakeholder que o eDSR modela com precisão.

4.1.3 Artefato Gerado: Declaração do Problema Validada

A síntese das Fases 1 e 2 permite formular a Declaração do Problema que orientou os echelons subsequentes:

“Existe uma lacuna persistente na capacidade de geração de texto (NLG) com sensibilidade cultural em PT-BR nos LLMs globais, que não pode ser resolvida apenas com mais dados, exigindo uma intervenção de design na arquitetura do modelo. A solução para este problema técnico requer um arranjo colaborativo capaz de alinhar interesses acadêmicos e industriais para produzir um artefato de base (*foundation model*) acessível, visando a soberania tecnológica e a redução da dependência de modelos genéricos estrangeiros.”

Há convergência entre (i) literatura e mapeamentos que evidenciam a lacuna generativa e (ii) dado primário confirmando o DO1 e esclarecendo o gatilho como composição sociotécnica. Este fechamento cumpre a regra de evidência e habilita o avanço para o Echelon 2 (Requisitos).

4.2 Echelon 2: Objetivos e Requisitos

O Echelon 2 do framework eDSR tem como propósito converter a “Declaração do Problema” (E1) em um conjunto de Objetivos de Design (DOs) e Requisitos de Design

Tabela 15 – Mapeamento do Echelon 1 (Diagnóstico do Problema)

Componente	Descrição e Achados do Caso Gaia	Status de Validação & Fonte
1. O Problema Técnico	Descrição: Déficit generativo em PT-BR apesar de grandes corpora (Jabuticaba). Achado: Problema não é falta de dados, mas baixa sensibilidade cultural dos modelos globais.	VALIDADO (Triangulação) Literatura: pilares e surveys recentes. Entrevista: concordância máxima (5/5) com o DO1.
2. O Gatilho de Negócio	Descrição: Ausência de um “dono” único; motivação distribuída. Achado: Projeto nasce de alinhamento sociotécnico entre academia, indústria e comunidade.	VALIDADO Entrevista: nega motivação comercial isolada. Documentos: parceiros diversos reforçam o caráter colaborativo.
3. Artefato Gerado	Declaração do Problema Validada que consolida lacuna técnica + gatilho sociotécnico.	Consolidado a partir de (1) e (2).

Fonte: Elaboração própria.

(DRs) que orientarão a construção do artefato. O artefato intermediário desta fase é o conjunto de **Requisitos de Design Validados**.

A triangulação entre literatura técnica e dado primário confirmou que o Projeto Gaia hierarquizou requisitos: **eficácia como cláusula pétrea** e **eficiência como parâmetro ajustável** (HEVNER et al., 2004; PEFERS et al., 2007; TUUNANEN; GHANBARI; KAZAN, 2024).

A Tabela 16 apresenta a consolidação final desses requisitos, confrontando a hipótese inicial com a validação empírica.

4.2.1 Prioridades Inflexíveis: O Imperativo da Eficácia

DO1/DR1 — Desempenho SOTA em benchmark de alta complexidade [confirmado, 5/5]. O alcance/superação do estado da arte — com destaque para o ENEM — não foi métrica *ex post*, mas condição de existência do projeto. Isso reforça o vínculo com E1: um LLM de nicho só seria relevante se demonstrasse capacidade generativa competitiva em PT-BR.

DO2/DR4 — Arquitetura de geração (decoder-only, família Gemma) [confirmado, 5/5]. A opção por decoders foi estratégica: direcionar esforços para a lacuna de NLG ainda pouco explorada no ecossistema PT-BR.

Tabela 16 – Mapeamento de Objetivos (DO) e Requisitos (DR) do Echelon 2

Objetivo de Design (DO)	Requisitos de Design (DRs)	Conhecimento Justificativo
	DR1. O artefato deve atingir (ou superar) o desempenho SOTA em benchmarks de alta complexidade em PT-BR (p.ex., ENEM).	Lacuna generativa amplamente registrada; necessidade de meta explícita.
	DR2. Treinar em dataset massivo e majoritariamente em PT-BR ($\geq 10B$ tokens).	Jabuticaba mostra que o gargalo não é o volume bruto, mas seu uso adequado.
	DR3. Avaliação deve incluir tarefas sensíveis ao registro cultural brasileiro.	Quedas mais acentuadas aparecem em NLG culturalmente marcada.
	DR4. Adotar arquitetura decoder-only para ocupar espaço pouco atendido de tarefas generativas.	Falta de decoders eficientes no ecossistema PT-BR.
	DR5. Aplicar continuous pre-training seguido de restauração de instrução.	Estratégia de especialização sem treinar do zero.
	DR6. Otimizar design para infraestrutura disponível (H100s).	Viabilidade computacional é condição de design pragmático.
	DR7. Disponibilizar família de tamanhos (4B, 13B).	Permite trade-off entre performance e custo.
	DR8. Lançar como open-source/open-weight.	Democratização do ecossistema PT-BR.
	DR9. Publicação e documentação em repositório público.	Transparência e difusão dos artefatos.

DO4. Promover a adoção pela comunidade.

Fonte: Elaboração própria.

Tabela 17 – Matriz de Priorização e Validação dos Requisitos (Efficacy vs. Efficiency)

Requisito	Prioridade	Foco	Conclusão da Validação
DO1/DR1 (SOTA/ENEM)	5/5	Eficácia	Requisito central; define sucesso em E4.
DR4 (Decoder-only)	5/5	Eficácia	Decisão estratégica: ocupar lacuna de arquitetura.
DO3 (Viabilidade)	2/5	Eficiência	Ajustável; não determinou limite superior de qualidade.

Fonte: Elaboração própria com base nas entrevistas.

4.2.2 Parâmetros Ajustáveis: A Flexibilização da Eficiência

DO3 — Viabilidade/eficiência de treino e operação [parcial, 2/5]. A infraestrutura disponível (H100s) foi um limite real, mas não um limitador da ambição técnica. O tamanho do modelo (4B/13B) e o volume de dados foram ajustados dinamicamente para otimizar performance e estabilidade.

DR2 — Volume de dados (Jabuticaba integral $\rightarrow$ subset $\sim 13B$) [confirmado]. A redução foi guiada por testes de estabilidade e curadoria, não por orçamento. Antecipação direta dos mecanismos do Echelon 3: *estabilidade e curadoria superam volume bruto*.

4.2.3 Conclusão do Echelon

O Echelon 2 estabelece a prevalência da **eficácia** sobre a **eficiência**: diante de conflitos, preserva-se o piso de qualidade (benchmarks, arquitetura), ajustando-se parâmetros operacionais.

Esse arranjo prepara o caminho para o Echelon 3 e fundamenta o **DDR-IR-E3**:

Assunção de Design — aplicar CPT no modelo-base seguido de Instruction Residuals para restaurar a capacidade instrucional com custo controlado.

Tal decisão materializa a estratégia de mitigação de risco/eficiência coerente com as prioridades definidas em E2.

4.3 Echelon 3 — Design e Desenvolvimento

O Echelon 3 descreve como o Projeto Gaia transformou os objetivos e requisitos (E2) em uma solução projetável, explicitando decisões sob incerteza, seus *trade-offs* e as evidências que as sustentam. Aqui, o pipeline **CPT→IR** (Continuous Pre-Training seguido de Instruction Residuals) emerge como eixo arquitetural do design, orientado por dois imperativos confirmados em E2: (i) eficácia em geração (NLG) para PT-BR, aferida por benchmarks de alta complexidade; (ii) mitigação de risco de perda de capacidade instrucional pós-CPT, preservando eficiência computacional em vez de *full fine-tuning* oneroso. As decisões são registradas como DDRs (*Design Decision Records*), com ponteiros de evidência, momento aproximado e critérios/fallback, mantendo rastreabilidade para E4/E5 (KUECHLER; VAISHNAVI, 2012; GREGOR; HEVNER, 2013).


4.3.1 Racionalidade do pipeline CPT→IR (o “porquê” e a “ordem”)

Os dados primários indicam que a sequência CPT (E3) → IR (E3) foi planejada, não apenas uma correção reativa; o objetivo foi (a) ampliar competência linguística via CPT e (b) restaurar/cimentar a instrução com um método modular e barato em parâmetros (IR), evitando custos e risco de *catastrophic forgetting* associados a ajustes extensivos. Evidência formativa adicional veio de testes preliminares em família Qwen (pré-Gaia), que funcionaram como “campo de provas” para a sequência, antes da aplicação ao backbone Gemma — um episódio que já antecipa E4 (formativo/artificial).

4.3.2 Arquitetura de base: seleção e racionalidade técnica (E2→E3)

A escolha do *backbone* do Gaia foi tratada como decisão de design rastreável (DDR-E3-01), derivada dos requisitos priorizados em E2 e validada por episódios formativos em E4. Em termos de eDSR, trata-se de uma passagem explícita dos requisitos (E2) para

Figura 7 – Pipeline CPT→IR e mitigação de risco



Fonte: Elaboração própria. Mecanismo baseado em Jindal et al. (2024). Seta sólida = ordem do pipeline; tracejada = retorno a E2; pontilhada = ligação com episódios FEDS.

o design e desenvolvimento (E3), mantendo vínculo com avaliação subsequente (FEDS) e critérios de promoção definidos no Cap. 3 (GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016). O objetivo era viabilizar um *pipeline* CPT→IR eficiente para PT-BR — especializar linguisticamente sem sacrificar a capacidade instrucional — sob restrições de infraestrutura e licenciamento compatíveis com um consórcio multistakeholder (JINDAL; AL., 2024).

Critério	DR	Prioridade	Justificativa / Evidência
Licença compatível	DR8	Crítico	Consórcio exige uso/redistribuição sem restrições; governança deve ser estável. Evidência: termos oficiais; minutas internas; DDR-E3-01.
Decoder-only (NLG)	DR4	Crítico	Fechamento da lacuna de geração em PT-BR; encoder-only é inadequado. Fontes: model cards; documentação técnica.
Potencial SOTA	DR1	Crítico	Backbone deve sustentar alto desempenho em benchmarks complexos. Fontes: benchmarks públicos; PoC (E4).
Eficiência em H100	DR6	Prioritário	Throughput e KV-cache devem caber no orçamento. Fontes: logs, medições internas.
Viabilidade CPT + IR	DR5	Prioritário	Pipeline depende de CPT focalizado + restauração instrucional estável. Fontes: ablações; registros de treino.
Ecossistema	—	Prioritário	Menos atrito em engenharia, mais velocidade em ablações. Fontes: issues, PRs, docs.

Quadro 1: Critérios de seleção do *backbone* mapeados a DRs (E2→E3)

Tabela 18 – Matriz comparativa de candidatos × critérios para seleção do *backbone*

Critério \ Candidato	LLaMA 3.1	Qwen 2.5	Mistral 7B / Mixtral	Gemma (2/3)	
DR8 — Licença (abertura)	~ (licença comunitária com restrições)	(Apache 2.0)	(Apache 2.0)	~ (<i>ToU</i> permissiva p/ consórcio; proprietária)	
DR4 — <i>Decoder-only</i> (NLG)					
DR1 — Potencial SOTA (benchmarks)			~ (escala/variante impactam)		
DR6 — Eficiência em H100 (CPT)	~ (custo KV/cache em escala)	~	~ (MoE adiciona complexidade)	(atenção híbrida favorece CPT)	
DR5 — Viabilidade CPT + IR	~	~ (histórico positivo em CPT)	~	(<i>pipeline</i> CPT→IR consolidado)	
Ecossistema (<i>tooling</i> /docs/comunidade)	(amplo)	~ (crescimento rápido)	~ (bom, menor que LLaMA)	(docs oficiais + <i>tooling</i> estável)	

Legenda: atende; ~ atende parcialmente/condicional; não atende / risco alto.
Ponteiros de fonte: documentações oficiais dos modelos e registros internos (ver Caps. 3–4).

Tabela 19 – Quadro 4.3.2-C — DDR-E3-01: Seleção do backbone do Gaia

Campo	Conteúdo
ID	DDR-E3-01
Echelon	E3 (Design & Desenvolvimento)
Título	Seleção da família Gemma como <i>backbone</i> do Gaia
Enunciado	Selecionar a família Gemma como <i>backbone</i> principal para o Gaia, alinhada a CPT→IR e aos requisitos de E2.
Racionalidade	
Momento	E3, com validação formativa em <i>proxy</i> (E4).
Evidências	Documentação oficial, logs de ablação, episódios formativos.
Critério de sucesso	Estabilidade de treino e restauração instrucional via IR.
Fallback	Qwen 2.5 (já avaliado como <i>proxy</i> formativo).

Fonte: Elaboração própria.

4.3.2.1 Processo de seleção do backbone (E2→E3)

Contexto e *timing*. A decisão ocorreu quando havia múltiplas famílias *decoder-only* de acesso aberto ou semiaberto aptas à geração (DR4), mas com regimes de licença e maturidade de ecossistema distintos (DR8). Em coerência com E2, trataram-se como críticos: (i) abertura/redistribuição no escopo do consórcio (DR8); (ii) adequação gerativa

(DR4); (iii) potencial de desempenho em benchmarks de alta complexidade (DR1). Como prioritários (ajustáveis): (iv) eficiência computacional em H100 (DR6); (v) viabilidade do CPT e restauração via IR (DR5); (vi) suporte de ecossistema (documentação, *tooling*, comunidade) (HEVNER et al., 2004; GREGOR; HEVNER, 2013).

Universo de candidatos. Foram considerados LLaMA 3.1 (Meta), Qwen 2.5 (Alibaba), Mistral 7B/Mixtral (Mistral) e a família Gemma (Google/DeepMind). A depender da linha do tempo do projeto, a instanciação inicial pode ter ocorrido em Gemma 2 com migração para Gemma 3 quando esta se tornou disponível, ou com acesso antecipado, o que é explicitado no Quadro 19 para preservar consistência temporal (Google DeepMind, 2024; Meta AI, 2024; Alibaba Cloud, 2024; Mistral AI, 2023).

Critérios mapeados a E2.

- **Críticos (impeditivos):** DR8 (licença compatível com uso/redistribuição no consórcio), DR4 (*decoder-only* para NLG), DR1 (potencial SOTA em tarefas complexas em PT-BR).
- **Prioritários (ajustáveis):** DR6 (eficiência: KV-cache/*throughput/batch* em H100), DR5 (histórico/viabilidade de CPT + IR), ecossistema (*tooling* e documentação).

Matriz de avaliação qualitativa. A Tabela 18 registra atendimento por critério (/ ~ / o) com ponteiros de fonte. Em síntese: Gemma atende aos críticos e oferece propriedades arquiteturais que favorecem CPT→IR sob orçamento; LLaMA 3.1 apresenta risco de governança/licença para um consórcio (DR8); Mistral/Mixtral eleva complexidade operacional (MoE) para CPT; Qwen 2.5 é tecnicamente sólido e foi mantido como *proxy* formativo (E4) e *fallback* (Meta AI, 2024; Mistral AI, 2023; Alibaba Cloud, 2024; Google DeepMind, 2024).

4.3.2.2 Gemma: características arquiteturais relevantes para CPT→IR

Atenção e gerenciamento de contexto. A combinação de atenção local (janela deslizante) com camadas de atenção global intercaladas, associada a MQA/GQA conforme a escala do modelo, reduz a pressão do KV-cache e permite *batch* mais alto em CPT, preservando dependências de longo alcance — um equilíbrio crítico quando se deseja especialização linguística com custo controlado (Google DeepMind, 2024; Gemma Team, 2024). Esse arranjo arquitetural melhora o saldo custo/qualidade na fase de pré-treino contínuo, reduzindo instabilidades típicas em contextos multilíngues.

Tokenização e cobertura. A tokenização baseada em SentencePiece/BPE com vocabulário amplo tende a diminuir a “fertilidade de tokens” em PT-BR, reduzindo fragmentação morfológica e, por consequência, custo computacional e ruído em CPT. Quando combinada à curadoria por qualidade (subset nacional estável), essa característica

favorece convergência e qualidade de geração em domínios culturais específicos (Google DeepMind, 2024; RAFFEL et al., 2020).

Eficiência computacional em H100. Implementações otimizadas de atenção e camadas *feed-forward*, aliadas a suporte maduro no ecossistema, viabilizam CPT focalizado e IR com *throughput* estável em H100, ajustando tamanho de lote/gradiente ao orçamento disponível (Google DeepMind, 2024).

Implicações para CPT→IR. O design do Gaia explora M1 (CPT) para elevar competência lexical/estilística em PT-BR, ciente do risco de esquecimento instrucional; aplica M2 (IR) para repor/estabilizar capacidade de seguir instruções com baixo custo paramétrico — solução modular que evita *fine-tuning* caro e preserva a utilidade geral do modelo (JINDAL; AL., 2024). Em conjunto, atenção eficiente + tokenização apropriada + IR compõem um mecanismo causal coerente com a teoria de médio alcance apresentada no Cap. 5 (GREGOR; HEVNER, 2013).

Nota de consistência temporal. Caso o ciclo inicial tenha usado Gemma 2 e a migração para Gemma 3 seja posterior, registramos o encadeamento no DDR-E3-01 para manter o rastro E3→E4 e evitar anacronismos (Google DeepMind, 2024).

4.3.2.3 Alternativas descartadas e *trade-offs* conscientes

LLaMA 3.1 (Meta). Tecnicamente competitivo, porém o regime de licença impõe restrições relevantes para consórcios que visam abertura/redistribuição ampla; tal risco de governança conflita com DR8 no contexto multistakeholder do Gaia (Meta AI, 2024).

Qwen 2.5 (Alibaba). Compatível em licença (Apache 2.0) e sólido em NLG; documentação/ecossistema parcialmente assimétricos foram ponderados. Foi utilizado como *proxy* formativo (E4) e mantido como *fallback* no DDR-E3-01 (Alibaba Cloud, 2024).

Mistral 7B/Mixtral (Mistral). A variante MoE agrega complexidade de roteamento e potenciais instabilidades sob *distribution shift* em CPT, além de aumentar o custo de engenharia; o modelo denso 7B tem janela/eficiência menos favoráveis ao nosso *pipeline* (FEDUS; ZOPH; SHAZEER, 2022; Mistral AI, 2023).

Síntese. À luz dos critérios críticos (DR8/DR4/DR1) e prioritários (DR6/DR5/ecossistema), a seleção por Gemma materializa um *trade-off* consciente: otimiza CPT→IR para PT-BR com governança adequada ao consórcio, mantendo viabilidade computacional e caminho de avaliação claro (E4→E5) (HEVNER et al., 2004; GREGOR; HEVNER, 2013; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

4.3.3 Dados e curadoria (do Jabuticaba ao subset ~13B)

A evidência empírica indica que a qualidade/estabilidade de treino prevaleceu sobre a magnitude bruta de dados: o plano original (corpus massivo) foi revisto para um subset curado (~13B tokens), respondendo a sinais de instabilidade/deriva e a ganhos marginais decrescentes. Em termos de design, a curadoria atua como mecanismo de controle de ruído e “afinamento cultural”, reforçando o objetivo de eficácia (E2).

Tabela 20 – Curadoria de dados e implicações para CPT

Fonte/Tipo	Regra de inclusão	Sinal de qualidade	Impacto
Jabuticaba (web)	Deduplicação + filtros	Perplexidade ↓	Treino mais estável
Domínio jurídico	Remoção de boilerplate	Win-rate ↑ em QA	Geração mais fiel
Social mid-freq	Remoção de spam/ruído	Estilo ↑	Menos alucinação

Fonte: Documentação oficial Gemma 3 (Gemma Team; Google DeepMind, 2025).

4.3.4 Principais DDRs de E3 (registro mínimo e critérios)

Para tornar visíveis as decisões sob incerteza, registram-se ao menos quatro DDRs nucleares:

Tabela 21 – Principais DDRs de E3 (Design e Desenvolvimento)


ID	Enunciado	Racionalidade	Evidência	Critério	Vínculo	Status
DDR-E3-01	Adotar Gemma-3-X como backbone	Custo/benefício compatibilidade com CPT→IR	Documentação técnica	Manter/elevar ENEM-like	DO1/DR4	Confirmado
DDR-E3-02	CPT planejado no subset curado	Especialização linguística/cultural	Testes/ablação	Estabilidade; IFEval	DO1/DR2	Confirmado
DDR-E3-03	Aplicar IR modular	Restaurar instrução sem SFT extenso	Ablações IR	Recuperar ≥X pts; custo ≤Y	DO1/DR1	Confirmado
DDR-E3-04	Redução para subset ~13B	Estabilidade > volume bruto	Logs de treino	Perplexidade ↓; win-rate ↑	DR2/DO3	Confirmado

Fonte: Elaboração própria.

4.3.5 Encadeamento com E4 (FEDS) — episódios formativos

Os testes prévios em Qwen e o uso subsequente de ENEM como formativo (durante o design) e somativo (ao final) estruturam a tipagem FEDS: formativo/artificial nos ensaios internos; somativo/artificial nos leaderboards; e naturalístico quando em contexto de adoção/uso real (ver §4.4–4.5). Esse encadeamento fecha o ciclo E3→E4 de forma rastreável.

Figura 8 – Linha do tempo FEDS (E3→E4→E5)



Fonte: Fonte: Elaboração própria com base no framework FEDS (Venable; Pries-Heje; Baskerville, 2016).

4.3.6 Candidatos a Princípios de Design (DPs) a partir de E3

À luz da regra de convergência (entrevista + documento), E3 fornece matéria-prima para DPs no formato de (GREGOR; HEVNER, 2013):

- **DP-E3-A (CPT+IR modular):** Para LLMs de nicho PT-BR com alvo de geração SOTA, quando o CPT introduzir queda mensurável em capacidade instrucional, então aplicar IR modular alinhado a métricas de instrução para restaurar desempenho com custo inferior ao SFT integral, a fim de maximizar eficácia sob restrições de eficiência (boundary: disponibilidade de dados de instrução e sinais de avaliação confiáveis).
- **DP-E3-B (Curadoria por estabilidade):** Para cenários com corpus heterogêneo, quando sinais de instabilidade de treino emergirem, então reduzir/curar o dataset por qualidade e alinhamento cultural, a fim de elevar estabilidade e win-rates em PT-BR, mesmo com menor volume.

Tabela 22 – Boundary conditions e indicadores de saída

Dimensão	Detalhes
Pré-condições	Backbone compatível; métricas de instrução; orçamento finito; curadoria mínima.
Restrições	Hardware-alvo; requisitos de licença; coordenação multistakeholder.
Indicadores	Δ ENEM/PT-benchmarks; win-rates vs. baselines; estabilidade de loss; custo marginal pós-treino.

Fonte: Elaboração própria.

4.4 Echelon 4 — Demonstração (Prova de Conceito, PoC)

No E4 o artefato instanciado é colocado à prova para demonstrar viabilidade funcional e eficácia frente aos requisitos de E2. Adotamos o FEDS para tipar cada episódio de avaliação por propósito (formativo vs. somativo) e paradigma (artificial vs. naturalístico) (VENABLE; PRIES-HEJE; BASKERVILLE, 2016), preservando rastreabilidade com E3 (DDRs) e ponteiros de evidência.

4.4.1 PoC formativo (fase exploratória em Qwen)

O que foi feito. Antes da instanciação no backbone Gemma, o pipeline CPT→IR foi exercitado em família Qwen como “campo de provas” para reduzir risco técnico e calibrar decisões do E3.

FEDS. Formativo / Artificial. Objetivo: gerar feedback para o design, em ambiente controlado e não definitivo.

Ligação com E3. Validações parciais de DDR-E3-02 (CPT planejado) e DDR-E3-03 (IR modular), com melhoras em métricas de instrução e estabilidade de treino.

Resultado operacional. Evidência de que a sequência CPT (ganho de repertório) seguida de IR (restauração instrucional a baixo custo) era tecnicamente viável sob restrições de eficiência.

4.4.2 PoC somativo (benchmark ENEM no Gaia final)

O que foi feito. O Gaia (instância final) foi submetido ao ENEM (conjunto de alta complexidade em PT-BR), atingindo 0,7000 vs. 0,6556 do baseline reportado.

FEDS. Somativo / Artificial. Benchmarks padronizados, ainda que altamente contextualizados, permanecem avaliações artificiais no FEDS; aqui funcionam como critério público de eficácia (DO1/DR1).

Observação de validade. O ENEM possui alta validade ecológica para o objetivo de NLG em PT-BR, razão pela qual também foi usado formativamente durante o ciclo (ajustes), mas seu score final é tratado como somativo/artificial para manter consistência metodológica.

Ligação com E3. Confirma em produção experimental as apostas de DDR-E3-02/03 (CPT→IR), provendo *checksum* público de eficácia.

4.4.3 Consolidação de E4 e ponte para E5

A estratégia de avaliação foi progressiva: (i) ensaios internos formativos para reduzir incerteza (Qwen); (ii) validação somativa pública (ENEM) para atestar eficácia do artefato. Itens naturalísticos (adoção/uso real) são tratados no E5.

Os resultados de E4 confirmam as decisões críticas de E3 (CPT→IR) sob a ótica de eficácia e risco técnico, entregando uma PoC robusta e publicamente compreensível (ENEM). A próxima seção (E5) desloca o foco para utilidade em uso (naturalística), onde a validade externa depende de contexto, atores e métricas de valor, fechando o ciclo eDSR com a distinção PoC/PoV.

Figura 9 – Progressão FEDS do Echelon 4

<i>E3 (DDRs) — Ajustes</i>		<i>E5 (PoV) — Contexto</i>
↑		↑
Qwen — PoC exploratória Formativo / Artificial • Exercício CPT→IR • Feedback para E3 • Métricas ↑	progressão→	Gaia — ENEM final Somativo / Artificial • 0,7000 vs. 0,6556 • Critério público (DO1) • Confirma CPT→IR

Fonte: Elaboração própria. Retornos a E3 e ponte para E5.

Tabela 23 – Episódios de E4, tipagem FEDS e ligação com E3/E5

Episódio	Artefato	FEDS (P)	FEDS (M)	Objetivo E4	DDRs (E3)	Evidência
Qwen	CPT→IR proxy	Formativo	Artificial	Redução de risco; feedback para design	DDR-E3-02, DDR-E3-03	Entrevista; model card
ENEM	Gaia Final	Somativo	Artificial	Eficácia pública (DO1/DR1)	DDR-E3-02, DDR-E3-03	Página pública

Fonte: Elaboração própria.

4.5 Echelon 5 — Avaliação (Prova de Valor, PoV)

Em E5 avaliamos o artefato em uso e a utilidade entregue no mundo real, isto é, episódios somativos em contexto naturalístico na tipologia FEDS (VENABLE; PRIESHEJE; BASKERVILLE, 2016). Diferente do E4 (eficácia técnica em benchmark), aqui o foco é para quem e em que termos o Gaia gerou valor — organizacional e/ou de ecossistema — e como isso fecha (ou não) ciclos de realimentação para o design.

4.5.1 Escopo de PoV para o Gaia

A partir da entrevista, o valor principal percebido não foi comercial imediato, mas P&D/Ecossistema: consolidação de *know-how* sobre como treinar LLMs (decisões CPT→IR, curadoria de subset ~13B, governança de eficiência) e impacto público/open-source. Isso é consistente com DSR: utilidade pode residir no conhecimento de design transferível, não apenas em ROI direto (HEVNER et al., 2004; GREGOR; HEVNER, 2013). Assim, tomamos Ecossistema/P&D como eixo central de PoV, e Adoção Organizacional como eixo adicional quando houver evidência.

4.5.2 PoV confirmado — P&D e Ecossistema

A entrevista confirma que o projeto produziu utilidade cognitiva e comunitária: (i) *know-how* explicitável sobre especialização em PT-BR com risco/eficiência (CPT→IR), (ii) artefato aberto que catalisa testes, forks e aprendizagem coletiva. Em termos de eDSR,

trata-se de PoV que projeta o design além do caso, sustentando a futura derivação de DPs (Cap. 5). Evidências públicas de comunidade (downloads/estrelas/comentários) podem compor métricas de PoV de ecossistema; quando ausentes ou não auditadas nesta fonte, mantemos e remetemos ao Apêndice de evidência.

Tabela 24 – Indicadores de Ecossistema e Adoção (Hugging Face)

Indicador	Valor	Fonte	Interpretação
Likes (HF)	140	Model card	Proxy de interesse/engajamento.
Downloads (30d)	1.524	Model card	Uso técnico recente em ambiente naturalístico.
Quantizações	16	Model card	Portabilidade por terceiros; indicador de adoção comunitária.
Spaces	1	Leaderboard	Uso referenciado em benchmarking e demonstrações.
Issues	6	HF Repo	Engajamento mínimo de comunidade técnica.

Fonte: Dados públicos do Hugging Face (não auditados nesta coleta).

4.5.3 PoV parcial — Adoção organizacional e feedback loop

O respondente não acompanhou se pilotos/usuários (e.g., TCM-GO) geraram novos requisitos de volta ao roadmap (retorno a E2). Do ponto de vista FEDS, há indício de uso naturalístico, mas sem confirmação do ciclo de realimentação somativo → novos requisitos. Em consórcios multistakeholder, essa opacidade é recorrente: *ownership* do valor, governança do roadmap e visibilidade de métricas tendem a ficar segmentados por parceiro, o que dificulta observar a volta formal a E2 (VENABLE; PRIES-HEJE; BASKERVILLE, 2016). Registramos, portanto, PoV organizacional como parcial/indireto nesta fonte, preservando ponteiros para checagens documentais futuras.

Para não subestimar a utilidade em contextos de ciência aberta, triangulamos o PoV organizacional com indicadores de ecossistema (downloads, forks/issues, quantizações, referências em leaderboards/Spaces), que evidenciam adoção técnico-comunitária em ambiente naturalístico, ainda que não equivalham a métricas de negócio internas. À luz da nossa regra de convergência (entrevista + documento ou múltiplas fontes independentes), tais indicadores sustentam a classificação E5 = somativa/naturalística (parcial) (GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024) e corroboram a tese de que o valor primário do Gaia concentrou-se em P&D/ecossistema, mais do que em captura organizacional imediata.

Em termos de *boundary conditions*, PoV organizacional pleno exigiria evidências adicionais de feedback loop (E5→E2) sob controle de um mesmo ator — condição não satisfeita nesta coleta.

Tabela 25 – Episódios de PoV, tipagem FEDS e status de evidência

Episódio	Contexto	FEDS (P)	FEDS (M)	Indicador	St
Know-how	P&D/Ecosystema	Somativo	Naturalístico	DDR/Entrevista	✓
Modelo Aberto	OSS/Comunidade	Somativo	Naturalístico	Downloads/Stars/Forks	✓
Piloto	Órgão Público (TCM-GO)	Somativo	Naturalístico	Uso não auditado	△
Feedback a E2	Roadmap Produto	Somativo	Naturalístico	Não observado	

Fonte: Elaboração própria.

4.5.4 Implicações para a tese (ponte a Cap. 5)

Com E5, fechamos o arco eDSR: (i) utilidade comprovada no eixo P&D/Ecosystema; (ii) utilidade organizacional com visibilidade limitada nesta coleta; (iii) condições de aplicação emergentes (abertura, corpus local, restrições de custo) que informam os Princípios de Design. Em Cap. 5, candidatos a DPs derivam de cadeias rastreáveis E3→E4→E5, por exemplo:

“Em contextos de LLMs de nicho sob restrição de custo, quando o CPT ameaçar a capacidade instrucional, designers devem empregar residualização instrucional modular para recuperar instrução com baixo custo, maximizando utilidade de ecossistema por abertura audível.”

Tabela 26 – Síntese da Instanciação do eDSR no Projeto Gaia (E1–E5)

Echelon	Artefato	Conteúdo Validado (Síntese)	FEDS	Evidência	Status
E1	Prob. Statement	Lacuna generativa PT-BR; déficit decoder; gatilho multistakeholder.	Form/Nat	Lit+Entrevista	Conf.
E2	DO/DR	DR1 SOTA/ENEM (pétreo); DR4 decoder-only; DR2 subset curado; DO3 eficiência flexível.	Form/Nat	Docs+Entrev.	Parc→Conf.
E3	Blueprint/DDR	CPT→IR (especialização+preservação); H100; Curadoria 13B.	Form/Art	Jindal+ModelCard	Conf.
E4	PoC	Qwen (proxy); ENEM (0.7000 vs 0.6556).	Som/Art	Benchmark	Conf.
E5	PoV	Adoção comunitária (HuggingFace); Pilotos (TCM-GO). Feedback E2 não visto.	Som/Nat	HF+Parceiros	Conf/Parc.

Fonte: Elaboração própria.

Tabela 27 – Projeto Gaia — Visão eDSR (E1–E5)

	C1. Artefato Intermediário	C2. Decisão de Design (DDR)	C3. Avaliação (FEDS)
E1 Análise do Problema	E1. Problem statement (validado) • Lacuna generativa/cultural em PT-BR • Déficit de decoder-only • Dados nacionais (Jabuticaba) não geram desempenho NLG sozinhos <i>Evidência:</i> surveys, pilares, doc. pública, entrevista.		
E2 Objetivos & Requi- sitos	E2. DO/DR validados (v1) • DO1/DR1: SOTA em benchmark (ENEM) • DR4: Arq. geração (decoder-only, base Gemma 3) • DO3: Eficiência/volume flexíveis (qualidade>quantidade) <i>Fonte:</i> Tabela DO/DR + entrevista.		E2b. Revisão de requisitos Prioridades, métricas e constraints refinadas (workshop/entrevista). <i>Status:</i> confirmado.
E3 Design & Desenv.	E3.1 Blueprint Base Gemma 3 / Subset Jabuticaba ≈ 13B tokens. Obj: NLG PT-BR. E3.3 Infra/treino H100 / batch e seq. length compatíveis. Plano de ablações (com/sem IR).	E3.2 DDR — CPT → IR • CPT focalizado em PT-BR (especialização) • Risco: esquecimento instrucional • IR repõe capacidade de seguir instruções com baixo custo • Critério: restaurar instrução s/ fine-tuning pesado <i>Status:</i> confirmado.	E3.x Ablações/Proxies Testes internos (com/sem IR; proxy). Formativa · Artificial. E4a. Exploração em Qwen (proxy) Validação do pipeline CPT→IR antes da instanciação final. <i>FEDS:</i> Formativa · Artificial.
E4 Demos- tração (PoC)			E4.1 ENEM 2024 — PoC Resultado 0.7000 vs 0.6556 (baseline). Requisito DR1 satisfeito. <i>FEDS:</i> Somativa (com uso formativo durante treino).
E5 Avaliação (PoV)			E5.1 PoV organizacional — TCM-GO Uso naturalístico; feedback contextual. <i>Status:</i> parcial/indireto (loop a E2 não confirmado). E5.2 PoV ecossistema — Hugging Face Downloads / likes / forks / citações (utilidade de P&D). <i>Status:</i> confirmado (comunidade).

Legenda: E = Echelon / PoC = Prova de Conceito / PoV = Prova de Valor.

DDR = Design Decision Record / FEDS = Formativa/Somativa · Artificial/Naturalística.

Fonte dos dados: Literatura/pilares; documentação pública do Gaia; entrevista (Formulário v3.0).

5 Conclusões e Contribuições

Este capítulo converte as cadeias de evidência reconstruídas no Capítulo 4 (E1→E5) em conhecimento de design prescritivo, no espírito da *Design Science Research*: gerar conhecimento por meio do ciclo construir–avaliar de artefatos e explicitar relações meio–fim entre espaços de problema e solução (HEVNER et al., 2004; MARCH; SMITH, 1995). Operacionalmente, adotamos a lógica echelonada do eDSR para manter a rastreabilidade entre decisão, evidência e episódio de avaliação — decompondo o projeto em partes logicamente coerentes (E1–E5) e promovendo resultados apenas quando validados no próprio *echelon* (TUUNANEN; GHANBARI; KAZAN, 2024). A tipagem de avaliação segue o FEDS, que classifica episódios segundo propósito funcional (formativo ↔ somativo) e paradigma (artificial ↔ naturalística) e orienta a construção de estratégias de avaliação em quatro passos: explicitar objetivos, escolher a estratégia, definir propriedades e desenhar episódios de avaliação (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

O produto principal é um conjunto de Princípios de Design (DPs) e um modelo de teoria de médio alcance adequado a LLMs de nicho em PT-BR. Cada DP é formulado no formato prescritivo recomendado para DSR — “para contextos do tipo C, quando ocorrer P, designers devem executar A para obter E” — e ancorado em ponteiros de evidência (entrevista/documento) e condições de aplicação (*boundary conditions*) (GREGOR; HEVNER, 2013). Esse posicionamento atende à noção de teoria de médio alcance: conhecimento de design sobre fenômenos embutidos, acumulado via instâncias situadas e abstraído em princípios empiricamente avaliados (GREGOR; HEVNER, 2013; GHANBARI; TUUNANEN; KAZAN, 2025).

Para garantir rigor e relevância (diretrizes clássicas da DSR), adotamos três salvaguardas metodológicas: (i) **regra de promoção** — um item só deixa o status de hipótese quando há convergência entre entrevista e documento (ou múltiplas fontes independentes) (HEVNER et al., 2004); (ii) **triangulação FEDS** — encadeamos avaliações formativas/artificiais (p.ex., ablações, *proxies*) e somativas/naturalísticas (p.ex., ENEM, pilotos) para cobrir eficiência de processo e eficácia em uso (VENABLE; PRIES-HEJE; BASKERVILLE, 2016); e (iii) **explicitação do artefato e de suas decisões rastreáveis (DDRs)** — cada decisão possui enunciado, racionalidade, momento e critério de sucesso, preservando o rastro entre construção e avaliação (KUECHLER; VAISHNAVI, 2012).

5.1 Teoria de médio alcance

Propomos uma teoria de médio alcance para projetos de LLMs de nicho em PT-BR conduzidos por consórcios multistakeholder, com dados nacionais abundantes e orçamento finito (**C**). O problema que a teoria endereça é duplo: (i) a lacuna generativa/registro

cultural em PT-BR decorrente do déficit de modelos *decoder-only* fortes treinados com foco brasileiro, e (ii) a “caixa-preta” decisória que obscurece como escolhas técnicas são feitas e validadas em IA aplicada (**P**) (LIPTON; STEINHARDT, 2018).

Em termos de mecanismos (**M**), a teoria articula um encadeamento operativo:


- **M1 – especialização linguística via CPT focalizado:** aumenta competência lexical/estilística, mas eleva o risco de esquecimento instrucional;
- **M2 – preservação instrucional por Instruction Residuals (IR):** reintroduz sinal de instrução com baixo custo paramétrico e estabiliza a capacidade de seguir comandos;
- **M3 – curadoria por qualidade:** seleção de subset nacional guiada por estabilidade e ruído, não por volume bruto;
- **M4 – avaliação dual FEDS:** combinação de PoCs formativas/artificiais (p.ex., ablações, *proxies*) e PoVs somativas/naturalísticas (p.ex., ENEM, pilotos) para reduzir risco técnico e atestar utilidade contextual (JINDAL; AL., 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Os resultados esperados (**E**) são: eficácia técnica em tarefas relevantes (PoC) e utilidade/ecossistema em uso real (PoV), com variantes de tamanho do modelo que favorecem adoção sob restrições de custo e latência (GREGOR; HEVNER, 2013).

A teoria é prescritiva no sentido da DSR: para contextos do tipo C, quando ocorrer P, designers devem executar A para obter E — em que A corresponde ao encadeamento CPT→IR acoplado à curadoria por qualidade e à avaliação dual FEDS, operado e documentado em *echelons* para garantir rastreabilidade (GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024). Suas condições de aplicação (*boundary conditions*) incluem: disponibilidade de corpus nacional amplo; recursos computacionais limitados que tornam IR atraente frente a *fine-tuning* instrucional integral; governança multistakeholder que privilegia valor de P&D/ecossistema; e processo eDSR capaz de ligar decisões (DDRs) a episódios FEDS.

A teoria herda a estrutura procedimental dos Capítulos 3–4: deriva de cadeias de evidência E1→E5 registradas por eDSR e tipadas por FEDS, evitando avaliações apenas *ex post* e promovendo ciclos *build-evaluate* com rastro auditável (TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Figura 10 – Teoria de médio alcance (C–P–M–E) para LLMs de nicho em PT-BR



Fonte: Elaboração própria. Encadeamento entre Contexto (C), Problema (P), Mecanismos (M1–M4) e Resultados (E), mapeado aos *echelons* (E1–E5) e à tipagem FEDS.

5.2 Princípios de Design (DPs)

Esta seção transforma as cadeias E1→E5 em proposições prescritivas reutilizáveis. Cada DP é formulado no formato recomendado — “para contextos do tipo C, quando ocorrer P, designers devem executar A para obter E” — e ancorado em mecanismos eDSR/FEDS, condições de aplicação e rastro de evidência (entrevista + documentos), conforme diretrizes de DSR e teoria de médio alcance (GREGOR; HEVNER, 2013; HEVNER et al., 2004; PEFFERS et al., 2007; TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016; KUECHLER; VAISHNAVI, 2012; LIPTON; STEINHARDT, 2018; JINDAL; AL., 2024).

5.2.1 DP1 — Especialização linguística com preservação instrucional (CPT→IR)

Enunciado prescritivo. Para projetos de LLMs de nicho em PT-BR, com múltiplos *stakeholders* e orçamento finito (C), quando a especialização linguística por *Continuous Pre-Training* (CPT) elevar a fluência/aderência cultural, mas abrir risco de esquecimento instrucional (P), os designers devem aplicar *Instruction Residuals* (IR) logo após o CPT (A) para restaurar/estabilizar a capacidade de seguir instruções com baixo custo paramétrico e manter a eficácia em tarefas instrucionais (E) (HEVNER et al., 2004; GREGOR; HEVNER, 2013).

Propósito e contexto. A assimetria de desempenho em PT-BR exige especialização linguística para ganhos de estilo, registro e vocabulário; contudo, ao deslocar distribuições internas, o CPT pode degradar capacidades instrucionais previamente adquiridas (*catastrophic forgetting*). O princípio estabelece uma correção modular e eficiente via IR, compatível com restrições de custo/infraestrutura e com o encadeamento *build-evaluate* próprio da DSR/eDSR (GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024).

Mecanismo causal. O CPT, ao intensificar a exposição a PT-BR, melhora a modelagem de tokenização/estilo, mas desancora vetores associados a seguir instruções; o IR recompõe tais padrões por adição/subtração de tensores que reintroduzem (ou “residualizam”) a competência instrucional sem um novo *fine-tuning* completo, preservando eficiência computacional e reduzindo risco de regressões (JINDAL; AL., 2024; LIPTON; STEINHARDT, 2018). Em termos de avaliação, espera-se recuperação de métricas instrucionais sem perda dos ganhos de geração em PT-BR (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Relações com outros DPs. DP1 depende de curadoria por qualidade (DP2) para evitar que ruído amplificado no CPT comprometa a recuperação por IR; antecipa também a avaliação dual FEDS (DP3), pois a eficácia do par CPT→IR deve ser primeiro inspecionada em episódios formativos/artificiais e depois julgada em episódios somativos/naturalísticos (p.ex., ENEM/pilotos). A rastreabilidade por DDRs (DP5) torna explícitos enunciado, racionalidade, momento e critérios de sucesso/*fallback* (KUECHLER; VAISHNAVI, 2012; VENABLE; PRIES-HEJE; BASKERVILLE, 2016; TUUNANEN; GHANBARI; KAZAN, 2024).

Condições de aplicação e limites (boundary conditions). (i) Disponibilidade de corpus nacional curado; (ii) Orçamento computacional restrito (IR substitui *fine-tuning* instrucional completo); (iii) Métricas instrucionais de verificação; (iv) *Fallback*: caso IR falhe, recorrer a *adapters*/FT adicional, retornando a E2/E3 (VENABLE; PRIES-HEJE; BASKERVILLE, 2016; GREGOR; HEVNER, 2013).

Rastro de evidência (eDSR/FEDS).

- **E3:** DDR-E3 registrou CPT→IR com critério “especializar sem perder instrução”.
- **E4:** Episódios formativos (Qwen, ablações) e somativo (ENEM) confirmaram o mecanismo.
- **E5:** Utilidade/ecossistema reforça a projetabilidade para LLMs de nicho em PT-BR.

Tabela 28 – Cartão DP1 — CPT→IR: especializar preservando instruções

Enunciado	Para LLMs de nicho em PT-BR, multistakeholder e com orçamento finito (C), quando a especialização via CPT elevar o risco de esquecimento instrucional (P), aplicar <i>Instruction Residuals</i> logo após o CPT (A) para restaurar/estabilizar a capacidade instrucional com baixo custo paramétrico e manter eficácia em tarefas baseadas em instrução (E). (JINDAL; AL., 2024; GREGOR; HEVNER, 2013)
Mecanismos	M1 (CPT: especialização ↑ / risco instrucional ↑) → M2 (IR: preservação/restauração de instrução).
Evidências	• E3 DDR-IR: racionalidade, momento e critério. • E4 PoC (Qwen): eficácia formativa confirmada. • E4 PoC (ENEM): eficácia somativa confirmada. • E5 PoV: utilidade de P&D/ecossistema (parcial). (VENABLE; PRIESHEJE; BASKERVILLE, 2016)
Boundary	Corpus nacional curado; GPU moderada (H100 ou equivalentes); restrição de custo; necessidade de benchmark contextual (ENEM); governança multistakeholder. (TUUNANEN; GHANBARI; KAZAN, 2024)
Métricas	Δ ganho vs. baseline no ENEM; manutenção/recuperação de métricas instrucionais (p.ex., IFEval).
Risco	Necessidade de FT instrucional adicional ou <i>adapters</i> se o IR não recuperar metas esperadas.
Estado	Confirmado (E3+E4) / PoV parcial (E5). (KUECHLER; VAISHNAVI, 2012)

Fonte: Elaboração própria.

5.2.2 DP2 — Curadoria por qualidade (subset nacional guiado por estabilidade/ruído)

Enunciado prescritivo. Para projetos de LLMs de nicho em PT-BR com orçamento finito e múltiplos *stakeholders* (C), quando a disponibilidade de dados nacionais é abundante porém heterogênea (P), os designers devem construir um subset curado por qualidade do corpus nacional — priorizando estabilidade de treino e redução de ruído/duplicação/sesgo sobre volume bruto (A) — a fim de maximizar a eficácia técnica e a consistência comportamental do modelo ao longo do pipeline (E) (HEVNER et al., 2004; GREGOR; HEVNER, 2013).

Propósito e contexto. A existência de grandes corpora em PT-BR (e.g., Jabuticaba) elimina o gargalo de quantidade, mas não o de qualidade/estabilidade; em cenários de recursos limitados, mais tokens pode significar mais ruído, maiores custos e instabilidades de otimização que degradam o ganho marginal por token treinado. O princípio orienta a curadoria guiada por sinais de qualidade (p.ex., deduplicação, filtros de PII/toxicidade, *language ID*, perplexidade, diversidade temática), mantendo aderência

cultural sem sacrificar a convergência (SCOTTI; CRUZ-CASTAÑEDA; AMADEUS, 2025; LIPTON; STEINHARDT, 2018).

Mecanismo causal. Ao reduzir variância e ruído na distribuição de treino, o subset curado estabiliza gradientes, previne *mode collapse* temático e acelera a convergência do CPT, preservando sinal útil para estilo/registo de PT-BR. Isso eleva a eficiência de aprendizagem por token, melhora métricas de geração e diminui regressões comportamentais que, de outro modo, exigiriam correções caras no pós-CPT. A curadoria, portanto, potencializa o DP1 (CPT→IR): um CPT mais estável reduz a magnitude do esquecimento instrucional e facilita a restauração por IR, sob custo computacional controlado (LIPTON; STEINHARDT, 2018; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Relações com outros DPs. DP2 suporta o DP1 (especialização preservando instruções), ao fornecer um CPT com menor ruído; alimenta o DP3 (avaliação dual FEDS) por meio de ablações de dados — comparar *baseline* vs. subset curado em episódios formativos/artificiais e julgar efeitos em tarefas contextualizadas — e sinergiza com o DP4 (variantes de tamanho) ao levar qualidade ao dado, habilitando modelos menores (4B/13B) a capturar capacidades úteis em PT-BR. A rastreabilidade da curadoria deve ser materializada em DDRs (DP5): critérios, *scores*, *cut-offs*, datas e ponteiros para *scripts* e *manifests* (KUECHLER; VAISHNAVI, 2012; TUUNANEN; GHANBARI; KAZAN, 2024).

Condições de aplicação e limites (boundary conditions). (i) Disponibilidade de corpus nacional amplo com metadados mínimos para curadoria; (ii) Sinais de qualidade observáveis (dedup, LID, perplexidade, filtros de segurança/licença); (iii) Orçamento finito, onde eficiência por token supera volume; (iv) Risco de enviesamento temático: a curadoria deve preservar diversidade (jurídico, jornalístico, técnico, conversacional) e representatividade regional; (v) *Fallback*: se o subset curado reduzir cobertura sem compensar em estabilidade, ajustar limiares, reequilibrar domínios ou compor misturas estratificadas (VENABLE; PRIES-HEJE; BASKERVILLE, 2016; GREGOR; HEVNER, 2013).

Rastro de evidência (eDSR/FEDS). No E2, explicitar DR-dados (qualidade > volume) como requisito; no E3, registrar a decisão em DDR-E3 Curadoria: enunciado, critérios (dedup/ruído/segurança/balanceamento), *cut-offs*, evidências de estabilidade (curvas de perda, *gradient norms*, taxa de instabilities), data e ponteiros; em E4, conduzir episódios formativos/artificiais (ablação: bruto vs. curado; *learning curves*; custos) e somativos/naturalísticos (efeito no ENEM e tarefas *downstream* reais); em E5, documentar utilidade/ecossistema (reprodutibilidade do *data card*, reutilização do subset) e impactos percebidos por *stakeholders* (HEVNER et al., 2004; VENABLE; PRIES-HEJE; BASKERVILLE, 2016; TUUNANEN; GHANBARI; KAZAN, 2024; SCOTTI; CRUZ-CASTAÑEDA; AMADEUS, 2025).

Tabela 29 – Cartão DP2 — Curadoria por qualidade: subset > volume bruto

Enunciado	Para projetos de LLMs de nicho em PT-BR com corpus nacional abundante e heterogêneo (C), quando o uso do volume integral induzir instabilidade/ruído de treino e custo excessivo (P), construir um subset curado guiado por estabilidade, redução de ruído/duplicação e preservação de diversidade temática (A) para otimizar custo–desempenho e robustez comportamental do modelo (E). (GREGOR; HEVNER, 2013; SCOTTI; CRUZ-CASTAÑEDA; AMADEUS, 2025)
Mecanismos	M3 (curadoria por qualidade: redução de ruído/variância, estabilidade de treino) apoiando M1/M2 (CPT + IR).
Evidências	• E2 DR-dados: requisito “qualidade > volume” explicitado. • E3 DDR-Curadoria: 139B → ~13B tokens; critérios e sinais de estabilidade documentados. • E4 ENEM: subset curado sustenta eficácia técnica em benchmark. • E5 PoV: utilidade/ecossistema via <i>data card</i> reproduzível e reuso do subset.
Boundary	Corpus nacional amplo com metadados mínimos; heurísticas de estabilidade (perplexidade, detox, LID, deduplicação), custos de I/O e de treino; necessidade de preservar diversidade temática e regional em PT-BR.
Métricas	Melhora de estabilidade de treino (curvas de perda mais suaves, menos <i>instabilities</i>); Δ ENEM vs. corpus bruto; custo/token efetivo; redução de colapsos temáticos e regressões comportamentais.
Risco	<i>Overfiltering</i> ou enviesamento temático; mitigar via ajustes de limiar, A/B com fatias, reequilíbrio de domínios ou mistura com dados sintéticos/estratificados.
Estado	Confirmado (E2+E3+E4) / PoV parcial (E5).

Fonte: Elaboração própria.

5.2.3 DP3 — Avaliação dual FEDS (formativa/artificial → somativa/naturalística)

Enunciado prescritivo. Para projetos de LLMs de nicho em PT-BR com múltiplos *stakeholders* e orçamento finito (C), quando há simultaneamente incerteza técnica e exigência de utilidade contextual (P), os designers devem orquestrar uma estratégia dual de avaliação segundo o FEDS: ciclos formativos/**artificiais** (p.ex., ablações, proxies de modelo, testes internos) seguidos de episódios somativos/**naturalísticos** (p.ex., ENEM, pilotos com órgãos/empresas), cada qual mapeado ao seu echelon (E4/E5), com critérios de sucesso e regras de retorno explícitas (A), a fim de obter PoC sólida e PoV verificável, com rastro completo de evidências (E) (VENABLE; PRIES-HEJE; BASKERVILLE, 2016; HEVNER et al., 2004; GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024).

Propósito e contexto. A avaliação exclusivamente ao final invisibiliza decisões intermediárias e posterga riscos; a estratégia dual distribui a avaliação ao longo do processo: primeiro para aprender e corrigir (formativa/artificial), depois para julgar utilidade em contexto (somativa/naturalística). No caso Gaia, testes prévios em proxy (família Qwen) antecederam a instanciação final e foram seguidos por avaliação em ENEM 2024 e interações

com *stakeholders* (PoV), materializando a progressão FEDS (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Mecanismo causal. A camada formativa/artificial reduz risco técnico (detecta regressões, calibra CPT e IR, escolhe *mixes* de dados), enquanto a camada somativa/naturalística assegura validade externa (utilidade cultural/linguística em PT-BR). Em conjunto, o ciclo converte feedback em decisões de design rastreáveis (DDRs), evitando “viés de benchmark” e *teaching-to-the-test* por meio de congelamento de conjuntos de avaliação, pré-especificação de critérios e separação entre dados de treino e teste (VENABLE; PRIES-HEJE; BASKERVILLE, 2016; KUECHLER; VAISHNAVI, 2012).

Relações com outros DPs. DP3 potencializa o DP1 (CPT→IR) ao exigir ablações que quantificam esquecimento e recuperação instrucional; corrobora o DP2 (curadoria por qualidade) com experimentos de ablação de dados e *learning curves*; informa o DP4 (variantes de tamanho) ao comparar eficácia/latência sob cenários de hardware-alvo; e depende do DP5 (DDRs) para registrar episódios, métricas, limiares e decisões de retorno entre echelons (HEVNER et al., 2004; GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024).

Condições de aplicação e limites (boundary conditions). (i) Disponibilidade de proxies de alta fidelidade para avaliação formativa (modelos/benchmarks internos) e de tarefas contextualizadas para avaliação somativa (ENEM, pilotos); (ii) Governança de dados para evitar *leakage* e *teaching-to-the-test* (conjuntos congelados, *hold-outs*); (iii) Participação de *stakeholders* reais para PoV; (iv) Quando PoV imediato não for viável, empregar proxies naturalísticos documentados como tal e marcar limites de generalização (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Rastro de evidência (eDSR/FEDS). Em E2, pré-especificar objetivos/metaspes de avaliação (DO/DR) e critérios *pass/fail*; Em E3, planejar episódios e registrar DDRs de avaliação (o que medir, quando e por quê); Em E4, conduzir formativo/artificial (proxy Qwen, ablações CPT±IR, curvas de aprendizado, custos); Em E5, conduzir somativo/naturalístico (ENEM, pilotos como TCM-GO), coletando métricas e feedbacks e registrando o retorno a echelons anteriores (VENABLE; PRIES-HEJE; BASKERVILLE, 2016; HEVNER et al., 2004; GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024).

5.2.4 DP4 — Família de tamanhos alinhada ao contexto de adoção

Enunciado prescritivo. Para projetos de LLMs de nicho em PT-BR, multistakeholder e com orçamento finito (C), quando coexistem cenários de adoção heterogêneos quanto a hardware, latência e custo (P), os designers devem instanciar uma **família de tamanhos** (p.ex., ~4B e ~13B) derivada do mesmo pipeline (CPT→IR), com SLOs

Tabela 30 – Cartão DP3 — Avaliação dual (FEDS): Formativa/Artificial → Somativa/Naturalística

Enunciado	Para projetos de LLMs com risco técnico e exigência de utilidade contextual (C), quando avaliações tardias forem insuficientes e ocultarem regressões decisórias (P), encadear avaliações formativas/Artificiais (ablação, proxies, testes internos) antes de avaliações somativas/Naturalísticas (ENEM, pilotos) (A) para reduzir risco técnico e demonstrar valor contextual (E). (VENABLE; PRIES-HEJE; BASKERVILLE, 2016; GREGOR; HEVNER, 2013)
Mecanismos	M4 (estratégia dual FEDS) conectando E3 → E4 → E5, com ciclos de retorno quando necessário.
Evidências	• E3 DDR-Avaliação: objetivos e critérios registrados. • E4 Qwen: Formativa/Artificial — testes proxy e ablações (confirmado). • E4 ENEM 2024: Somativa/Naturalística — desempenho contextualizado (confirmado). • E5 Pilotos (TCM-GO, parceiros): Somativa/Naturalística — utilidade parcial (PoV).
Boundary	Objetivos ex-ante; congelamento de conjuntos de teste; custo de múltiplos episódios; necessidade de acesso a contexto real e governança para mitigar <i>leakage</i> .
Métricas	Passagem de <i>gates</i> E3→E4 (estabilidade e regressões), E4→E5 (ENEM), E5 (adoção e utilidade); calibração CPT/IR; impacto de ablações; custo/latência.
Risco	<i>Teaching-to-the-test</i> , <i>leakage</i> , proxies pouco fiéis; mitigar via <i>hold-outs</i> , congelamento e critérios predefinidos.
Estado	Confirmado (E3+E4) / PoV parcial (E5).

Fonte: Elaboração própria.

pré-especificados (latência, throughput, memória) e planos de quantização/serving por alvo de hardware; a seleção do modelo por caso de uso deve ser guiada pela avaliação dual FEDS e registrada em DDRs com critérios de retorno entre echelons (A), a fim de maximizar eficácia percebida e adoção sob restrições reais, mantendo rastro de evidência até o PoV (E) (HEVNER et al., 2004; GREGOR; HEVNER, 2013; VENABLE; PRIES-HEJE; BASKERVILLE, 2016; TUUNANEN; GHANBARI; KAZAN, 2024).

Propósito e contexto. A família de tamanhos desacopla qualidade de geração do custo de inferência, permitindo encaixe em ambientes diversos (edge/consumer GPU, A10/H100, CPU-cloud) sem reengenharia do pipeline. No Gaia, variantes 4B/13B emergem como compromisso entre qualidade e viabilidade de implantação, alinhadas ao foco em valor de P&D/ecossistema e adoção aberta (CRUZ-CASTAÑEDA; AMADEUS, 2025).

Mecanismo causal. (i) *Consistência comportamental*: treinar variantes a partir do mesmo subset curado (DP2) e do mesmo arranjo CPT→IR (DP1) preserva estilo/registro em PT-BR; (ii) *Eficiência de serving*: quantização e runtimes adequados reduzem memória/latência mantendo faixas de qualidade; (iii) *Adequação contextual*: a avaliação

FEDS (formativa/artificial $\rightarrow$ somativa/naturalística) identifica o ponto de Pareto qualidade $\times$ custo para cada cenário.

Relações com outros DPs. Depende de DP1 (CPT $\rightarrow$ IR) para preservar instrução em ambas as variantes; utiliza DP2 (curadoria por qualidade) para estabilizar ganhos em tamanhos distintos; requer DP3 (avaliação dual FEDS) para comparar eficácia/latência sob cargas realistas; e se operacionaliza via DP5 (DDRs), que registram SLOs, planos de quantização, métricas de carga e regras de fallback.

Condições de aplicação e limites (boundary conditions). (i) Targets de hardware claros e SLOs definidos em E2; (ii) Governança de avaliação para evitar *leakage*; (iii) Quando a utilidade exigir contexto altamente especializado, variantes muito pequenas podem degradar coerência discursiva — aplicar distillation ou routing e repetir avaliação somativa.

Rastro de evidência (eDSR/FEDS). E2: formalização de DO/DR (SLOs, hardware-alvo, orçamento). E3: decisão sobre tamanhos e quantização/serving documentada em DDRs. E4: testes formativos/artificiais (latência, memória, trade-offs qualidade $\times$ custo). E5: validação somativa/naturalística em pilotos (tempo de resposta, taxa de erro percebida, custo por requisição).

Tabela 31 – Cartão DP4 — Família de tamanhos para adoção contextualizada

Enunciado	Para ecossistemas heterogêneos em hardware/latência (C), quando um único tamanho limitar adoção ou elevar custo (P), ofertar uma família de tamanhos (p.ex., $\sim$ 4B e $\sim$ 13B), derivada do mesmo pipeline CPT $\rightarrow$ IR, com SLOs e planos de quantização definidos ex-ante (A) para maximizar adequação contextual e adoção sob restrições reais (E). (GREGOR; HEVNER, 2013; VENABLE; PRIES-HEJE; BASKERVILLE, 2016)
Mecanismos	Consistência comportamental via CPT $\rightarrow$ IR; estabilidade via subset curado; avaliação FEDS para selecionar o tamanho ótimo por cenário.
Evidências	• E2: requisitos declarados (hardware-alvo, latência). • E3 DDR-Tamanhos: decisão registrada; racionalidade custo$\times$qualidade. • E4: testes de latência/memória/qualidade confirmam viabilidade 4B/13B. • E5: adoção parcial por hardware em pilotos.
Boundary	Targets disponíveis (A10/H100/consumer GPU); orçamentos; SLO de latência; risco de perda de coerência em variantes muito pequenas.
Métricas	Throughput; latência p95; memória; custo por 1k tokens; Δ ENEM; estabilidade comportamental.
Risco	Degradação de coerência em variantes pequenas; necessidade de distillation, routing ou ajuste fino adicional.
Estado	Confirmado (E2+E4) / PoV parcial (E5).

Fonte: Elaboração própria.

5.2.5 DP5 — Rastreabilidade de decisões (DDRs) acoplada a echelons

Enunciado prescritivo. Para projetos de LLMs de nicho em PT-BR, multistakeholder e com orçamento finito (C), quando decisões técnicas críticas são tomadas sob incerteza e ao longo de iterações não lineares (P), os designers devem registrar cada decisão como um **Design Decision Record (DDR)**, acoplado explicitamente a um **echelon eDSR (E#)**, incluindo enunciado, racionalidade, momento, evidências, plano de avaliação FEDS, critérios de sucesso/fallback, vínculos a DO/DR e ponteiros para artefatos. Os DDRs devem ser promovidos ou revisados conforme resultados PoC/PoV (A), a fim de preservar rastreabilidade entre construir–avaliar, reduzir ambiguidade organizacional e transformar decisões locais em conhecimento de design generalizável (E) (HEVNER et al., 2004; GREGOR; HEVNER, 2013; VENABLE; PRIES-HEJE; BASKERVILLE, 2016; TUUNANEN; GHANBARI; KAZAN, 2024; KUECHLER; VAISHNAVI, 2012).

Propósito e contexto. DDRs formalizam “o porquê” e “o quando” de cada escolha (p.ex., CPT→IR), evitando que fiquem invisíveis em model cards e permitindo o acoplamento processo–evidência exigido pela DSR. O mapeamento $DDR \leftrightarrow E\#$ torna observável o fluxo $E2 \rightarrow E3 \rightarrow E4 \rightarrow E5$ em projetos sociotécnicos e iterativos (TUUNANEN; GHANBARI; KAZAN, 2024; KUECHLER; VAISHNAVI, 2012).

Mecanismo causal. (i) *Estruturação da decisão*: o formato DDR força a explicitação de alternativas, trade-offs e critérios *ex ante*, reduzindo vieses de reconstrução posterior (HEVNER et al., 2004). (ii) *Acoplamento avaliativo*: ao incluir plano FEDS (formativo/somativo; artificial/naturalístico), o DDR cria laço verificável entre decisão e episódio de avaliação (VENABLE; PRIES-HEJE; BASKERVILLE, 2016). (iii) *Generalização*: DDRs confirmados tornam-se insumos para Princípios de Design e boundary conditions, compondo teoria de médio alcance (GREGOR; HEVNER, 2013).

Relações com outros DPs. DP1 e DP2 requerem DDRs para registrar racionalidade, risco e critérios; DP3 consome DDRs como plano de avaliação; DP4 precisa de DDRs para estabelecer SLOs, targets de hardware e fallback; DP5 é o elemento integrador que institucionaliza o fluxo eDSR/FEDS.

Condições de aplicação e limites (boundary conditions). Requer: (i) governança mínima para versionamento/assinatura de decisões; (ii) disciplina de evidências (links para issues/PRs, benchmarks, pilotos); (iii) janela temporal para avaliação planejada. Limites: ambientes com decisões totalmente estáveis podem usar DDR reduzido; contextos hiperdinâmicos exigem DDRs lightweight com posterior consolidação.

Rastro de evidência (eDSR/FEDS). E2: abrir DDR rascunho vinculado a DO/DR; E3: fixar enunciado, alternativas e plano FEDS (métricas pass/fail e fallback); E4: registrar resultados formativos/artificiais (ablação, proxies); E5: registrar resultados somativos/naturalísticos (pilotos), decidindo promover/revisar DDR ou retornar a E2/E3.

Template mínimo recomendado (conteúdo). [ID] [Echelon E#] [Título] [Enunciado] [Racionalidade/hipótese] [Alternativas/trade-offs] [Vínculo a DO/DR] [Plano FEDS: propósito + paradigma + métricas pass/fail] [Evidências/ponteiros] [Fallback/rollback] [Status: hipótese, parcial, confirmado] [Data/Assinatura].

Tabela 32 – Cartão DP5 — Rastreabilidade via DDRs acoplada a echelons

Enunciado	Para consórcios multistakeholder e auditoria acadêmica (C), quando decisões críticas ficam invisíveis ou dispersas em múltiplos artefatos (P), registrar DDRs vinculados a echelons eDSR e à tipagem FEDS (A) para transformar escolhas técnicas em conhecimento generalizável e rastreável (E) (KUECHLER; VAISHNAVI, 2012; GREGOR; HEVNER, 2013).
Mecanismos	Estruturação ex-ante de alternativas e critérios; acoplamento eDSR↔FEDS; documentação de M1–M4.
Evidências	• E3 DDRs: estruturação confirmada. • E4–E5: vínculos com PoC/PoV (parcial).
Boundary	Políticas de confidencialidade; tempo de engenharia; padrão mínimo de campos; necessidade de versionamento.
Métricas	Cobertura DDR (decisões críticas documentadas/total); completude de ponteiros; aderência ao plano FEDS.
Risco	Falta de versionamento; DDRs incompletos; registro tardio; ambiguidade de critérios; perda de rastro entre echelons.
Estado	Confirmado (E3) / PoV parcial (E5).

Fonte: Elaboração própria.

5.3 Implicações

Acadêmicas. A formalização do processo por echelons (eDSR) e sua amarração a episódios FEDS torna o design sociotécnico “visível” e rastreável, reduzindo a “caixa-preta” típica de projetos de IA e permitindo auditar a passagem de DO/DR → DDR → PoC/PoV (TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016; LIPTON; STEINHARDT, 2018). Ao derivar DPs com *boundary conditions* e ponteiros de evidência, o trabalho entrega uma teoria de médio alcance aplicável a línguas sub-representadas: liga mecanismos técnicos (CPT, IR, curadoria por qualidade) a efeitos observáveis de eficácia/utilidade em contextos nacionais, contribuindo para a base de conhecimento da DSR e para a consolidação de *design knowledge* acumulável (GREGOR; HEVNER, 2013; HEVNER et al., 2004; JINDAL; AL., 2024; SCOTTI; CRUZ-CASTAÑEDA; AMADEUS, 2025).

Práticas. O resultado é um roteiro replicável de execução: (E2) priorização de eficácia e explicitação de requisitos; (E3) *pipeline* CPT+IR com DDRs e subset nacional orientado por estabilidade/ruído; (E4) PoC dual (formativa/artificial e somativa/*proxy*

contextualizado) com benchmarks de alta fidelidade (ENEM); (E5) PoV focado em valor de P&D/ecossistema e governança de adoção por família de tamanhos (JINDAL; AL., 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016; TUUNANEN; GHANBARI; KAZAN, 2024). Em ambientes multistakeholder, o uso disciplinado de DDRs e da matriz FEDS reduz ambiguidade, acelera ciclos *build-evaluate* e melhora a transferência de *know-how* para novas instâncias de LLMs de nicho (HEVNER et al., 2004; GREGOR; HEVNER, 2013).

5.4 Validade e limitações

As evidências primárias concentram-se em um respondente-chave e não cobrem integralmente a dimensão organizacional da PoV (adoção/roadmap), o que limita inferências sobre ciclos de realimentação interinstitucionais; além disso, a classificação “naturalística (*proxy*)” do ENEM, embora justificável, permanece uma aproximação do uso em serviço (campo) (VENABLE; PRIES-HEJE; BASKERVILLE, 2016). Mitigamos esses riscos pela regra de convergência entrevista+documento, triangulação entre literatura/pilares, documentação pública e DDRs, e explicitação do status (hipótese/parcial/confirmado) por *echelon*; ainda assim, a generalização deve respeitar as *boundary conditions* declaradas (HEVNER et al., 2004; GREGOR; HEVNER, 2013; TUUNANEN; GHANBARI; KAZAN, 2024).

Referências

- ADELANI, D.; AL. et. Global performance asymmetry in llms. 2024. 19, 23, 37, 38
- ADELANI, D. et al. Zero-shot transfer capabilities of gpt-4 in brazilian indigenous languages. 2025. 21, 22, 37, 39
- Alibaba Cloud. *Qwen2.5 Technical Report*. 2024. Preprint. 74, 75
- ASSIS, G.; FREITAS, L.; PAES, R. Fauna de llms brasileiros: Um panorama de arquiteturas. 2025. 22, 37, 39, 42, 43, 44, 45
- BOMMASANI, R. et al. On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258*, 2021. 20
- CEIA-UFG. *Model Card: Gemma-3-Gaia-PT-BR-4b-it*. 2025. Hugging Face Repository. Disponível em: <https://huggingface.co/CEIA-UFG>. 48
- COSTA-JUSSÀ, M. R.; AL. et. Nllb: No language left behind. 2022. 38, 41
- COSTA-JUSSÀ, M. R. et al. Nllb: No language left behind: Scaling human-centered machine translation. *arXiv preprint arXiv:2207.04672*, 2022. 19, 23, 37
- CRUZ-CASTAÑEDA, J.; AMADEUS, L. Tornando visível o design de llms: um estudo edsr do projeto gaia em português brasileiro. 2025. Manuscrito não publicado. 5, 19, 21, 22, 23, 24, 26, 28, 38, 41, 42, 45, 91
- DARĠIS, R.; AL. et. Generative failures in low-resource languages: the case of latvian. 2024. 19, 21, 23, 37, 38, 42
- DELOBELLE, P.; WINTERS, T.; BERENDT, B. Robbert: a dutch roberta-based language model. 2020. 41
- FEDUS, W.; ZOPH, B.; SHAZEER, N. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. *Journal of Machine Learning Research*, 2022. 75
- Gemma Team. *Gemma Model Card and Architecture Notes*. 2024. Technical report. 74
- Gemma Team; Google DeepMind. *Gemma 3: Open Foundation Models*. 2025. Technical Report. 76
- GHANBARI, H.; TUUNANEN, T.; KAZAN, E. Dsr in the era of generative ai. *Journal of Management Information Systems (Forthcoming)*, 2025. 5, 83
- Google DeepMind. *Gemma: Open Models for the Next Generation of AI*. 2024. Technical report. 74, 75
- GREGOR, S.; HEVNER, A. R. Positioning and presenting design science research for maximum impact. *MIS quarterly*, JSTOR, p. 337–355, 2013. 5, 23, 24, 26, 27, 28, 37, 38, 45, 53, 60, 63, 64, 66, 67, 71, 72, 74, 75, 77, 79, 80, 83, 84, 85, 86, 87, 88, 89, 90, 91, 92, 93, 94, 95, 104, 105, 107, 108, 109, 110

- HEVNER, A. R. et al. Design science in information systems research. *MIS quarterly*, JSTOR, p. 75–105, 2004. 19, 24, 25, 26, 27, 37, 45, 47, 48, 51, 52, 60, 64, 66, 69, 74, 75, 79, 83, 85, 87, 88, 89, 90, 91, 93, 94, 95, 104, 105, 107, 108, 110
- HUANG, X.; MO, Y.; ZHANG, Z. Assessing multilingual llms. 2024. Preprint. 19, 21
- HUANG, X.; MO, Y.; ZHANG, Z. Assessing multilingual llms. 2025. 21, 37, 45
- JINDAL, A.; AL. et. Instruction residuals for niche llms. 2024. 5, 9, 20, 25, 37, 39, 40, 44, 48, 49, 52, 55, 57, 61, 72, 75, 84, 85, 86, 87, 94, 95
- KADDOUR, J. et al. Challenges and applications of large language models. *arXiv preprint arXiv:2307.10169*, 2023. 20
- KITCHENHAM, B.; CHARTERS, S. Guidelines for performing systematic literature reviews in software engineering. *Technical Report, EBSE*, 2007. 64
- KUECHLER, W.; VAISHNAVI, V. A framework for theory development in design science research. *Journal of the Association for Information Systems*, 2012. 67, 71, 83, 85, 86, 87, 88, 90, 93, 94
- LIN, X. et al. Few-shot learning with multilingual language models. 2022. 20, 42
- LIPTON, Z. C.; STEINHARDT, J. Troubling trends in machine learning scholarship. *arXiv preprint arXiv:1807.03341*, 2018. 5, 24, 25, 26, 28, 84, 85, 86, 88, 94
- LIPTON, Z. C.; STEINHARDT, J. Troubling trends in machine learning scholarship. *Queue*, v. 17, n. 1, p. 45–77, 2019. Também disponível como arXiv:1807.03341 (2018). 37, 63
- MARCH, S. T.; SMITH, G. F. Design and natural science research on information technology. *Decision support systems*, Elsevier, v. 15, n. 4, p. 251–266, 1995. 26, 83
- Meta AI. *Introducing LLaMA 3.1*. 2024. Technical report. 74, 75
- Mistral AI. *Mistral 7B and Mixtral Model Card*. 2023. Technical report. 74, 75
- PAVA, A.; AL. et. Generative ai and large language models. 2025. 19, 43
- PEFFERS, K. et al. A design science research methodology for information systems research. *Journal of Management Information Systems*, v. 1, n. 1, p. 1–10, 2007. 47, 48, 51, 69, 85
- RAFFEL, C. et al. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, v. 21, n. 140, p. 1–67, 2020. 75
- ROZIÈRE, B. et al. Code llama: Open foundation models for code. 2023. 42, 44
- SCAO, T. L. et al. Bloom: A 176b-parameter open-access multilingual language model. *BigScience Workshop*, 2023. 19, 21, 37, 41
- SCHUCK, A.; AL. et. Generalization capabilities of sota llms. 2025. 43
- SCOTTI, V.; CRUZ-CASTAÑEDA, J.; AMADEUS, L. Corpus jabuticaba: 139 bilhões de tokens em português. 2025. 19, 22, 29, 38, 45, 61, 88, 89, 94

- SEIN, M. K. et al. Action design research. *MIS quarterly*, p. 37–56, 2011. 24, 25, 27, 37, 47
- TUUNANEN, T.; GHANBARI, H.; KAZAN, E. Echeloned design science research. *MIS Quarterly*, 2024. 5, 19, 20, 23, 24, 25, 26, 27, 28, 37, 38, 44, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55, 57, 58, 60, 61, 63, 64, 67, 69, 72, 80, 83, 84, 85, 86, 87, 88, 89, 90, 91, 93, 94, 95, 104, 105, 107, 108, 109, 110
- VENABLE, J.; PRIES-HEJE, J.; BASKERVILLE, R. Feds: a framework for evaluation in design science research. *European journal of information systems*, Taylor & Francis, v. 25, n. 1, p. 77–89, 2016. 5, 19, 24, 25, 27, 29, 37, 38, 44, 45, 46, 48, 50, 51, 52, 53, 54, 55, 56, 57, 58, 60, 61, 63, 64, 67, 72, 75, 77, 79, 80, 83, 84, 85, 86, 87, 88, 89, 90, 91, 92, 93, 94, 95, 104, 105, 108, 109, 110
- WU, S. et al. Bloomberggpt: A large language model for finance. 2023. 44
- WU, Y. et al. Open source vs closed source llms. 2023. 44
- ZHANG, S. et al. Opt: Open pre-trained transformer language models. *arXiv preprint arXiv:2205.01068*, 2022. 20

Apêndices

APÊNDICE A – Proposições Testáveis e Modelo de Maturidade eDSR

Este apêndice apresenta dois artefatos conceituais derivados da teoria de médio alcance discutida no Capítulo 5: (i) um conjunto de proposições testáveis (P1–P5) articuladas a partir das relações C–P–M–E; e (ii) um modelo de maturidade para adoção progressiva do eDSR em projetos de LLMs.

A.1 Proposições testáveis derivadas da teoria de médio alcance

Tabela 33 – Proposições testáveis (P1–P5) baseadas na teoria de médio alcance C–P–M–E

ID	Relação C–P–M–E	Proposição testável (Pi)	Condições contingenciais	Limites de validade
P1	CPT → IR → NLG	Em contextos de LLMs de nicho com orçamento finito (C), aplicar CPT seguido de IR melhora o desempenho instrucional em PT-BR (E) frente a modelos multilíngues sem esse pipeline.	Corpus nacional curado; métricas instrucionais; compute mínimo.	Restrita a arquiteturas <i>decoder-only</i> ; exige separação rigorosa treino–teste.
P2	Curadoria por qualidade → estabilidade de treino	Conjuntos curados por qualidade (dedup, LID, perplexidade) geram maior estabilidade e melhor NLG do que corpora brutos, mantendo o mesmo orçamento de tokens.	Preservação de diversidade temática; monitoramento de perda e gradiente.	Menor aplicabilidade em domínios ultranichados com poucos dados.
P3	Avaliação dual FEDS → menor risco	Estratégia dual FEDS (formativa + somativa) reduz regressões e aumenta confiança dos stakeholders em comparação a avaliações concentradas apenas ao final.	Benchmarks de alta fidelidade; pilotos; governança de dados.	Aplicação limitada em projetos de ciclo único (<i>one-shot</i>).
P4	Família de tamanhos → adoção	Ofertar uma família de tamanhos (p.ex., 4B/13B) aumenta adequação percebida e taxa de adoção em ambientes heterogêneos de hardware.	SLOs de latência/throughput definidos; roteamento por caso de uso.	Pouco relevante em ambientes totalmente homogêneos em <i>cloud</i> .
P5	DDRs + eDSR → reusabilidade	Documentar decisões em DDRs vinculados a echelons aumenta reusabilidade e auditabilidade em comparação com apenas <i>model cards</i> .	Versionamento; disciplina documental; armazenamento compartilhado.	Menor impacto em projetos pequenos com poucas decisões críticas.

Fonte: Elaboração própria com base em (GREGOR; HEVNER, 2013; HEVNER et al., 2004; TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

A.2 Modelo de maturidade para adoção do eDSR

O Quadro 2 sintetiza cinco níveis de adoção do eDSR, variando da documentação básica de echelons (Nível 1) à capacidade de gerar princípios de design generalizáveis (Nível 5).

Nível	Rótulo	Descrição	Evidências mínimas
1	Documentação básica de echelons	Registro narrativo simples dos echelons E1–E5, sem vinculação formal entre artefatos.	Descrição do problema, requisitos gerais, design alto nível e resultados PoC/PoV.
2	DDRs estruturados	Decisões centrais documentadas em DDRs com campos obrigatórios (racionalidade, alternativas, vínculo E#, etc.).	DDRs para backbone, curadoria, CPT→IR; rastreabilidade manual E2→E3→E4.
3	Avaliação FEDS sistemática	Episódios planejados explicitamente como formativos/somativos e artificiais/naturalísticos.	Matriz FEDS; critérios <i>pass/fail</i> pré-definidos; PoC e PoV separados.
4	Feedback E5→E2	Ciclos iterativos onde resultados de PoV retroalimentam requisitos e decisões de design.	DDRs com campos de feedback; versões sucessivas de DO/DR; documentação de ajustes motivados por PoV.
5	DPs generalizáveis	Organização sintetiza seus aprendizados em Princípios de Design com condições de contorno.	Presença de DPs; teoria C–P–M–E consolidada; plano de reuso/replicação.

Fonte: Elaboração própria com base em (GREGOR; HEVNER, 2013; HEVNER et al., 2004; TUUNANEN; GHANBARI; KAZAN, 2024; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

Quadro 2: Modelo de maturidade para adoção do eDSR em projetos de LLMs

APÊNDICE B – Artefatos Computáveis

C.1 Tabela-mestra eDSR (template preenchível)

A Tabela-Mestra eDSR consolida todo o ciclo E1–E5 em um único artefato computável, permitindo rastreabilidade vertical (entre echelons) e horizontal (entre decisões, avaliações e evidências). Ela pode ser exportada diretamente para Excel, Notion ou Google Sheets.

C.2 Checklist DDR para registro disciplinado de decisões de design

O checklist a seguir oferece uma estrutura padronizada para registros DDR (*Design Decision Records*). Ele visa garantir transparência, rastreabilidade e reuso ao longo do ciclo eDSR.

ID	Item do Checklist	Status
1	Título claro e específico da decisão (ex.: “Escolha do backbone 13B”).	☐
2	Data da decisão e versão do projeto (v0.1, v0.2...).	☐
3	Responsáveis pela decisão (nomes ou papéis).	☐
4	Echelon relacionado (E2: requisitos, E3: design, etc.).	☐
5	Problema motivador (contexto que levou à decisão).	☐
6	Alternativas consideradas (A1, A2, A3) e critérios de comparação.	☐
7	Justificativa da escolha (argumentos técnicos, custos, riscos, constraints).	☐
8	Evidências que sustentam a decisão (benchmarks, logs, literatura, PoC).	☐
9	Registro de consequências esperadas (impacto em desempenho, custo, risco).	☐
10	Riscos residuais e mitigações planejadas.	☐
11	Dependências com outras decisões (encadeamento DDR → DDR).	☐
12	Versão “fallback” caso a decisão falhe (plano B explícito).	☐
13	Critérios de validação da decisão (quando ela será considerada correta).	☐
14	Resultados observados após execução (preencher em E4/E5).	☐
15	Revisão posterior: manter, ajustar ou abandonar decisão.	☐

Fonte: Elaboração própria com base em práticas de DDR e eDSR (TUUNANEN; GHANBARI; KAZAN, 2024; GREGOR; HEVNER, 2013; HEVNER et al., 2004).

Quadro 3: Checklist DDR — Estrutura recomendada

Tabela 34 – Template — Tabela-mestra eDSR (E1–E5)

Echelon	Objeto	Campos preenchíveis	Evidências / Pontos	Decisões / Saídas
E1	Problema	- Descrição do problema - Lacuna empírica/teórica - Stakeholders afetados - Hipóteses iniciais	- Entrevistas iniciais - Documentação setorial - Literatura-base	- Declaração formal do problema - Escopo da investigação
E2	Requisitos (DO/DR)	- Objetivos (DO) - Requisitos (DR1...DRn) - Prioridade (Crítico/Priorizável) - Métricas desejadas - Restrições de contexto	- Benchmarking - Minutas internas - Critérios de stakeholders	- Lista DO/DR priorizada - Critérios de promoção para E3
E3	Design / Desenvolvimento	- Decisões técnicas tomadas - Alternativas consideradas - Justificativa - Campos DDR (ID, racionalidade, vínculo E#, fallback)	- DDRs - Logs de treino/curadoria - Arquitetura / artefatos intermediários	- Versão candidata do artefato - Design consolidado para PoC
E4	Prova de Conceito (PoC)	- Tipo FEDS (formativa / artificial) - Experimentos / ablações - Métricas pass/fail - Protocolos	- Benchmarks - Resultados de ablação - Comparações com baseline	- Validação formativa - Decisão de promover, revisar ou descartar design
E5	Prova de Valor (PoV)	- Avaliação somativa / naturalística - Casos de uso reais - Métricas de utilidade/percepção - Ciclos de feedback E5→E2	- Pilotos - Feedback de stakeholders - Relatório de adoção	- Valor entregue - Ajustes ao DO/DR - Insumos para DPs e teoria de médio alcance

Fonte: Elaboração própria com base nos frameworks eDSR e FEDS (TUUNANEN; GHANBARI; KAZAN, 2024; GREGOR; HEVNER, 2013; HEVNER et al., 2004; VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

C.3 Matriz FEDS Interativa para Episódios de Avaliação

A matriz abaixo operacionaliza o FEDS (*Framework for Evaluation in Design Science*) permitindo classificar episódios de avaliação de acordo com:

- **Propósito:** Formativo (F) ou Somativo (S);
- **Paradigma:** Artificial (A) ou Naturalístico (N);

- **Echelon associado:** E3, E4, E5;
- **Cr terios de sucesso** (*pass/fail*) pr -especificados;
- **Rastro para DDRs.**

ID	Epis�dio de avalia��o	Classifica��o FEDS	Cr�terios de sucesso (<i>pass/fail</i>)	Echelon
1	Benchmark interno (ex.: ENEM proxy, perplexidade, abla��o)	Formativo�Artificial (F�A)	Estabilidade de treino; aus�ncia de regress�es; melhoria em m�tricas chave.	E4
2	Teste comparativo com proxy (p.ex., Qwen 2.5)	Formativo�Artificial (F�A)	Pareto custo�qualidade; an�lise de trade-offs; decis�o informada para DDR.	E4
3	Avalia��o somativa via ENEM 2024 (contexto realista)	Somativa�Natural�stica (S�N)	Desempenho m�nimo pr�-definido; robustez a varia��o tem�tica.	E4/E5
4	Piloto com �rg�os parceiros (ex.: TCM-GO, CEIA-UFG)	Somativa�Natural�stica (S�N)	Validade externa; feedback qualitativo; taxa de ado��o; custo operacional.	E5
5	Avalia��o cont�nua de PoV (impacto em ecossistema/P&D)	Somativa�Natural�stica (S�N)	Utilidade percebida; difus�o; gera��o de DPs; reuso institucional.	E5

Fonte: Elabora  o pr pria com base em (VENABLE; PRIES-HEJE; BASKERVILLE, 2016; TUUNANEN; GHANBARI; KAZAN, 2024; GREGOR; HEVNER, 2013).

Quadro 4: Matriz FEDS interativa para classifica  o de epis dios de avalia  o

Nota de uso: Para cada novo epis dio de avalia  o, recomenda-se:

- abrir um DDR correspondente e vincul -lo ao epis dio na matriz;
- pr -registrar cr terios de *pass/fail*;
- congelar conjuntos de teste para garantir validade;
- registrar rastro entre E4 (PoC) e E5 (PoV);
- atualizar a matriz conforme novos epis dios forem sendo realizados.

C.4 Modelo de maturidade para ado  o do eDSR (visual)

O quadro a seguir sintetiza um modelo de maturidade para ado  o do *Echeloned Design Science Research* (eDSR) em projetos de LLMs, organizado em cinco n veis progressivos. Cada n vel representa um patamar de sofistica  o na forma como a organiza  o

documenta, avalia e generaliza o conhecimento de design gerado ao longo dos echelons (E1–E5).

Nível	Rótulo	Descrição	Evidências mínimas
1	Documentação básica de echelons	A equipe registra, ainda que de forma narrativo-descritiva, os principais elementos dos echelons E1–E5 (problema, requisitos, design, PoC, PoV), mas sem estrutura formal de vínculos entre eles.	Texto ou documento único com descrição do problema, requisitos gerais, esboço de arquitetura e resultados de avaliação (PoC/PoV) apresentados de modo agregado.
2	DDRs estruturados	Decisões centrais de design são formalizadas em <i>Design Decision Records</i> (DDRs) com campos obrigatórios (enunciado, racionalidade, alternativas, vínculo a E#, plano de avaliação).	DDRs específicos para: escolha de <i>backbone</i> , estratégia de curadoria de dados, pipeline CPT→IR; menção explícita ao echelon em que cada decisão é tomada (E2/E3/E4).
3	Avaliação FEDS sistemática	Os episódios de avaliação são planejados e classificados explicitamente segundo o FEDS (Formativo/Somativo × Artificial/Naturalístico), com critérios de <i>pass/fail</i> definidos ex ante.	Matriz FEDS preenchida; benchmarks identificados como formativos (F–A) ou somativos (S–N); registro de quais episódios sustentam PoC e quais sustentam PoV, com rastro para DDRs.
4	Ciclos de feedback E5→E2	Resultados de PoV (E5) realimentam sistematicamente requisitos (E2) e decisões de design (E3), configurando ciclos iterativos explícitos (aprendizado organizacional).	Versões sucessivas de DO/DR; DDRs atualizados com campo de feedback; evidência de que pilotos, stakeholders e uso em serviço motivaram revisões de requisitos e ajustes arquiteturais.
5	Geração de DPs generalizáveis	A organização consolida o aprendizado em Princípios de Design (DPs) com condições de contorno e teoria de médio alcance (C–P–M–E), visando reuso em novos projetos e contextos.	Presença de DPs documentados (C–P–A–E), <i>boundary conditions</i> explícitas, mapa C–P–M–E formulado e plano de reuso/replicação (outros projetos ou domínios).

Fonte: Elaboração própria com base em (HEVNER et al., 2004; GREGOR; HEVNER, 2013; VENABLE; PRIES-HEJE; BASKERVILLE, 2016; TUUNANEN; GHANBARI; KAZAN, 2024).

Quadro 5: Modelo de maturidade eDSR em projetos de LLMs

Sugestão de uso: Este modelo pode ser utilizado como guia diagnóstico e de planejamento:

- **Diagnóstico:** marcar o nível atual do projeto (1–5) a partir das evidências disponíveis;
- **Planejamento:** definir ações concretas para migrar de um nível ao seguinte (p.ex., introduzir DDRs, criar matriz FEDS, instituir ciclos de feedback E5→E2);

- **Comparação:** utilizar o modelo para comparar maturidade eDSR entre projetos, unidades ou organizações distintas.